齿轮外观缺陷检测

系统技术报告

自建数据·两类缺陷选型·参数依据·软件集成

GearPro 阶段记录日期：2026 年 10 月 8 日

摘要

针对齿轮外观质检中划痕和齿部缺损的自动识别问题，本项目基于自建数据集，设计并实现了一套运行于 Jetson Orin NX 边缘设备的齿轮外观缺陷检测系统。数据来自 50 个自行采购或定制的齿轮（正常 10 个、划痕 15 个、齿部缺损 25 个），由流水线原型上的工业相机从多个角度拍摄，并按图像中的可见缺陷人工标注。早期实验将两类缺陷合并为“有无缺陷”的单一分类任务，即使增加模型数量，低对比度划痕的检出也没有改善。因此，系统先定位齿轮并裁剪感兴趣区域，再对两类缺陷分别建模：每类缺陷由 EfficientNet-B0、ResNet18（残差网络，Residual Network）两个分类模型和一个 YOLO26n 检测模型组成，三者的分数经温度缩放后加权融合，任一类分数超过阈值即判为疑似缺陷。

两类缺陷的检测结构依据验证集实验分别确定：划痕检测模型加入高分辨率的 P2 检测层（特征金字塔第 2 层，相对输入图像下采样 4 倍），以保留细小纹理；齿部缺损采用单类标注。判定阈值按经验的奈曼–皮尔逊准则选择，即在验证集 P_{FA}（无可见目标缺陷图像被误报的比例）不超过 0.20 时，使 P_D（缺陷图像被检出的比例）最大。固定全部参数后，在 150 张测试图像上，系统检出 71 张缺陷图像中的 63 张（$P_D = 88.73\%$），在 79 张无可见目标缺陷的图像中误报 18 张（$P_{FA} = 22.78\%$）；同一测试集上，当前统一缺陷分类配置检出 54 张、误报 33 张。该比较只代表当前两套配置，已记录的漏检主要涉及浅划痕和斜向位置的齿部缺损。

现用参数来自有限候选和验证阈值扫描，而不是理论常数。划痕子系统中分类分数占 0.25、检测分数占 0.75，阈值 0.3003 正好落在一个验证集缺陷样本的分数上，与阈值下方最近的正常样本只差约 0.0004，没有预留分数余量；融合分数也不是校准后的真实缺陷概率，因此 0.5 不是天然分界。按固定测试结果模拟，当可见缺陷比例为 1% 时，两类合并系统的精确率约 3.78%，每千张图像约有 225.6 次虚警。这些结果说明现有配置可用于研究阶段的疑似件筛选，但阈值和复核负担仍需在真实产线数据上重新确定。

检测软件已在第一代整机上与工业相机、Web 监控界面和 STM32 分拣机构完成原型联调；整机按上下双相机设计，目前测试仍使用单路相机。由于图像尚未对应到具体工件，整机运行也未经系统测试，现有结果只反映离线图像上的表现，系统当前定位为辅助人工复核。下一步将用未参与训练的新齿轮开展现场测试，验证系统的泛化能力和实时性。

关键词：齿轮外观检测；划痕；齿部缺损；模型融合；边缘计算

目录

1 引言 1

2 国内外研究现状 1

3 技术路线 2

4 系统总体设计 3

5 数据集 4

6 检测方法 6

7 选型实验 8

8 测试结果与分析 13

9 结论与下一步工作 16

附录 A 术语及方法名称 17

附录 B 关键固定训练参数与资料索引 18

附录 C 数据检查细节 20

附录 D 早期方案详细记录 21

附录 E 候选实验与未采用配置 23

附录 F 参数选择与补充结果 24

附录 G 原型状态与后续测量 29

附录 H 文献与证据的对应关系 31

参考文献 32

1 引言

1.1 应用场景

针对传送带逐件输送场景中的齿轮划痕与齿部缺损筛查问题，本项目设计并实现了一套边缘端机器视觉检测系统。现场流程是传送带一次只送入一个齿轮，齿轮到达检测工位后完成图像采集和缺陷判定，再由分拣机构送入相应工位。整机装有上下两台工业相机，设计目标是两路各自检测后取或；本阶段的数据采集和测试只使用其中一台相机，因此报告结论均限于单路图像检测。

1.2 研究任务

本项目的任务是完成从图像采集、齿轮定位、缺陷判定到结果显示、统计和分拣信号输出的检测链路。检测对象包括两类外观缺陷：一类是划痕，另一类是 missing_hole，即齿侧、齿角等部位的局部缺失。判定以单张图像为单位；图像中存在可见的目标缺陷即为正样本，系统输出“疑似缺陷”或“未检出缺陷”，软件中的 REJECT（拒收）和 PASS（通过）字段分别对应这两种输出。

项目将所有明确可见的划痕和齿部缺损都视为不合格，没有建立按深度、尺寸或机械性能分级的合格标准。因此，本系统识别的是已定义的外观缺陷，不评价齿轮的服役安全。考虑到现有测试数据有限，系统当前定位为辅助手段：疑似件交由人工复核，模型未检出的工件如何抽查，仍需结合现场流程确定。

1.3 关键技术

本项目的关键技术包括目标区域提取、面向不同缺陷的模型改造、异构模型分数融合和边缘端集成。首先，用目标检测模型在整帧图像中定位齿轮并裁剪感兴趣区域（region of interest，ROI），把后续判断限制在齿轮表面。其次，针对划痕细小、齿部缺损位置变化较大的特点，分别选择检测结构和训练配置。再次，将两个图像分类模型的整体纹理判断与一个目标检测模型的局部线索融合，在验证集上选择融合系数和判定阈值。最后，把固定配置部署到 Jetson Orin NX（英伟达公司的嵌入式人工智能计算模块，下文简称 NX），与相机、网页和串口分拣链路连接。本文的技术工作不是提出新的通用网络，而是围绕逐件输送的齿轮检测场景选择并改造已有方法。

2 国内外研究现状

2.1 齿轮与工业表面缺陷检测

深度学习已成为齿轮外观缺陷检测的重要路线，研究重点从能否识别逐步转向小缺陷、背景干扰和边缘端效率。Yu 等针对工业背景中的断齿、缺齿和划痕，采用背景弱化与改进 YOLO（You Only Look Once，一类单阶段目标检测算法）v3 相结合的方法，并在在线检测平台上验证了微小缺陷识别能力 [18]。Yan 等通过轻量化骨干网络和特征融合改造 YOLOv5，在减少参数量的同时保持齿轮表面缺陷检测性能 [19]。Zhang 等针对油污和阴影干扰，引入注意力机制与双向特征融合，提高了齿轮缺陷的检出表现 [20]。国内关于深度学习表面缺陷检测的综述也指出，数据规模、微小缺陷特征和复杂成像条件是工业应用中的共同问题 [21]。这些研究说明，齿轮缺陷检测通常需要结合具体成像条件改造网络，不能只依赖通用模型的默认配置。

2.2 两级检测与小缺陷特征

先定位部件、再判断缺陷，是降低背景干扰并统一后续输入的一条成熟路线。Chen 等在接触网紧固件检测中采用级联定位与缺陷诊断 [22]；Tao 等先定位绝缘子，再对裁剪区域进行缺陷检测 [23]；Wei 等在轨道扣件检测中比较了先定位后分类与端到端检测方法 [24]。这些工作与本项目“先定位齿轮、再分析齿轮表面”的任务结构一致，为两级流程提供了方法依据。

高分辨率特征有助于保留小缺陷信息，但增加检测层并不保证在所有任务上都有效。变换器预测头 YOLOv5（Transformer Prediction Head YOLOv5，TPH-YOLOv5）在无人机小目标场景中增加高分辨率预测头，以改善微小目标检测 [25]；Tang 等在印制电路板表面缺陷检测中增加 160×160 小目标检测层，也报告了较好的检测结果 [26]。本项目据此把高分辨率 P2 检测层作为划痕候选结构，同时仍通过同一验证集上的配置比较决定是否采用，而不把其他场景的结果直接当作本项目结论。

2.3 小样本迁移与模型融合

在工业缺陷样本有限时，迁移学习和多模型融合可以利用已有特征并组合不同线索。Kim 等将迁移学习用于自动光学检测，在少量微调后显著提高分类性能 [27]；Ren 等提出面向多类表面缺陷的通用迁移学习方法，说明预训练特征可降低对大量标注数据的依赖 [28]。在融合方面，Chen 等合并多个卷积网络的输出进行钢材表面缺陷分类 [29]，Stephen 等采用加权平均组合多个预训练网络判断有无缺陷 [30]，Kittler 等则系统讨论了求和、最大值等分类器组合规则 [16]。这些研究支持在同一任务中组合整体纹理和局部检测线索，但没有直接证明“按缺陷类别分别建模后取或”一定优于统一模型，因此本项目只比较当前两套配置，不作普遍结论。

2.4 本项目的切入点

现有研究为齿轮检测、两级流程、小目标特征和模型融合提供了方法基础，本项目的切入点是把这些方法组合到逐件输送的齿轮筛查场景中并记录完整选型过程。项目围绕划痕和齿部缺损的外观差异分别选择检测结构，以分类模型和检测模型提供互补分数，再把固定配置接入边缘端原型。与只报告单个网络精度的工作相比，本报告同时说明数据来源、参数选择、固定测试结果和尚未完成的现场验证，以便评审判断技术路线是否闭合。

3 技术路线

3.1 总体路线

本项目采用“明确场景与标签、建立数据集、两级检测、验证选参、固定测试、原型集成”的技术路线。第一步，根据逐件输送场景定义划痕和齿部缺损的图像级标签，并采集多角度图像。第二步，在整帧中定位齿轮并裁剪 ROI，把齿轮表面作为两个缺陷检测子系统的共同输入。第三步，分别训练图像分类模型和目标检测模型，使前者提供整体纹理分数，后者提供局部缺陷分数。第四步，只在验证集上选择成员、温度、融合系数和阈值；配置固定后，用独立测试集报告结果。第五步，把同一判定链路部署到 NX，与图像采集、网页显示、统计和串口输出连接。

这一路线把方法选择和性能评价分开。文献用于确定可行的方法方向，候选实验用于确定当前配置，测试集用于评价固定配置，整机原型用于验证链路能否连通。当前结果仍是图像级离线评价，不能替代按新工件、真实缺陷比例和连续输送条件开展的现场验证。

3.2 本阶段工作与报告结构

本阶段已完成数据集整理、两类检测子系统选型、固定测试和单路原型集成。项目自建了 50 个齿轮的多角度图像数据集；早期统一模型的当前配置未显示出划痕检出改善，因此分别构建了划痕和齿部缺损检测子系统，每个子系统组合两个图像分类模型和一个目标检测模型。固定配置后，项目在同一批 150 张测试图像上比较了单类检测、当前两类合并配置和当前统一缺陷分类配置。检测流程已集成到 NX 上的软件中，与相机采集、Web 监控、统计和串口分拣连通。

第4章介绍系统组成，第5章说明数据集，第6章给出检测方法，第7章报告模型选型实验，第8章分析测试结果与局限性，第9章总结本阶段工作并给出下一步计划。术语定义、参数来源和补充实验记录见附录。

4 系统总体设计

4.1 硬件组成

第一代整机已经完成从上料、检测到分类收集的实物搭建，组成与信号流如图1所示。输送带将齿轮送入检测区，其启停和速度由 STM32（意法半导体公司的 32 位微控制器）控制。检测区采用透明亚克力载台，上下各安装一台工业相机，使齿轮的上下表面都能被观察。相机图像送入 Jetson Orin NX，在设备端完成齿轮定位和缺陷判定，不依赖远程服务器。判定结果一方面在 Web 页面上显示和统计，另一方面通过串口发送给 STM32，由步进电机驱动的旋转分拣平台将齿轮送入对应工位；电机采用平滑加减速，以减少齿轮在转动过程中被甩出。

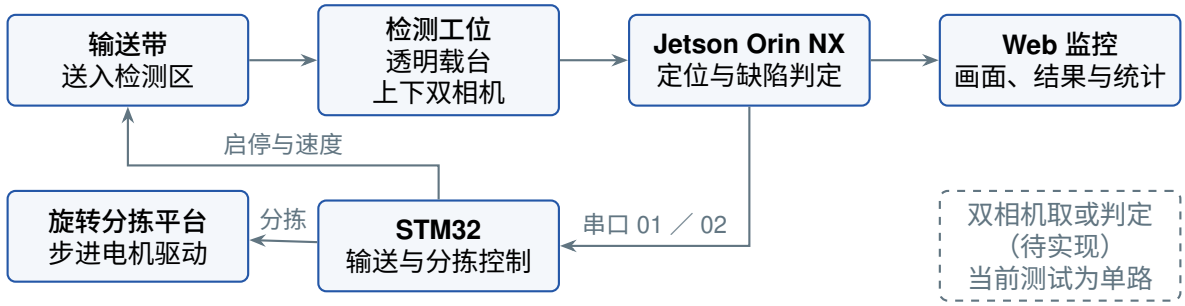


图 1 第一代整机组成与信号流。实线为已连通的链路；虚线框为双相机的设计用法，尚未实现。整机连通不等于当前模型已完成现场验证。

双相机的设计用法是两路图像各自完成检测，任一路判为疑似缺陷，该工件即判为疑似件。目前的软件测试和训练数据采集都只使用其中一台相机，双路取或的工件级判定尚未实现。第一代整机已连通输送、采集、检测、显示和分拣流程，但当前模型只做过简单现场测试，没有记录整机性能数据。

4.2 软件链路

软件运行在 Jetson Orin NX 上，后端采用 Python 语言的 FastAPI 网络框架，前端为基于 Vue 3（一种 JavaScript 前端框架）的网页，图像采集和推理均在后台线程中进行（图2）。采集线程只保留最新一帧，推理较慢时不会积压图像；推理线程依次执行齿轮定位、感兴趣区域（region of interest，ROI）裁剪和两个检测子系统，并把成员模型分数、阈值、预测类别、辅助预测框和各阶段耗时写入同一个检测结果对象。网页显示、统计和串口都读取这一对象，因此不同输出端的判定始终一致。

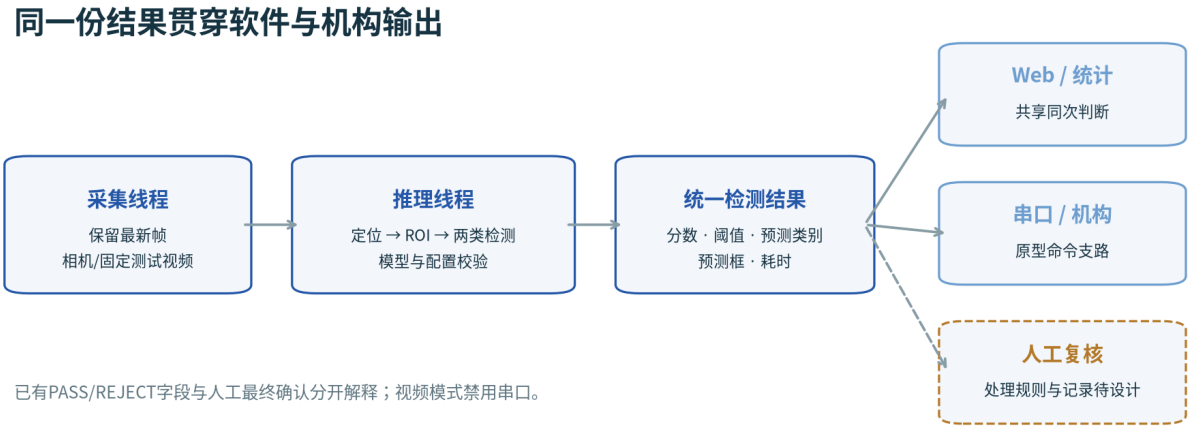


图 2 软件链路。同一次检测结果供页面、统计与串口共享；原型分拣支路已打通，人工复核规则及记录尚待设计。

串口向 STM32 发送“01”（未检出缺陷）或“02”（疑似缺陷）两种命令。任一检测子系统运行失败或输出非法分数时，系统停止输出检测结果，而不会退化为单个子系统继续判定。

4.3 边缘端耗时

本阶段尚未完成整机计时，但已在 Orin NX 上用数据集回放测量了部分推理环节（表1）。测试循环回放 40 帧非测试集齿轮图像，预热 15 s 后连续采样 60 s，每种配置约 115 个检测周期。当时运行的软件版本只包含齿轮定位和划痕检测子系统，尚未加入齿部缺损检测子系统。定位模型分别以 PyTorch（一种深度学习框架）权重和 TensorRT（英伟达公司的深度学习推理优化库）FP16（16 位半精度浮点）引擎两种格式运行；表中 p95 为第 95 百分位数，即 95% 的检测周期耗时不超过该值。

表 1 Orin NX 回放测试的分环节耗时（p95）

定位模型格式	齿轮定位	划痕检测子系统	单帧合计
PyTorch 权重	65.0 ms	181.2 ms	244.2 ms
TensorRT FP16 引擎	26.7 ms	196.5 ms	219.9 ms

两种配置下划痕检测子系统均以 PyTorch 运行。数据来自NX 回放耗时记录；不含齿部缺损检测子系统，也不是整机测试。

将定位模型转为 TensorRT FP16 引擎后，定位耗时的 p95 从 65.0 ms 降至 26.7 ms，单帧合计从 244.2 ms 降至 219.9 ms。划痕检测子系统的 p95 约为 181–197 ms，是当前最主要的耗时环节。加入齿部缺损子系统后，每个 ROI 还需增加三个模型的推理，整机节拍需要重新测量。

5 数据集

5.1 工件与图像采集

项目共有 50 个齿轮，均为自行采购或定制，其中正常 10 个、划痕 15 个、侧部缺损 15 个、齿角缺损 10 个。图像由流水线原型上的一台工业相机采集，原图分辨率为 2560×1440。拍摄时人工摆放和调整齿轮，获得上下表面、旋转和侧面等多个角度，以模拟部分观察条件；连续输送中的运动和姿态变化尚未覆盖。图3给出了正常外观和两类缺陷的示例。



图 3 自建数据中的正常外观、划痕与齿部缺损示例。红框为人工标注，局部放大用于观察，均不是模型预测。（来源：划痕数据清单；齿部缺损数据清单）

5.2 标注规则

标注以当前图像中的可见缺陷为依据。划痕容易与加工纹和高光混淆，齿部缺损的可见性受位置和观察角度影响，因此缺陷工件的某些视角可能看不到缺陷，这类图像作为该任务的负样本。齿部缺损另按 bottom、oblique、side 三种位置分组，用于分析观察角度对检出结果的影响。

5.3 数据划分

两类检测任务分别划分训练集和验证集，共用同一批 150 张测试图像（表2）。测试图像中 31 张含划痕、44 张含齿部缺损，其中 4 张同时含两类缺陷，因此至少含一类缺陷的图像为 71 张，无可见目标缺陷的图像为 79 张。测试集在模型、温度、融合系数和阈值全部固定之后才用于评价。

表 2 自建图像数据划分

检测任务	训练图像	验证图像	测试图像
划痕	364	150	150
齿部缺损	397	99	150

训练、验证数量来自划痕数据清单与齿部缺损数据清单；测试计数来自划痕测试记录与齿部缺损及联合测试记录。图像数量不等于不同工件数量。

当前图像只有顺序编号，没有记录对应的齿轮编号，因此无法确认同一齿轮的不同角度是否同时出现在训练、验证和测试集中。这一点限制了对新工件泛化能力的判断，详细说明见附录 C。

6 检测方法

6.1 总体流程

检测分为齿轮定位和缺陷判定两级（图4）。定位模型是单类别 YOLO26n 检测器（YOLO 即 You Only Look Once，一类单阶段目标检测算法；YOLO26 为 Ultralytics 公司发布的版本，n 表示最小的 nano 规模），在整帧图像中检出齿轮（置信度阈值 0.70），并按检测框裁剪感兴趣区域（region of interest，ROI）。同一 ROI 再分别送入划痕检测子系统和齿部缺损检测子系统，两者独立计算融合分数并与各自阈值比较，任一子系统达到阈值，该齿轮即被判为疑似缺陷。

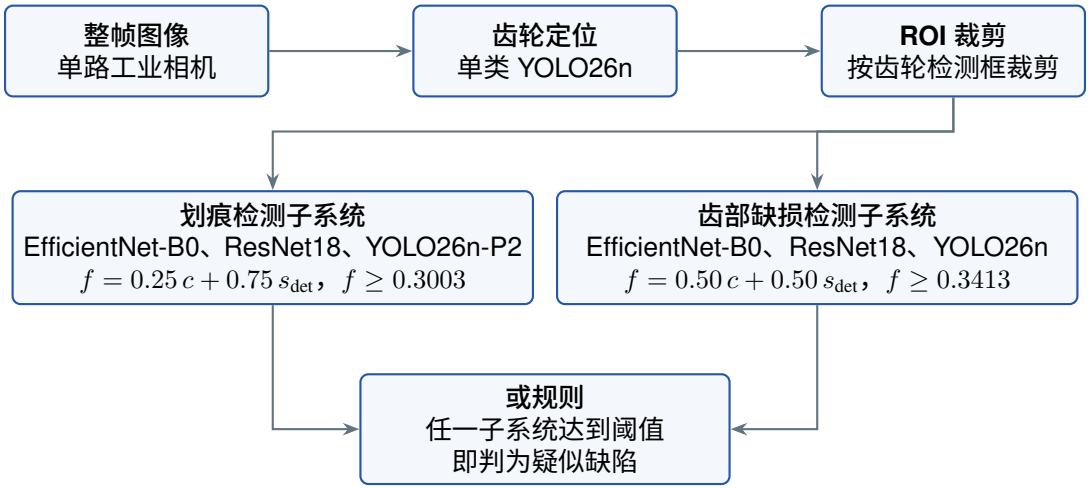


图 4 两级检测流程。c 为两个分类模型温度缩放后分数的平均，s_{det} 为检测模型最高预测框置信度经温度缩放后的分数；阈值为四舍五入后的展示值。

6.2 检测子系统

每个检测子系统由两个图像分类模型和一个目标检测模型组成。分类模型从整体纹理和结构判断 ROI 是否含缺陷，骨干网络采用 ResNet18（18 层残差网络，Residual Network）[10] 和 EfficientNet-B0（按复合缩放统一调整网络深度、宽度和输入分辨率的卷积网络，B0 为其基础规模）[11]；输入图像按原长宽比缩放并以灰色填充为正方形，再按 ImageNet（大规模自然图像数据集）的均值和方差归一化。目标检测模型提供局部缺陷线索，其最高预测框置信度作为图像级分数；预测框本身只在界面上辅助显示，不参与判定。

两个子系统的成员配置不同（表3）。划痕细小且对比度低，划痕子系统的检测模型采用带 P2 检测层的 YOLO26n。P2 指特征金字塔的第 2 层，相对输入图像下采样 4 倍，空间分辨率高于默认检测层，其思路来自特征金字塔网络（feature pyramid network，FPN）的多尺度特征 [12]，有利于保留细小缺陷的细节，但也可能让正常加工纹引起误报。齿部缺损子系统采用原始 YOLO26n，并将三种位置合并为单一类别训练。两项选择的实验依据见第7章。

表 3 检测子系统的成员模型、温度与判定参数

项目	划痕子系统	齿部缺损子系统
分类模型 1（输入）	EfficientNet-B0（384）	EfficientNet-B0（512）
分类模型 2（输入）	ResNet18（384）	ResNet18（384）
检测模型（输入）	YOLO26n-P2（960）	YOLO26n，单类（960）
温度 T（按上述顺序）	0.700 ／ 2.050 ／ 2.125	1.000 ／ 2.375 ／ 1.850
分类分数系数 α	0.25	0.50
判定阈值（约）	0.3003	0.3413

括号内为输入边长（像素）。运行配置保留完整阈值精度，见附录 F；来源为划痕发布配置与齿部缺损发布配置。

6.3 温度缩放与分数融合

三个成员模型的分数尺度不同，直接平均会让尺度较大的模型主导结果。融合前先对每个模型的分数 p 做温度缩放 [4]：

$$p_T = \mathrm{sigmoid}\left(\frac{\mathrm{logit}(p)}{T}\right), \qquad \mathrm{logit}(p) = \ln\frac{p}{1-p}, \tag{1}$$

其中温度 $T > 0$ 按验证集负对数似然（negative log-likelihood，NLL）最小选择。随后，两个分类分数取平均 $c = (s_{\mathrm{Eff}} + s_{\mathrm{Res}})/2$，再与检测分数加权：

$$f = \alpha\, c + (1-\alpha)\, s_{\mathrm{det}}. \tag{2}$$

划痕子系统取 $\alpha = 0.25$，即两个分类模型各占 0.125、检测模型占 0.75；齿部缺损子系统取 $\alpha = 0.50$，即两个分类模型各占 0.25、检测模型占 0.50。融合系数只描述分数计算中的比例，不表示各模型对检出的贡献，也不表示定位准确率。

两个子系统各自判定后，按或规则合并：

$$\mathrm{REJECT} = (f_{\mathrm{scratch}} \geq \tau_{\mathrm{scratch}}) \vee (f_{\mathrm{missing}} \geq \tau_{\mathrm{missing}}). \tag{3}$$

两类缺陷的负样本定义和温度估计所用数据不同，因此先分别判定，再合并二值结果。分类器组合规则 [16]、多检测模型融合 [17] 以及按缺陷类别分别建模后的或规则决策融合 [15] 均有已有研究；本项目沿用这些方法，工作重点在于针对齿轮数据确定成员、温度、系数和阈值。

6.4 训练与参数选择

分类模型从 ImageNet 预训练参数初始化，使用 AdamW 优化器（带解耦权重衰减的 Adam 自适应矩估计优化器）和 Focal BCE 损失（在二元交叉熵 binary cross-entropy 上加入焦点损失调制项，$\gamma = 1.5$）[13]；检测模型在 Ultralytics 公司的 YOLO 训练框架下以 960 像素输入训练。完整训练参数见附录 B。

参数选择按“训练候选、验证选择、测试评价”三步进行。项目先训练候选模型，再在验证集上依次选择成员模型、温度、融合系数和判定阈值，最后固定全部配置，在测试集上评价。阈值按经验 NP 准则选择：在验证集 $P_{FA} \leq 0.20$ 的条件下使 P_D 最大；齿部缺损还优先比较各位置组中的最低 P_D，以免某一位置的缺损被忽视。$P_D \geq 0.95$、$P_{FA} \leq 0.20$ 是项目早期设定的实验目标，用于约束选择，并非经过成本测算的生产验收标准。

反复使用同一验证集选择多个参数会带来选择偏差 [1][2]。因此，第7章的验证结果只作为选型依据，系统性能以第8章的测试结果为准。

7 选型实验

7.1 评价指标与经验 NP 准则

本报告以图像为评价单位，并采用检测理论中的检出概率和虚警概率作为主要指标。真阳性（true positive，TP）、假阴性（false negative，FN）分别为被正确检出和被漏检的缺陷图像，假阳性（false positive，FP）、真阴性（true negative，TN）分别为被误报和被正确排除的无缺陷图像。检出概率和虚警概率定义为

$$P_D = \frac{\mathrm{TP}}{\mathrm{TP}+\mathrm{FN}}, \qquad P_{FA} = \frac{\mathrm{FP}}{\mathrm{FP}+\mathrm{TN}}. \tag{4}$$

其中 P_D 衡量缺陷被检出的比例，P_{FA} 衡量无目标缺陷图像被误报的比例。精确率 $\mathrm{Precision} = \mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$ 用于估计疑似件中实际缺陷所占比例，但会随应用中的缺陷比例变化。

本项目把“在验证集 $P_{FA} \le 0.20$ 时使 P_D 最大”的阈值规则称为经验 NP 准则。奈曼–皮尔逊方法以一种错误概率为约束、优化另一种错误概率 [31]；本项目的做法与这一思想一致，但只约束有限验证样本上的经验 P_{FA}。Tong 等指出，经验误报比例满足上限，并不能保证总体虚警概率也受同一上限控制 [5]。因此，本文用“经验 NP 准则”说明历史选参方法，不声称获得了正式 NP 总体误差保证。

选型时还使用精确率–召回率曲线下面积（area under the precision–recall curve，AUPRC）衡量模型在不同阈值下的整体排序能力；在类别不平衡的数据上，它比受试者工作特征（receiver operating characteristic，ROC）曲线更能反映误报的影响 [3]。AUPRC 与固定阈值下的 P_D、P_{FA} 回答的是不同问题，下文分开报告。

7.2 早期统一模型的当前配置比较

早期两个版本尝试用一套模型同时处理两类缺陷。以下结果只比较当时的具体配置，用于说明后续分别建模路线的形成过程。

V3（第 3 版实验方案，V 表示版本，下同）用分类模型区分正常、划痕和齿部缺损，另训练检测模型定位缺陷。以齿部缺损为例（表4），图像分类检出 15/19 张，缺陷定位只找对 25/52 个标注区域。两者的评价单位不同，不能直接比较高低，但说明“判断图像有无缺陷”与“准确框出每处缺陷”是两项不同的任务，需要分别评价。后续方案据此只让检测模型的最高框分数参与图像判定，预测框仅作辅助显示。

表 4 V3 图像判断与区域定位的不同评价单位

评价任务	判断对象	正确检出／参考数量	P_D
图像分类	图像中是否有齿部缺损	15/19 张图像	78.95%
缺陷定位	预测框是否正确对应缺损区域	25/52 个标注区域	48.08%

来源：V3 测试与定位记录。V3 划痕的两套定位计数存在未核清的差异，正文不引用，见附录 D。

V4 把两类缺陷合并为“有无缺陷”的二分类，比较了不同模型、训练预算和模型组合（表5）。三模型最大值融合比基线多检出 2 张缺陷图像，同时多误报 1 张；扩展单模型的 AUPRC 最高，但在所选阈值下检出反而更少，说明排序能力与固定阈值下的表现需要分别评价。更关键的是，按缺陷类别拆开后，划痕在各方案中始终只检出 4/11，增加的检出全部来自齿部缺损（由 13/19 升至 15/19）。融合方案中每个成员各做四路测试时增强，每张图需要 12 次分类前向计算，是单模型的 3 倍。

表 5 V4 排序指标与所选工作点

方案	AUPRC	P_D	P_{FA}	每图分类前向次数
基线模型	0.767	56.67%（17/30）	30.00%（6/20）	4
扩展单模型	0.899	约 46.7%	约 5.0%	4
三模型融合	0.814	63.33%（19/30）	35.00%（7/20）	12

基线及融合计数核对原始 JSON（JavaScript Object Notation）记录；扩展单模型的留出指标来自既有详细报告的历史摘要。完整实验名、阈值和来源见附录 D。

当前统一模型配置未显示出划痕检出改善，这一结果促使项目为两类缺陷分别组织数据、选择检测结构和判定规则。V4 的留出集曾用于指导后续方向，因此以上结果只用于解释选型过程，不作为盲测证据，也不代表统一建模方法的一般结论。

7.3 划痕检测子系统选型

划痕实验比较了 6 个初步分类模型、2 个初步检测模型和 2 个增加训练轮数上限的分类模型。分类候选包括 ResNet18、EfficientNet-B0 和 YOLO 分类器，检测候选为原始 YOLO26n 与带 P2 检测层的 YOLO26n，各候选在验证集上按各自阈值比较（图5）。

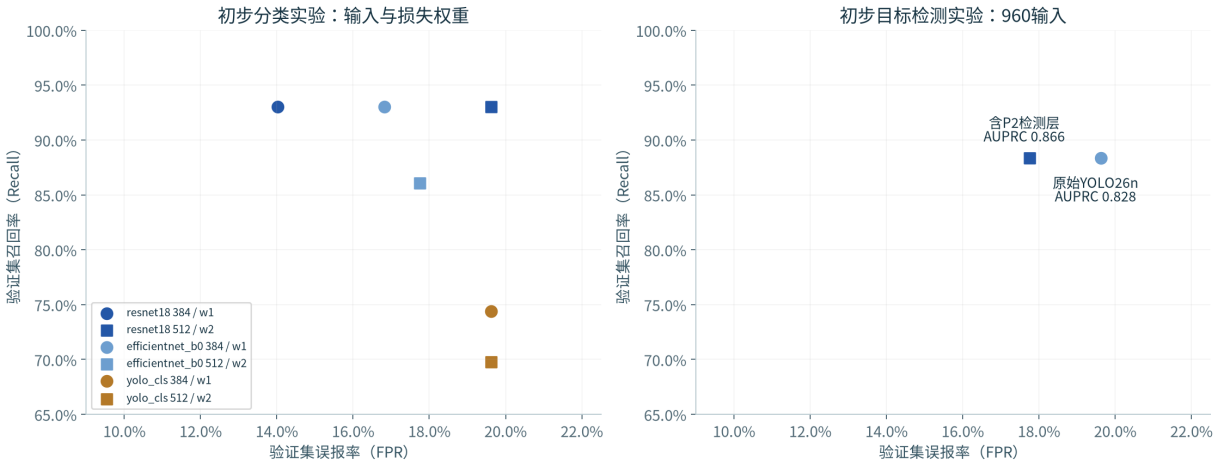


图 5 划痕候选在各自验证阈值下的 P_D 与 P_{FA}（$P_{FA} \leq 0.20$ 约束）。图中为候选配置比较，输入尺寸、权重和 batch（批大小，即每次参数更新使用的样本数）同时变化，不能解释为单因素效果。（来源：划痕候选模型评价表）

在检测结构上，两种检测模型都检出 38/43 张划痕图像，P2 版本误报 19/107，少于原始模型的 21/107，AUPRC 也更高（0.866 对 0.828），因此入选。两次实验的 batch 大小不同，这一差异不能完全归因于 P2 层。

在模型融合上（表6），最终三模型组合在验证集上检出 42/43、误报 9/107，比入选的 EfficientNet-B0 单模型多检出 1 张、少误报 4 张。P2 检测模型单独使用时误报最多，与分类模型组合后误报反而最少，提示整体纹理和局部线索在验证集上存在一定互补。这种互补是否稳定，仍需同图错误分析和控制条件的消融实验确认。

表 6 划痕单模型与融合验证对照

划痕验证方案	成员数	正确检出／43 张可见划痕图	误报／107 张无可见划痕图
入选 EfficientNet 单模型	1	41	13
P2 检测模型	1	38	19
最终加权融合	3	42	9

各方案在同一验证集上按经验 NP 准则选择各自阈值，不是固定阈值的组件消融。来源：划痕候选模型评价表；划痕发布配置。

7.4 齿部缺损检测子系统选型

齿部缺损在不同位置的外观差异较大。细分位置标签可能帮助模型区分，也可能分散有限的样本。初步检测实验用 12 组既有配置比较三类、两类和单类标注方案、训练数据筛选方式以及原始／P2 结构，统一使用 960 输入和 35 轮训练上限（图6）。

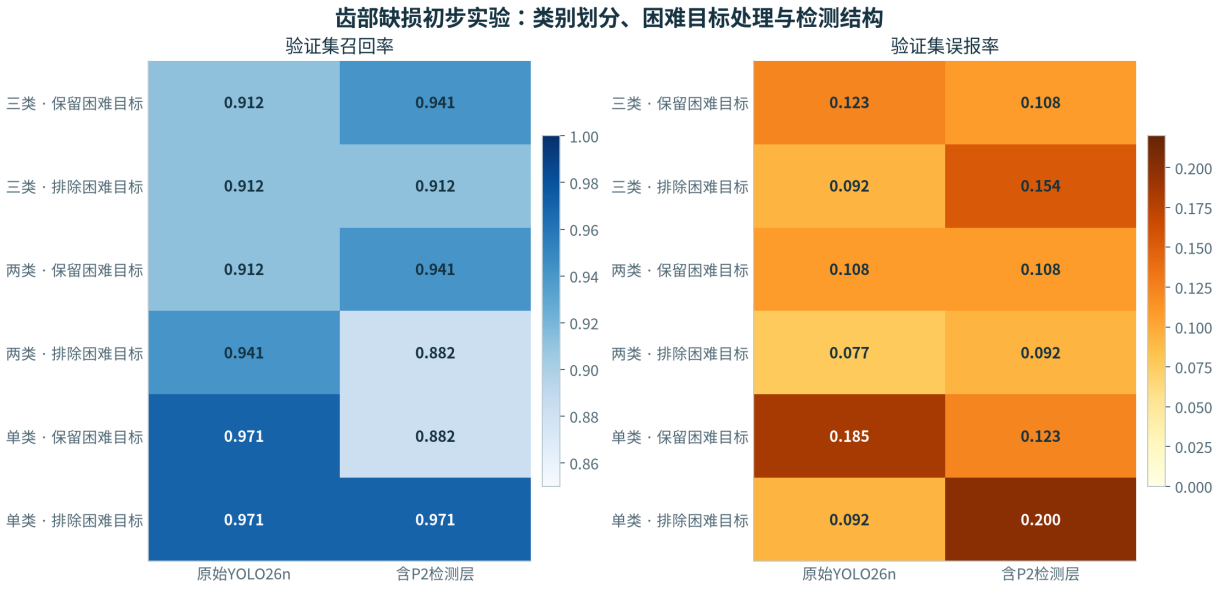


图 6 12 组检测配置在验证集上的 P_D 与 P_{FA}。每组采用自身验证阈值，batch 等条件未完全一致，该矩阵用于配置选择，不是严格隔离各因素的消融。（来源：齿部缺损候选模型评价表）

入选数据配置下，两种结构都检出 33/34 张缺损图像，原始 YOLO26n 误报 6/65，P2 版本误报 13/65。与划痕不同，P2 层在齿部缺损上带来了更多误报，细分位置标签也没有改善判定，因此最终采用单类标注的原始 YOLO26n。该结论来自成组配置比较，不能单独归因于某一个训练设置。

在模型融合上（表7），各候选的检出都接近满分，差别主要在误报：EfficientNet-B0 单模型误报 6/65，加权融合降至 4/65。EfficientNet-B0 与检测模型的两模型融合和最终三模型融合计数相同，后者因 AUPRC 略高（约 0.9660 对 0.9634）入选，这不能证明三个成员都必要。

表 7 齿部缺损单模型与融合验证对照

齿部缺损验证方案	成员数	正确检出／34 张可见缺损图	误报／65 张无可见缺损图
入选 EfficientNet 单模型	1	34	6
原始 YOLO 检测模型	1	33	6
两个分类模型分数均值	2	34	5
EfficientNet 与检测分数加权融合	2	34	4
最终加权融合	3	34	4

各方案在同一验证集上按经验 NP 准则选择各自阈值。完整配置见附录 F，来源为融合候选评价表。

7.5 融合权重与阈值依据

现用融合权重来自有限候选的验证比较，不是人工随意指定，也不是理论推导出的固定比例。历史流程先对成员分数做温度缩放，再比较单模型、均值、最大值和 $\alpha \in \{0.25, 0.50, 0.75\}$ 的加权方案，最后按经验 NP 准则及 AUPRC 等次级指标选出发布配置。划痕子系统取 $\alpha = 0.25$，即分类分数均值占 0.25、检测分数占 0.75；该配置在验证集检出 42/43 张划痕图像、误报 9/107 张无划痕图像。现有归档只保存了划痕最终融合的验证分数，没有保存三个成员在该验证集上的逐图分数，因此本轮不能重放连续权重搜索，也不能把 0.25 证明为全局最优。

划痕测试集的成员分数可用于检查当前结论是否对权重大幅敏感，但不能用于重新选参。图7右图显示，在每个 α 上重新按 $P_{FA} \le 0.20$ 取经验 NP 工作点时，$\alpha \le 0.30$ 一侧的 P_D 约为 0.81–0.90，而只使用分类分数的 $\alpha = 1$ 时降至约 0.45。现用 0.25 位于表现较好的一侧，这只是测试集敏感性诊断，不构成新的参数选择证据；正式搜索仍需取得三个划痕成员在验证集上的逐图分数。

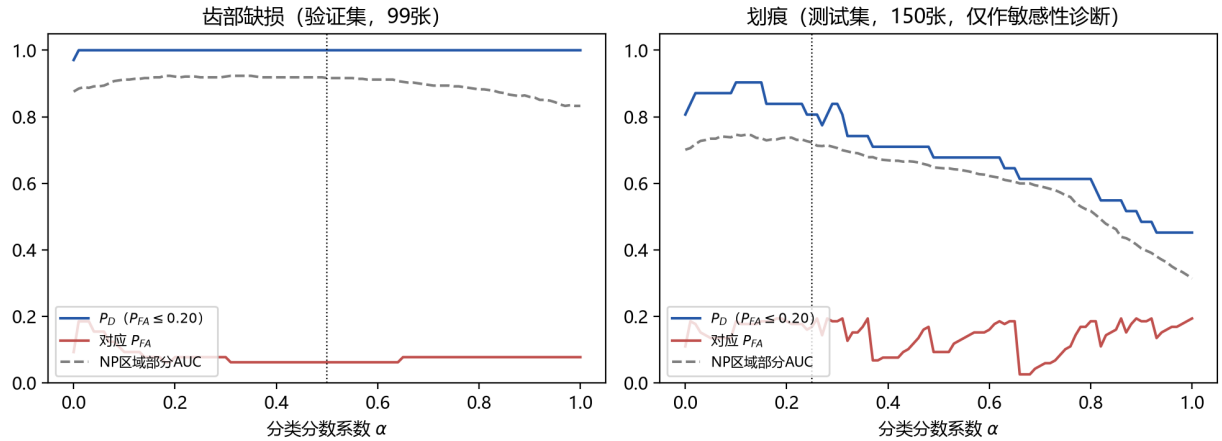


图 7 融合系数敏感性。左图使用齿部缺损验证集，可用于分析发布参数；右图使用划痕测试集，只作敏感性诊断，不能据此重选权重。竖虚线为现用 α。（来源：融合权重与阈值重分析）

齿部缺损子系统的验证分数完整，因而可以重放和扩展权重分析。分类分数系数 α 从 0.18 到 0.64 时，经验 NP 工作点均为 34/34 检出、4/65 虚警，现用 $\alpha = 0.50$ 位于这一平台中部，说明工作点对该系数不敏感。进一步用树结构 Parzen 估计器（tree-structured Parzen estimator，TPE）进行 300 次贝叶斯优化，以 $P_{FA} \in [0, 0.20]$ 内归一化的 ROC 部分曲线下面积（partial area under the curve，pAUC）为目标，得到 EfficientNet、ResNet 和 YOLO 权重 0.0486/0.2002/0.7513；最优值在第 98 次试验出现（图8）。该权重的 pAUC 为 0.9299，高于发布配置的 0.9163，但经验 NP 工作点仍是 34/34 检出、4/65 虚警。贝叶斯优化可用于集成权重搜索 [32]，但本结果只有 99 张验证图像且重复利用同一验证集，存在过拟合风险，因此不据此修改发布配置。

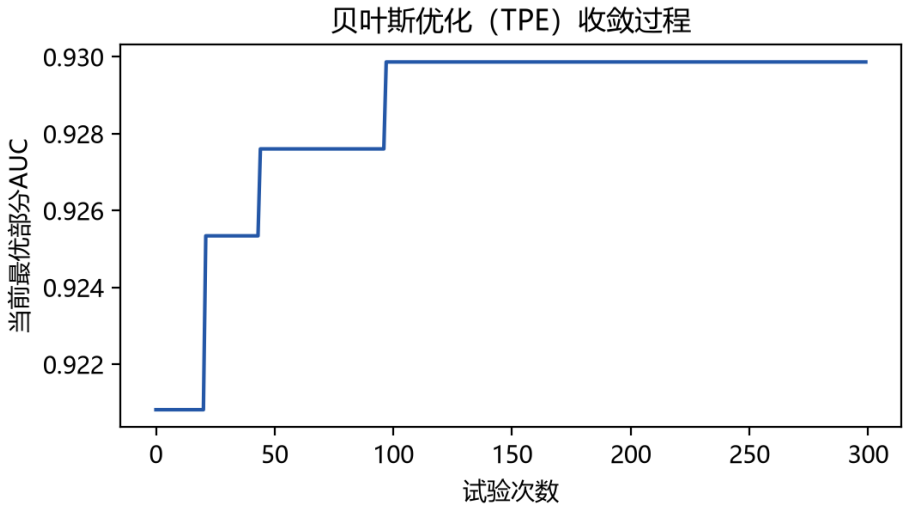


图 8 齿部缺损三成员权重的 TPE 贝叶斯优化收敛过程。纵轴为当前最优的 NP 区域 pAUC；搜索只使用已有验证分数，没有重新训练或运行模型。（来源：融合权重与阈值重分析）

阈值 0.3003 和 0.3413 都来自固定融合分数上的验证扫描，而不是把 0.5 当作概率分界。划痕完整阈值 0.300273610279458 在 $P_{FA} \leq 0.20$ 时给出 42/43 检出、9/107 虚警；它正好等于一张被检出划痕图像的分数，且只比阈值下方最近的正常图像分数 0.2998578839875169 高约 0.0004。齿部缺损完整阈值 0.3413327979078584 正好等于验证集中分数最低的缺陷图像；若直接改用 0.5，P_D 会从 34/34 降至 29/34，P_{FA} 从 4/65 降至 3/65。两个阈值都落在验证样本上，没有预留分数余量；验证分布稍有变化就可能改变边界样本的判定。

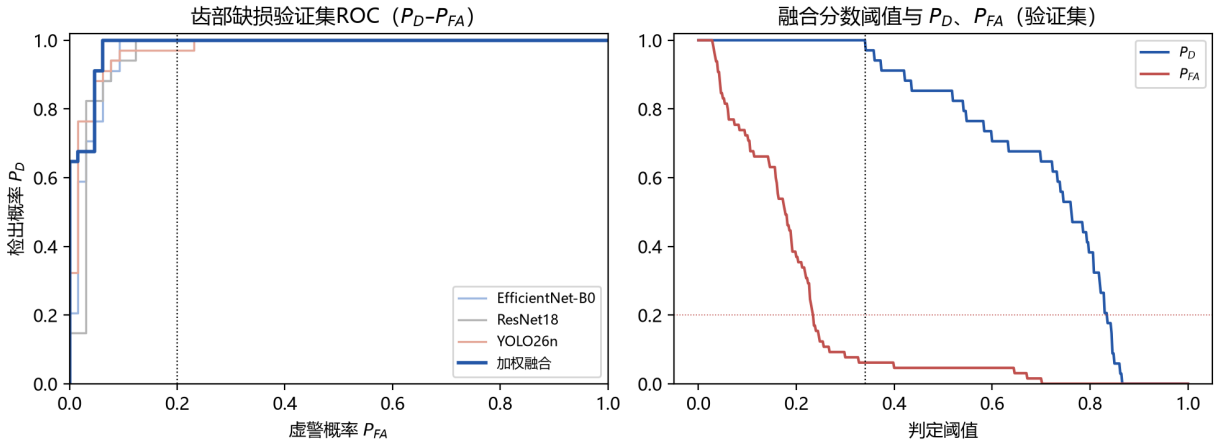


图 9 齿部缺损验证集的 ROC 与阈值曲线。左图比较三个成员和发布融合，右图给出融合阈值变化时的 P_D、P_{FA}；竖虚线为发布阈值 0.3413。（来源：融合权重与阈值重分析）

阈值低于 0.5 并不表示规则异常。温度缩放后的成员分数只被放到较可比的尺度，融合分数没有经过“融合后校准”，不能解释为真实缺陷的后验概率，所以 0.5 不是天然阈值。当前参数回答的是“在这批验证图像和经验 P_{FA} 约束下怎样取工作点”，不能回答总体虚警保证，也不能替代真实产线上的成本和复核能力测量。

8 测试结果与分析

8.1 固定配置的测试结果

在 150 张测试图像上，划痕子系统 $P_D = 80.65\%$、$P_{FA} = 16.81\%$，齿部缺损子系统 $P_D = 81.82\%$、$P_{FA} = 3.77\%$（表8）。两者按或规则合并后，系统检出 63/71 张缺陷图像，误报 18/79 张，$P_D = 88.73\%$、精确率 77.78%、$P_{FA} = 22.78\%$。前两行按各自缺陷评价，其负样本中可能含另一类缺陷；后两行按“任意缺陷”评价，因此只有后两行可以直接比较。

表 8 固定配置的图像级测试结果

检测方案	TP/FP/TN/FN	P_D	精确率	P_{FA}
划痕检测	25/20/99/6	80.65%	55.56%	16.81%
齿部缺损检测	36/4/102/8	81.82%	90.00%	3.77%
两类结果合并	63/18/61/8	88.73%	77.78%	22.78%
当前统一缺陷分类配置	54/33/46/17	76.06%	62.07%	41.77%

来源：划痕测试记录；齿部缺损及联合测试记录。18/79 是图像误报计数，不是 18 个合格工件被误判。

为检验分别建模是否值得增加模型数量，项目还用当前统一缺陷分类配置在同一批测试图像上判断有无任意缺陷。该配置检出 54/71、误报 33/79；当前合并系统多检出 9 张、少误报 15 张（图10），代价是模型文件由约 15.6 MB 增至约 130 MB。两套方案的训练数据构造、模型数量和训练预算都不同，这一比较只说明当前两套配置的差距，不能单独证明分别建模带来了全部收益。

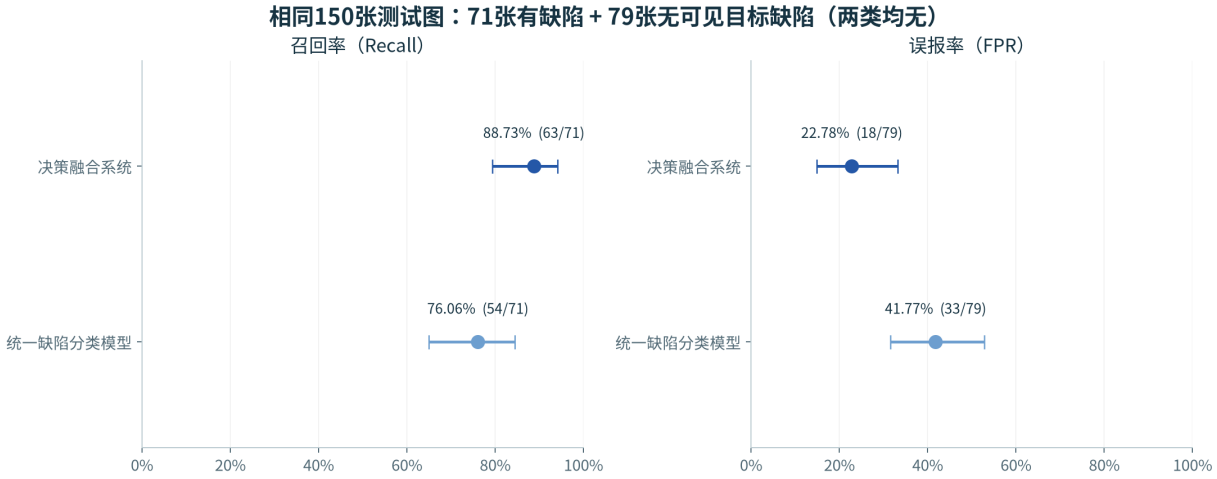


图 10 同一批 150 张图像、相同“任意缺陷”标签下的系统比较。误差线为按图像计数的 Wilson 得分 95% 置信区间；同一工件的图像之间可能相关，区间仅作描述性参考。（来源：齿部缺损及联合测试记录）

8.2 验证与测试的差距

两个子系统的测试 P_D 都明显低于验证结果：划痕从验证集的 42/43 降至测试集的 25/31，齿部缺损从 34/34 降至 36/44。按图像计数的 Wilson 95% 区间，两者的测试 P_D 分别约为 63.7%–90.8% 和 68.0%–90.5%。验证集参与了模型、温度、系数和阈值的多轮选择，存在选择偏差；测试图像的拍摄条件和样本构成也可能与验证集不同。现有数据无法区分这些因素各自的影响，逐项对照见附录 F。

8.3 错误案例与阈值取舍

已记录的错误主要涉及浅划痕和斜向位置的齿部缺损。图11中的两张划痕漏检都是对比度很低的浅划痕，误报则出现在正常加工纹区域；历史误差分析也提示加工纹和高光是需要重点检查的误报来源。齿部缺损的 8 张漏检中有 7 张带 oblique 位置标签，该位置组 P_D 仅为 10/17，而 bottom 和 side 分别为 11/12 和 20/20。斜向位置缺损的可见性是当前最突出的短板，改进需要从相机角度和照明入手。



图 11 两个划痕漏检和一个划痕误报案例。红框来自人工标注，模型分数来自固定配置的已有预测记录；“无划痕”不意味着无齿部缺损。（来源：划痕逐图预测与标注）

降低阈值可以补回部分漏检，但虚警会大幅增加。以划痕子系统为例，阈值降至约 0.2038 时，测试 P_D 约为 93.5%，P_{FA} 却升至约 58.8%。该数据只用于说明取舍，不用于在测试集上重新选择阈值。

8.4 真实缺陷率模拟

测试集的缺陷比例不能直接代表现场复核负担。当前测试集中至少含一类缺陷的图像占 71/150，远高于正常件占多数的产线情形；当 P_D、P_{FA} 固定时，精确率会随缺陷比例 π 变化：

$$\mathrm{Precision}(\pi) = \frac{\pi P_D}{\pi P_D + (1-\pi) P_{FA}}. \tag{5}$$

按照固定测试结果推算，两类合并系统在缺陷率 1% 时精确率约 3.78%，每千张图像约产生 225.6 次虚警、漏检 1.13 张缺陷图像；缺陷率 5% 时精确率约 17.01%，每千张约 216.5 次虚警、漏检 5.63 张。图12和表9给出了 0.5%–10% 范围内的结果。类别比例变化会显著改变精确率及模型比较结论 [33]，因此 77.78% 的测试精确率不能外推为生产复核确认率。

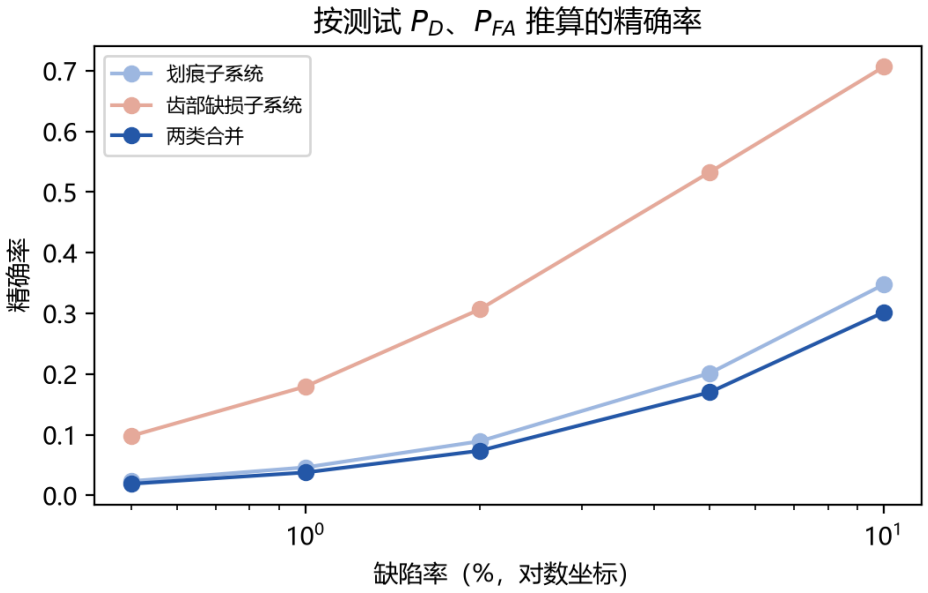


图 12　按固定测试 P_D、P_{FA} 推算的精确率。横轴为假设的可见缺陷图像比例，不是已测得的产线缺陷率；曲线只反映类别比例变化，不包含分布漂移。（来源：融合权重与阈值重分析）

表 9　两类合并系统在不同缺陷率下的模拟结果

缺陷率	精确率	每千张虚警数	每千张漏检数
0.5%	1.92%	226.7	0.56
1%	3.78%	225.6	1.13
2%	7.36%	223.3	2.25
5%	17.01%	216.5	5.63
10%	30.20%	205.1	11.27

由固定测试结果 $P_D = 63/71$、$P_{FA} = 18/79$ 代入公式计算；不是新增测试，也不表示已测得产线缺陷率。

8.5　局限性

本阶段结论受数据、实验设计和系统三方面条件的限制。

在数据方面，工件只有 50 个，图像缺少工件编号，无法确认同一齿轮的不同视角是否跨越训练、验证与测试集，测试结果尚不能代表对新齿轮的泛化能力。全部数据由单台相机在人工摆放下采集，没有覆盖连续输送时的运动和姿态变化。

在实验设计方面，多数候选对照同时改变了输入尺寸、权重或 batch 等多个因素，属于配置比较而非严格消融。融合成员的必要性与互补性、温度缩放的校准效果，以及 Focal 损失 $\gamma = 1.5$ 等预设参数，都没有经过独立验证。检测模型的预测框定位精度较低，界面上的框只能作为参考。

在系统方面，双相机取或的工件级判定尚未实现；系统按传送带一次通过一个齿轮的场景设计，但跨帧工件追踪尚未实现。Orin NX 上只测量了定位和划痕子系统的回放耗时，整机节拍、长时运行和分拣准确性均未测量。

9 结论与下一步工作

9.1 结论

本阶段完成了齿轮外观缺陷检测从数据、模型到原型集成的第一轮工作。早期统一模型的当前配置未显示出划痕检出改善，项目据此为划痕和齿部缺损分别构建“两个分类模型加一个检测模型”的检测子系统，并在验证集上确定了检测结构、温度、融合系数和阈值：划痕子系统采用带 P2 层的检测模型，齿部缺损子系统采用单类标注的原始检测模型。在 150 张固定测试图像上，合并系统 $P_D = 88.73\%$、$P_{FA} = 22.78\%$，比当前统一缺陷分类配置多检出 9 张、少误报 15 张。该比较只代表当前两套配置。检测流程已集成到 Jetson Orin NX 上的软件中，与 Web 监控、统计和串口分拣连通。

现有结果支持在当前数据上采用分别建模的方案，并将系统用于疑似件筛选和辅助复核。权重分析表明齿部缺损发布参数位于较宽的稳定平台，但划痕验证成员分数不完整，0.25/0.75 仍只能追溯到有限候选选择；两个阈值都落在验证样本分数上，没有余量。测试 P_D 仍明显低于验证结果，真实低缺陷率下的模拟虚警负担也较高，对新工件的泛化能力和现场效果尚待验证。

9.2 下一阶段工作

下一阶段优先解决数据来源、成像条件和整机测量问题（表10），在此基础上再决定是否需要对专项模型做 TensorRT 加速或更大范围的参数搜索。

表 10 下一阶段验证优先级

优先问题	验证方式
对新工件是否有效	建立齿轮编号，按工件和拍摄批次划分数据，用未参与训练的新齿轮测试
困难缺陷能否拍清	固定工件与相机，比较光照和观察角度，记录斜向缺损和浅划痕的可见性变化
双相机能否减少漏检	实现上下两路各自检测后取或的工件级判定，比较单路与双路的 P_D 和 P_{FA}
模型组合是否必要	控制其他条件比较输入、权重、成员模型与校准，记录共同错误和资源开销
NX 能否满足节拍	加入齿部缺损子系统后测量整机分项耗时，记录采集、判定与分拣的对应关系和长时运行情况
人工复核如何覆盖漏检	确定模型未检出工件的抽查方式，测量确认比例和复核时间

详细的验证设计与原型状态见附录 G。

附录 A 术语及方法名称

本报告采用中文名称，并在首次出现时给出英文或代码名。独立训练的网络称“成员模型”，两个面向同类缺陷的分类模型与一个目标检测模型构成“检测子系统”。方法名称按实际操作确定；有关名词的更完整说明见术语对照表。

表 11 术语与实际方法定义

中文名称	英文或代码名	本项目中的定义
齿部缺损	partial tooth damage；历史代码 missing_hole	齿侧或齿角等部位的局部缺失；不译为孔洞缺失
划痕检测子系统	Scratch V5	两个分类模型与一个目标检测模型的组合
齿部缺损检测子系统	Missing Hole V1	两个分类模型与一个目标检测模型的组合
分数级加权融合	score-level weighted fusion	对同类缺陷的模型分数进行加权平均
决策级融合	decision-level fusion	对两个子系统的二值判定进行合并
或规则	OR rule	任一子系统判为有缺陷，最终即判为有缺陷
温度缩放	temperature scaling	用正温度参数调整模型输出分数，参数根据验证集 NLL 选择
参考标注	ground truth annotations	人工标注的类别与边界框
正样本/负样本	positive/negative samples	含/不含当前任务可见目标缺陷的图像
精确率	precision	TP/(TP+FP)，与准确率 accuracy 不同
检出概率	probability of detection，P_D	TP/(TP+FN)，表示缺陷图像被检出的比例
虚警概率	probability of false alarm，P_{FA}	FP/(FP+TN)，表示无目标缺陷图像被误报的比例
预测为缺陷的样本比例	predicted-positive fraction	(TP+FP)/N；图像统计不能直接换算为工件送复核比例
目标级定位评价	object-level localization evaluation	基于预测框与标注框的匹配计算定位指标
初步实验	pilot experiment	以较低训练轮数上限比较候选配置
增加训练轮数上限的重新训练	retraining with a larger epoch limit	从预训练初始化重新训练，区别于从初步实验保存的 checkpoint（模型权重快照）接续训练
对照实验	comparative experiment	比较候选配置；多项因素同时变化时不解释为单因素效应
消融实验	ablation study	在控制其他条件下移除或改变某个组件，检验其作用；按实际设计使用

下表汇总本报告出现的英文缩写，正文和附录在各自首次出现处也给出了全称。

表 12 缩略语对照

缩写	英文全称	中文含义
AdamW	Adam with decoupled weight decay	带解耦权重衰减的自适应矩估计优化器
AUPRC	area under the precision–recall curve	精确率–召回率曲线下面积
AUROC	area under the ROC curve	ROC 曲线下面积
BCE	binary cross-entropy	二元交叉熵损失
CLAHE	contrast limited adaptive histogram equalization	限制对比度的自适应直方图均衡化
CSV	comma-separated values	逗号分隔值文件格式
FN ／ FP	false negative ／ false positive	假阴性（漏检）／假阳性（误报）

续下页

缩写	英文全称	中文含义
FP16	16-bit floating point	16 位半精度浮点
FPN	feature pyramid network	特征金字塔网络
FPS	frames per second	每秒处理帧数
ID	identifier	编号
IoU	intersection over union	交并比，预测框与标注框的重叠面积除以合并面积
JSON	JavaScript Object Notation	一种结构化文本数据格式
mAP	mean average precision	平均精度均值，目标检测常用指标
NLL	negative log-likelihood	负对数似然
NMS	non-maximum suppression	非极大值抑制，去除重叠的重复预测框
NP	Neyman–Pearson	奈曼–皮尔逊准则，在 P_{FA} 约束下使 P_D 最大
NX	NVIDIA Jetson Orin NX	英伟达公司的嵌入式人工智能计算模块
P2	pyramid level 2	特征金字塔第 2 层（相对输入下采样 4 倍）上的检测层
PR	precision–recall	精确率–召回率
ResNet	residual network	残差网络
RGB	red, green, blue	红绿蓝三通道彩色图像
ROC	receiver operating characteristic	受试者工作特征
ROI	region of interest	感兴趣区域
STM32	STMicroelectronics 32-bit microcontroller	意法半导体公司的 32 位微控制器系列
TN ／ TP	true negative ／ true positive	真阴性／真阳性
TTA	test-time augmentation	测试时增强
XML	Extensible Markup Language	可扩展标记语言，此处为标注文件格式
YOLO	You Only Look Once	一类单阶段目标检测算法

附录 B 关键固定训练参数与资料索引

表 13 固定训练参数摘要

参数组	Scratch V5	Missing Hole V1	来源性质
自定义分类初始化/输入	ImageNet；长宽比保留、灰色填充	同左；输入 384 或 512	外部初始化及工程输入设计
归一化	ImageNet mean/std	同左	预训练输入约定
自定义优化器	AdamW，学习率 lr=3e−4，权重衰减 weight_decay=5e−4	同左	脚本预先固定的参数
学习率调度	余弦退火，最小学习率 eta_min=1e−6	同左	脚本预先固定的参数
Focal 损失设置	γ=1.5，最终正类权重 w_pos=1	γ=1.5，w_pos=2	前者候选组合，后者固定
自定义 batch	384→24；512→12	同左	计算预算约束
检测输入	960	960；1280 候选未入选	实验变量
检测优化器	AdamW，初始学习率 lr0=7e−4，weight_decay=5e−4	同左	预先固定的参数

续下页

参数组	Scratch V5	Missing Hole V1	来源性质
最终 TTA	无	无	验证选择

表 按《GearPro 综合实验与部署技术报告》第 8.3、9.4 节摘要；各实验的有效配置应结合对应的训练参数文件（args）与训练历史记录（history）读取。检测结构、batch、增强与训练预算有版本差异，完整逐次表保留在综合报告。

项目事实说明。本报告中由项目组确认的内容包括：50 个齿轮工件构成；使用流水线原型上的一台工业相机人工摆拍多角度图像；按图像可见缺陷标注，当前视角确认不可见时作为该任务负样本；仅有图片顺序编号；明确缺陷均不合格；整机安装上下两台工业相机，设计为两路各自判定后取或，当前测试使用单路；计算平台为 Jetson Orin NX；新模型只做过简单现场测试，未记录数据；人工复核方向明确而流程未定；历史目标无正式需求依据。

综合项目资料。GearPro 综合实验与部署技术报告，2026-10-03；其中第 17 节列明原始实验及阶段汇报来源。Git 的 main 分支中的阶段 PDF 作为历史状态补充，当前状态以项目组确认的信息更新。

表 14 实验资料与配置来源目录

资料名称	可核对文件	本文用途
划痕发布配置	V5 发布配置	成员、温度、融合、阈值、验证计数
齿部缺损发布配置	V1 发布配置	同上
划痕测试记录	V5 测试记录	测试计数、相似对提示
齿部缺损及联合测试记录	V1 及联合测试记录	检测任务、位置、OR 与当前统一分类配置
划痕数据清单	V5 数据清单	训练/验证拆分及缺少工件编号（ID）的状态
齿部缺损数据清单	V1 数据清单	各拆分、图像/标签及样例索引
划痕候选模型评价表	V5 候选模型评价表	划痕候选结果
齿部缺损候选模型评价表	V1 候选模型评价表	检测全因子及后续候选
齿部缺损融合候选评价表	V1 融合候选模型评价表	21 个融合候选及最终选择
划痕逐图预测与标注	V5 逐图预测及原图/XML（可扩展标记语言）标注	仅用于已记录错误的展示与解释
V3 测试与定位记录	V3 测试与定位记录	图像与区域两种评价、划痕计数差异
V4 初始基线记录	V4 初始基线记录	基线计数、指标与类别分组
V4 最终融合记录	V4 最终融合记录	融合计数、指标与类别分组
V4 发布配置	V4 发布配置	成员、增强及融合方式
V4 候选评价记录	V4 候选评价记录	扩展单模型验证阈值与增强方式

续下页

资料名称	可核对文件	本文用途
V4 详细技术报告	V4 详细技术报告	扩展单模型既有留出摘要及四路增强说明
NX 回放耗时记录	GearPro 仓库 srtp 分支`docs/edgemedic-experiments.md`，提交`2c79075` 受控窗口	定位与划痕子系统的回放耗时
融合权重与阈值重分析	分析汇总与曲线	权重扫描、TPE 贝叶斯优化、阈值边界和缺陷率模拟

原有位图图表由`build_report.py` 读取上述记录生成，数值与来源汇总在`assets/chart_data.csv`，输入文件哈希和构建检查保存在`verification.json`。新增权重与阈值曲线由融合权重与阈值重分析读取已保存分数生成。脚本只读取已有实验产物，不运行模型、不修改阈值。第 4.1 节的整机组成图和第 6.1 节的检测流程图改用 TikZ 绘制，直接写在 LaTeX 源文件中。

附录 C 数据检查细节

正文的数据规模见第 3 章；以下保留构成、标注和拆分的详细说明。

C.1 工件构成与位置标签

项目共有 50 个齿轮工件：正常 10 个，划痕 15 个，侧部缺损 15 个，齿角缺损 10 个。工件由项目自行采购或定制，由一台工业相机从上下、旋转、侧面等多个角度拍摄。

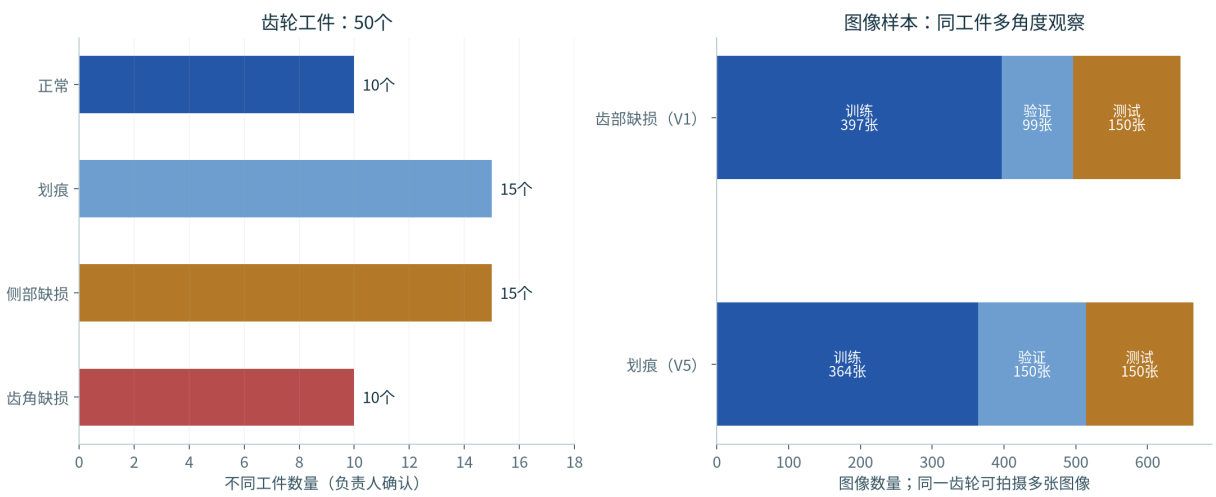


图 13 左侧为项目组确认的齿轮工件构成，右侧为两类缺陷的数据清单中的图像数量。多角度拍摄增加观察条件，不增加不同齿轮工件数量；图像尚未可靠对应到具体工件 ID。（来源：项目事实说明；划痕数据清单；齿部缺损数据清单）

需要区分三个概念：工件的缺陷类型、采集时的观察角度、XML 中的位置标签。采购时的“侧部缺损/齿角缺损”不能直接等同于 V1 的 bottom/oblique/side 标注，也不同于其他版本按宽高比推断的视角。本文保持原始定义，不自行建立未经核对的映射。

C.2 数据规模与类别定义

表 15 数据规模及各任务正负样本定义

检测任务	训练图	验证图	测试图	正负样本定义
Scratch V5	364	150	150	有可见划痕 / 无可见划痕
Missing Hole V1	397	99	150	有可见齿部缺损 / 无可见齿部缺损

表 训练、验证数量来自清单（来源：划痕数据清单；齿部缺损数据清单），测试计数来自（来源：划痕测试记录；齿部缺损及联合测试记录）。两个检测子系统使用同一批 150 张测试图，但负样本定义不同。

150 张测试图中，划痕 31 张、齿部缺损 44 张、二者同时存在 4 张，因此含至少一类缺陷的图像为 71 张，无可见划痕或齿部缺损的图像为 79 张。无划痕图可能具有齿部缺损，无齿部缺损图可能具有划痕；两个检测子系统 P_{FA} 的分母不能直接用于联合 P_{FA}。

缺少某类标注不能自动解释为不含该类缺陷。当前统一分类配置的数据构建曾排除 59 张划痕状态未知且无齿部缺损的候选图像，保留类别状态已确定的数据。（来源：《GearPro 综合实验与部署技术报告》第 10.1.2 节）

C.3 工件划分限制

当前只有图片顺序编号，清单没有可靠的图像与 50 个齿轮工件的对应关系，无法确认同一齿轮的不同角度是否跨训练、验证和测试。（来源：项目事实说明；划痕数据清单；齿部缺损数据清单）

项目组认为独特缺陷形态可用于辨识部分工件；正常工件及缺陷不可见的照片无法可靠辨识。本轮没有恢复或改写工件对应关系，完整工件独立性仍未知；只检查可辨识照片，未发现交叉也不能证明全体独立。

结合工件编号缺失，当前测试结果只反映所评价图像上的表现。报告保留“固定模型、温度、融合权重及阈值后评价”的流程记录，按工件划分数据的独立性仍待确认。

这一区分直接影响结论力度：测试图上的检出能力，尚不能自动转为新采购齿轮、不同批次或新生产线的泛化能力。后续采集应为每个齿轮工件建立 ID，其所有角度、照明和连续帧进入同一数据组。

C.4 训练、验证与测试职责

训练集用于更新网络参数；验证数据用于选候选、温度、融合及阈值；测试记录用于配置固定后的结果评价。测试一旦查看，后续调整需要新的开发数据和新的未查看测试，而现有集合可保留为历史回归集。[1][2]

本报告在现有证据上解释结果，不重新训练或调整运行阈值。多个阶段的数据和标签不同，跨版本仅讨论设计认识，不将各版指标连成同一条性能提升曲线。

附录 D 早期方案详细记录

正文第 5.2 节概述了 V3/V4 的结论；以下保留转向依据、未解释差异及 V4 配置来源。

D.1 转向依据

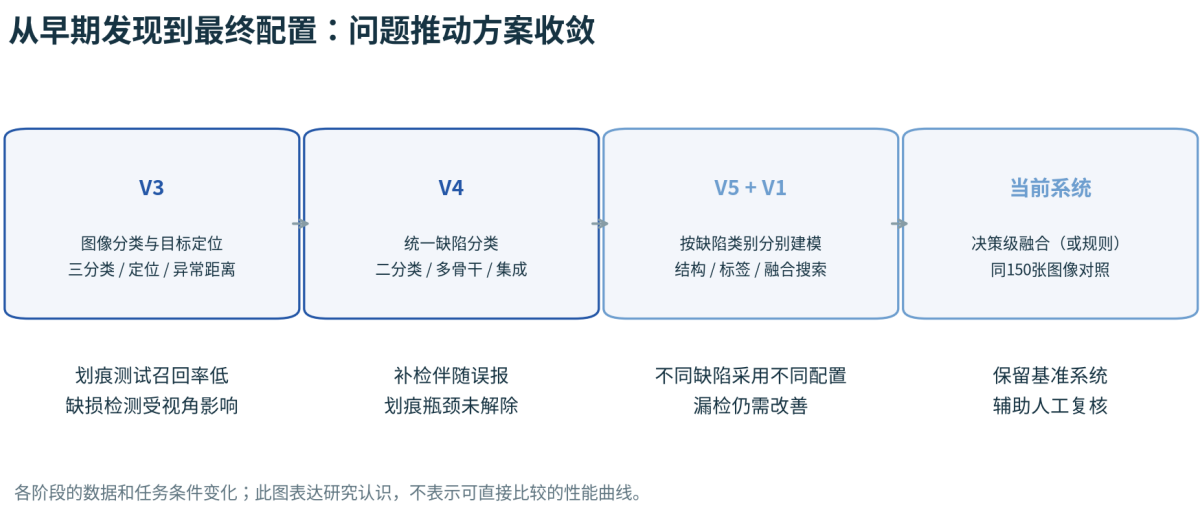


图 14 V3/V4 提供研究转向依据，V5/V1 承担重点技术探索。该图表示问题和设计演进，非同一数据上的性能趋势。（来源：《GearPro 综合实验与部署技术报告》第 3、6–10 节）

V3 用分类模型区分正常、划痕与齿部缺损，并用独立模型定位缺陷，并尝试增强、P2 和正常特征距离。它揭示低对比划痕与不同视角下的齿部缺损的困难，也建立了判定与定位分别评价的框架。V4 将两类合并为“至少一类缺陷”，探索多模型、纹理和集成。（来源：《GearPro 综合实验与部署技术报告》第 6–7 节）

V4 最终留出测试集的结果为正确检出 19/30 张缺陷图像、误报 7/20 张无可见目标缺陷图像；11 个漏检中 7 个来自划痕。模型组合补检了部分缺陷，也增加了误报，划痕漏检仍是主要问题。后续因而针对划痕与齿部缺损分别组织数据、检测结构及判定规则。V4 曾用第一次留出结果判断扩展方向，本文明确说明该留出测试集曾用于指导后续实验，不能视为始终未查看的最终测试集。（来源：《GearPro 综合实验与部署技术报告》第 7.7 节）

D.2 V3 划痕定位计数的未解释差异

原始测试 JSON 的划痕图像分类检出 4/11 张；整体定位评价记录 TP=0、FP=6、FN=19。另一个按视角逐框匹配的结果在 oblique 组、交并比（intersection over union，IoU）=0.5 时记录 TP=1、FP=5、FN=9，其他视角 TP=0。（来源：V3 测试与定位记录）两套定位计数不能相加或互相替换，差异原因尚未核清。因此正文采用齿部缺损数据解释图像判定与定位的任务区别，不作“划痕完全无法定位”的结论。

D.3 V4 新增比较的配置与资料来源

表 16 V4 配置与历史结果来源

正文名称	实验或配置	验证选择阈值（约）	留出指标来源
基线模型	`p_resnet18_512_w4`；四路增强	0.640567	基线 JSON 的 test.overall V4 初始基线记录
扩展单模型	`xfull_resnet18_384_w1_s73_r1`；四路增强	0.571126	详细报告 §7.2 历史测试摘要V4 详细技术报告；阈值及增强另核对候选 JSON V4 候选评价记录
三模型融合	三个分类成员，分别四路增强，分数取最大值	0.702842	最终 JSON 的 test.overall V4 最终融合记录；发布配置V4 发布配置

扩展单模型的验证 AUPRC 约 0.860，正文表中的 0.899 是详细报告记载的既有留出 AUPRC，不能混用；该留出摘要本轮没有逐图预测重算证据。这里保留已有记录，不运行模型或重选阈值。

基线与最终融合的划痕召回均为 4/11；齿部缺损分别为 13/19 和 15/19。两个增加的检出计数来自齿部缺损，但尚未按逐图集合确认哪些图像被补检或丢失。前向次数 4 与 12 是配置推导，不是现场计时；所有结果仍受既有留出反馈、样本规模和工件划分限制。

附录 E 候选实验与未采用配置

E.1 划痕候选与比较限制

问题与假设。图像分类可以识别纹理变化，却可能受加工纹和高光影响；目标检测可以预测局部缺陷区域，但定位并不总可靠。划痕检测实验比较两类模型的输出能否共同改善图像级分类结果。

对照设计。正式记录包含 6 个分类模型初步实验、2 个目标检测模型初步实验和 2 个增加训练轮数上限的分类模型重新训练实验。初步分类实验比较 ResNet18、EfficientNet-B0、YOLO 分类器及 384/w1、512/w2 配置；目标检测实验比较 960 输入的原始 YOLO26n 与包含 P2 检测层的模型。实验还比较是否使用测试时增强（test-time augmentation，TTA），随后进入温度参数与融合规则选择。（来源：《GearPro 综合实验与部署技术报告》第 8 节；划痕候选模型评价表）

原始 YOLO26n 检测模型的 P_D 为 38/43、P_{FA} 为 21/107，P2 对应 38/43 和 19/107；精确率–召回率曲线下面积（AUPRC）约 0.828 与 0.866。在相同 P_D 下，P2 虚警更少，排序指标更高，进入最终组合。最终分类成员为增加训练轮数上限后重新训练的 EfficientNet-B0 与初步实验中的 ResNet18，两者 384 输入、w1、无 TTA。（来源：划痕发布配置；划痕候选模型评价表）

设计认识。当前结果支持选择 P2 配置，但原始 YOLO26n 与包含 P2 检测层的模型采用不同批量大小（batch size），因此该对照未单独隔离结构变化的影响。384/w1 与 512/w2 同时改变输入和权重，也不能单独断言 w2 或 512 必然较差。融合方案的验证结果支持该模型组合，成员模型的错误互补情况还需要统计各模型在同一图像上的共同错误，并通过消融实验验证。

P2 模型的预测框最大置信度可用于图像分类，与准确定位是两个结论。原报告在 IoU=0.3 匹配中记录大量 FP，框仅作辅助线索。（来源：《GearPro 综合实验与部署技术报告》第 8.8–8.9 节）

E.2 齿部缺损候选与选择规则

问题与假设。齿部缺损在不同位置有不同外观。细分位置标签可能帮助学习，也可能分散有限监督。V1 用交叉矩阵比较类别设计、训练数据筛选方式和检测结构。

对照设计。初步目标检测实验比较三类、两类和单类标注、两种训练数据配置以及原始 YOLO26n 和包含 P2 检测层的模型，共 12 组，统一 960 输入和 35 轮训练上限。随后进行 12 个初步分类实验、增加训练轮数上限的重新训练、第二个随机种子的验证、1280 输入对照及重采样与 CLAHE（限制对比度的自适应直方图均衡化）增强实验，总计 34 个实验记录。（来源：《GearPro 综合实验与部署技术报告》第 9 节；齿部缺损候选模型评价表）

三类标注区分 bottom/oblique/side，两类合并 bottom 与 oblique，单类将位置归为一个齿部缺损目标。入选数据配置下，原始 YOLO26n 模型与包含 P2 检测层的模型均检出 33/34，原始 YOLO26n 检测模型误报 6/65，P2 误报 13/65。采用单类标注的原始 YOLO26n 模型以较低误报成为入选方向，说明细分标签或增加高分辨率特征层并未自动改善判定。

最终 EfficientNet 采用 512 输入，ResNet18 采用 384 输入，检测器采用单类标注的原始 YOLO26n 模型和 960 输入。不同成员保留不同训练配置；它们的互补程度仍需逐图对照。（来源：齿部缺损发布配置）

选择规则带来的取舍。最终检测模型采用初步实验保存的权重。增加训练轮数上限后重新训练的模型具有相同总体 P_D 和 P_{FA}，选择规则先比较各位置组中的最低 P_D：初步实验约 0.917，重新训练约 0.909，随后才比较 AUPRC。因此按既定规则选择初步实验模型。这个小差别对应很少样本，体现规则遵守，不证明初步实验模型具有稳定的统计优势。（来源：《GearPro 综合实验与部署技术报告》第 9.11 节）

E.3 未采用配置

表 17 未采用配置及已有观察

探索	预期作用	现有观察与选择
V4 纹理三通道	强调亮度、局部对比和边缘	已有比较未支持替换 RGB（红绿蓝三通道彩色）输入，最终方案保留 RGB
V5 四路 TTA	减轻外观变化	最终模型未采用测试时增强
V1 1280 输入	增加局部细节像素	所比较的重新训练配置该对照未支持替换最终模型，输入规模更大
V1 重采样与 CLAHE 增强	改善少数和易漏区域的学习	未替换当前最终检测器
V1 增加训练轮数上限后的重新训练	更充分拟合数据	最低位置组 P_D 的排序未优于初步实验模型，虽 AUPRC 更高

表 依据《GearPro 综合实验与部署技术报告》第 7–9 节。结论针对已有配置与数据；保留这些实验，是为了说明方案怎样收敛，而非宣称相应方法在所有场景无效。

附录 F 参数选择与补充结果

F.1 训练参数、采样与框架配置

分类网络从 ImageNet 预训练参数初始化，替换输出层后训练；YOLO 采用官方初始化或框架 P2 配置加载可迁移权重。最终 checkpoint 来自对应训练实验的保存及验证选择，并不是人为给每层设一个“识别权重”。（来源：《GearPro 综合实验与部署技术报告》第 8–9 节）

自定义分类器使用 Focal BCE：$L = \text{mean}[w_y(1-p_t)^\gamma \,\text{BCE}(z,y)]$，其中`p_t`为真实类别的预测分数。Focal 机制降低易样本的损失权重，方法动机来自 Lin 等 [13]；项目 γ=1.5 为预先固定的参数。V5 在组合候选中比较 w1/w2，最终分类器 w1；V1 正类权重 2 在本轮固定，没有独立网格证明其最优。

逆频率采样 $w_i = 1/n_{(\text{label, view or position})}$ 改变样本出现频率，与损失权重是不同机制。FN×3、FP×2 难例乘数为脚本设定；V5 本轮实际额外加权仅一张训练 FP，不能据策略存在就宣称额外采样带来主要收益。（来源：《GearPro 综合实验与部署技术报告》第 8.5 节）

YOLO 分类候选的 w2 通过复制正类文件改变训练经验分布，并非直接给其分类损失乘以 2。检测训练参数文件记录的边框回归、分类与分布焦点损失（box/cls/dfl）权重为 7.5/0.5/1.5，属于框架配置，未独立消融；通用字段是否实际生效须结合任务实现和 loss 日志解释。（来源：《GearPro 综合实验与部署技术报告》第 5.2、8.5、9.1 节）

F.2 温度参数选择

项目将原始分数 p 转换为 $\text{logit}(p) = \ln[p/(1-p)]$，计算 $p_T = \text{sigmoid}(\text{logit}(p)/T)$。温度 T 在 [0.35,4.00] 的 147 个等距候选中，以验证 NLL 最小选择，边界分数按发布实现处理。（来源：《GearPro 综合实验与部署技术报告》第 5、8.3.4 节）

温度缩放借鉴 [4]。正温度保持单个模型的样本分数排序，因此不能独立提升该成员模型理想排序下的 ROC 曲线下面积（AUROC）与 AUPRC；它可以改变融合中的相对尺度。当前做过温度选择，校准质量及融合概率可靠性仍需要校准前后 NLL、可靠性图与分箱样本量评价。

F.3 融合公式、候选与完整阈值

将两个分类模型经温度缩放后的分数先取平均 $c = (s_{\text{Eff}} + s_{\text{Res}})/2$，再比较 $f_\alpha = \alpha c + (1-\alpha)s_{\text{det}}$，$\alpha \in \{0.25, 0.50, 0.75\}$，同时比较单模型、分类分数平均/最大值及与检测模型分数取最大值的方案。V5 记录 20 个融合候选规则，V1 保留 21 个候选成绩。（来源：《GearPro 综合实验与部署技术报告》第 8.2、9.6 节；齿部缺损融合候选评价表）

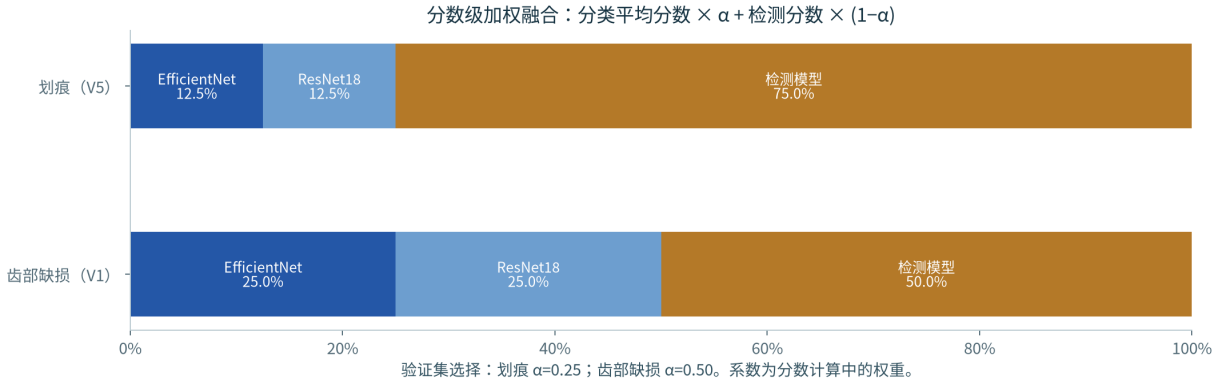


图 15 发布配置（来源：划痕发布配置；齿部缺损发布配置）中的融合公式展开。划痕 α=0.25，所以分类器分别 0.125、检测器 0.75；齿部缺损 α=0.50，所以分类器分别 0.25、检测器 0.50。系数表示分数计算规则，不能解释为因果贡献或定位精度。

表 18 最终成员系数、温度及阈值

检测任务	分类模型 1：EfficientNet	分类模型 2：ResNet18	目标检测模型	温度参数 T（同序）	判定阈值（展示值）
划痕 V5	0.125	0.125	0.750	0.700/2.050/2.125	0.3003
齿部缺损 V1	0.250	0.250	0.500	1.000/2.375/1.850	0.3413

V1 最终将分类平均分数与检测分数等权融合的方案，与仅使用 EfficientNet 分类分数并赋予其 0.25 权重的方案，均为 34TP、4FP；其 AUPRC 分别约 0.966 和 0.963，前者在优先评价指标相同时，按 AUPRC 排序被选中。（来源：齿部缺损融合候选评价表）连续扫描进一步显示，$\alpha = 0.18$–0.64 的经验

NP 工作点均为 34TP、4FP，现用 0.50 位于平台中部。TPE 搜索得到三成员权重 0.0486/0.2002/0.7513 和更高的 NP 区域 pAUC，但工作点计数没有变化；小验证集上的搜索不用于改写发布参数。（来源：融合权重与阈值重分析）

部署使用 JSON 完整精度：划痕阈值 0.300273610279458，齿部缺损阈值 0.3413327979078584。前者正好等于一张被检出划痕图像的分数，与阈值下方最近的正常图像只差约 0.0004；后者正好等于齿部缺损验证集的最低正样本分数。正文四位小数方便阅读，运行时不据正文舍入重建阈值。两个阈值都没有样本外分数余量。（来源：划痕发布配置；齿部缺损发布配置；融合权重与阈值重分析）

F.4 阈值选择与两类结果合并

历史流程在固定候选分数上扫描验证阈值，优先满足 $P_{FA} \leq 0.20$，再最大化 P_D，随后按项目规则比较位置、P_{FA} 和 AUPRC 等量。本文把这一规则称为经验 NP 准则。齿部缺损流程特别考虑各位置组中的最低 P_D，图像选择目标与基于边界框匹配的平均精度均值（mean average precision, mAP）不同。（来源：《GearPro 综合实验与部署技术报告》第 8.3.4、9.2 节）

$P_D \geq 0.95$、$P_{FA} \leq 0.20$ 没有正式产线需求或成本测算依据，本文将其保留为**历史实验目标及选择约束**。0.20 解释当时阈值如何被选出；0.95 解释历史目标，不作为本项目当前生产验收标准。经验比例也不提供总体虚警保证 [5]，结果继续保留真实数值，评价重点转向检出能力及人工复核负担。

决策级融合采用或规则：$\text{REJECT} = (s_{\text{scratch}} \geq \tau_{\text{scratch}}) \vee (s_{\text{missing}} \geq \tau_{\text{missing}})$。这里 OR 表示逻辑或：任一检测子系统判为有缺陷，最终即判为有缺陷。两个子系统的分数针对不同缺陷，负样本定义和温度参数估计所用的数据不同，因此分别进行阈值判定，再合并二值结果。每个任务的 P_{FA} 约束不自动成为融合系统的 P_{FA} 约束，不含这两类缺陷的图像上的虚警需单独统计。工业外观检测已有采用缺陷类别独立建模与或规则决策融合的研究 [15]；该文献用于方法命名及相关工作比较，不是历史参数来源。

F.5 复核评价框架

漏检优先的使用方向需要同时呈现：**主指标 P_D，配套指标 P_{FA}、精确率和预测为缺陷的样本比例**。对同一集合，预测为缺陷的样本比例为 $q = (\text{TP} + \text{FP})/N$，它在当前记录中只表示图像预测比例。只有评价单位与工件一一对应，且全部疑似工件送复核时，才等于工件送复核比例；多视角图像不能直接作此换算。

表 19 人工复核评价框架

评价问题	当前可以给出的证据	尚需明确的信息
有多少缺陷漏检	FN 计数、总体及位置分组的 P_D	被判为无缺陷的工件是否复核或抽查
正常件增加多少检查	FP 计数和 P_{FA}	人工复核时间、处理能力
一共需要检查多少件	当前数据上的预测为缺陷的样本比例	真实缺陷比例、复核流程
应选择哪个判定阈值	历史阈值对应的验证结果及误差分析	两类缺陷标签完整的新开发数据、可接受漏检与复核负担

NP 和成本敏感方法提供目标制定思想 [31][5][6]，不能直接给出新的合格百分比。当前权重和阈值维持历史配置，今后在流程明确后用新的开发数据选择判定阈值，旧测试留作回归。

F.6 参数来源完整表

表 20 参数来源完整表

参数	采用值/方法	来源类型与证据
网络参数	预训练初始化后微调	外部初始化＋对应训练实验保存
分类骨干与输入	V5 两个分类模型均为 384；V1 为 512/384	验证候选选择；V5 输入与 w 同时变化
检测结构	V5 含 P2 检测层；V1 单类原始 YOLO26n	两类任务分别对照；batch 等条件仍有差异
Focal 聚焦参数 γ / V1 正类权重	1.5 / 2	预先固定的训练参数，未独立消融
采样与难例乘数	逆频率；FN3、FP2	预先设定的采样规则，实际使用范围见附录 F.1
温度参数	每个检测子系统的三个成员模型分别估计 T	验证 NLL 估计，数值见划痕发布配置；齿部缺损发布配置
融合系数	α=0.25/0.50	验证有限候选搜索；V1 连续扫描与 TPE 诊断见重分析
判定阈值	约 0.3003/0.3413	固定融合的经验 NP 验证扫描；两者均落在验证样本分数上
候选框保留下限 / 非极大值抑制（NMS）IoU 阈值	0.001 / 0.7	推理配置；不同于判定及框显示门槛
学习率、优化器、增强范围	各训练脚本预先设定的值	完整归档见附录 B，未逐项证明最优

F.7 验证与测试差异

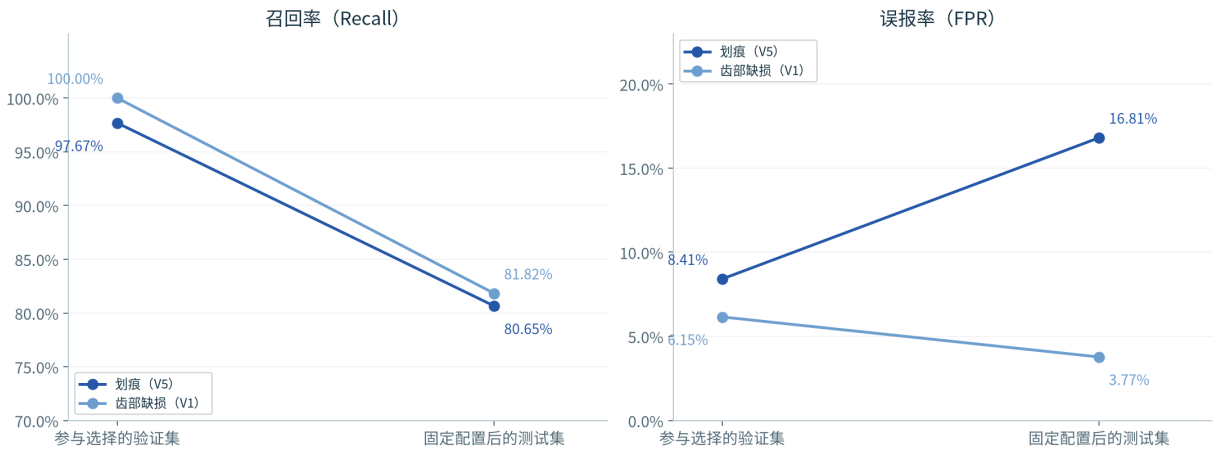


图 16 每条线连接同一缺陷类别的验证与测试 P_D、P_{FA}。两任务分母不同；验证参与多层选择，线条不表示时间上的退化。数据来自（来源：划痕发布配置；齿部缺损发布配置；划痕测试记录；齿部缺损及联合测试记录）。

划痕验证集正确检出 42/43、虚警 9/107，测试集正确检出 25/31、虚警 20/119；齿部缺损验证集正确检出 34/34、虚警 4/65，测试集正确检出 36/44、虚警 4/106。两个子系统的测试 P_D 均约 81%，明显低于参与选择的验证表现。

差异可能涉及验证选择偏差、拍摄条件变化和样本构成差异，当前数据不能量化各因素贡献。按图像计数的 Wilson 95% P_D 区间：划痕约 63.7%–90.8%，齿部缺损约 68.0%–90.5%；同一工件图像间的相关性未知，区间仅作描述性参考。

F.8 位置分组结果

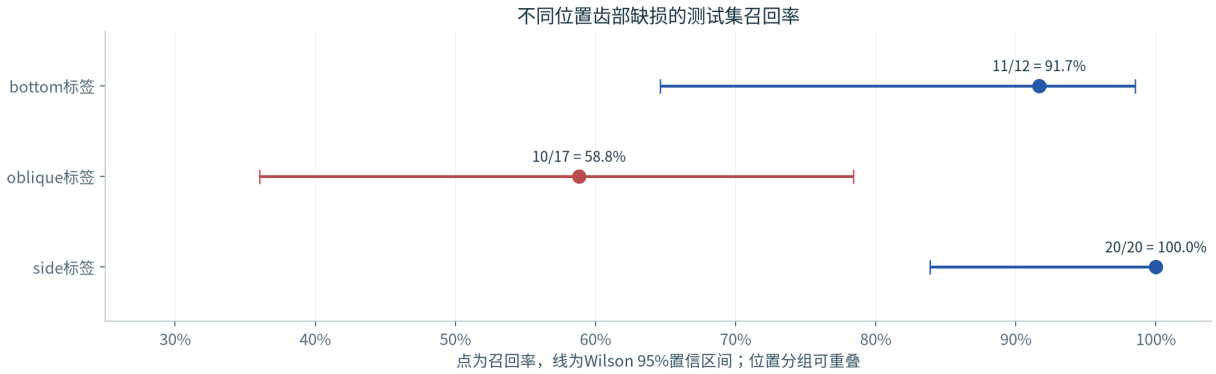


图 17 bottom 为 11/12、oblique 为 10/17、side 为 20/20。位置分组可重叠，数量之和 49 大于 44，不能相加算总体 P_D；区间按图像计数推导。（来源：齿部缺损及联合测试记录）

齿部缺损 8 个漏检中 7 个属于 oblique，说明这类位置是当前采集和可见性检查的重点。side 的 20/20 也应结合样本量理解；位置分组只用于描述当前测试集，不能单独解释验证与测试之间的差距。（来源：《GearPro 综合实验与部署技术报告》第 9.7 节；齿部缺损及联合测试记录）

F.9 缺陷比例与复核负担

联合测试可见目标缺陷图像比例 71/150，是富含缺陷的研究数据，不代表生产线。假设 P_D 和 P_{FA} 保持不变,Precision $= \pi P_D/[\pi P_D+(1-\pi)P_{FA}]$,预测为缺陷的样本比例为 $q = \pi P_D+(1-\pi)P_{FA}$，$\pi$ 为应用条件下的可见目标缺陷图像比例，并非整件缺陷率。正文按 0.5%–10% 模拟了精确率、每千张虚警数与漏检数。[3][33]

由此，论文与实验不能单凭 77.78% 测试 Precision 证明生产复核可靠性。下一步需分别测量应用图像与工件的缺陷比例、被判为无缺陷的工件中的漏检情况、疑似缺陷工件的人工确认比例与复核时间，再确定适用的判定阈值。当前可确认的是研究图像上的计数，人工复核效果未测量。

F.10 合并结果的类别解释与划痕分组统计

齿部缺损检测本身检出 36/44 张正样本；两类结果合并后，这 44 张图像中有 41 张被标为疑似缺陷。其中 5 张由划痕检测判为有缺陷，不能据此将齿部缺损检测的正确检出数改为 41。（来源：齿部缺损及联合测试记录）

历史划痕分析中，漏检组的分类模型平均分数约 0.455、检测模型平均分数约 0.144；误报组的分类模型平均分数约 0.814。结合图像外观，加工纹和高光是值得检查的误报来源，但分组均值不能直接解释每张图像的错误原因。（来源：《GearPro 综合实验与部署技术报告》第 8.6.3 节）

F.11 正文新增单模型与融合对照的完整记录

下表均为同一任务验证集、经验 NP 准则下各方案的工作点。α 表示分类分数系数，检测分数系数为 $1-\alpha$；两个分类分数均值作为一项时，共有三个成员。候选采用各自阈值，不能解释成阈值固定的组件移除实验。划痕发布配置未给出最终融合 AUPRC，此处不补造。

表 21 单模型与融合完整验证记录

任务	实验名／配置	组合规则	TP ／ FP	完整阈值	AUPRC	来源
划痕	`f_efficientnet_b0_384_w1_s20260911`	单模型	41 ／ 13	0.542919409017341	0.893870	候选评价表
划痕	`p_detector_p2_960`	单模型	38 ／ 19	0.18610403292287162	0.866130	候选评价表
划痕	发布配置中的两个分类模型及 P2 检测模型	分类均值与检测分数加权，α=0.25	42 ／ 9	0.300273610279458	未载明	发布配置
齿部缺损	入选 EfficientNet-B0 配置	单模型	34 ／ 6	0.3809993863105774	0.924740	融合候选评价表
齿部缺损	入选单类 YOLO26n 配置	单模型	33 ／ 6	0.12059450038989711	0.944733	融合候选评价表
齿部缺损	`classifier_mean`	两个分类分数均值	34 ／ 5	0.5251138191759659	0.894532	融合候选评价表
齿部缺损	入选 EfficientNet 与检测分数配置	EfficientNet 与检测分数加权，α=0.25	34 ／ 4	0.20599650265366867	0.963388	融合候选评价表
齿部缺损	`weighted_classifier_mean_0.5`	分类均值与检测分数加权，α=0.50	34 ／ 4	0.3413327979078584	0.965955	融合候选评价表

单模型与融合的逐图补检／丢失样本尚未在本轮核对，计数差是净变化。齿部缺损两模型与三模型的 34TP、4FP 相同，不代表预测图像集合相同，也不证明两者部署代价或稳定性相同。当前配置维持不变，成员必要性与 NX 开销仍待验证。

附录 G 原型状态与后续测量

正文第 2 章介绍了整机组成与软件链路；以下记录原型各部分的当前状态，以及后续整机测量与验证的设计。

G.1 原型状态

整机安装上下两台工业相机，计算平台为 Jetson Orin NX。当前软件测试使用单路相机，双路取或的工件级判定尚未实现；新模型只做过简单现场测试，未记录测试数据。第一代实物完成输送、采集、显示与分拣链路，表示原型功能可连接，不代表当前模型已经经过完整现场验收。软件链路的整理依据《GearPro 综合实验与部署技术报告》第 13 节。

软件只保留最新采集帧，可以避免推理积压。系统按传送带一次通过一个齿轮的场景设计，当前仍缺少跨帧工件 ID 追踪、检测时间和分拣对应测量。（来源：《GearPro 综合实验与部署技术报告》第 13.1–13.4 节）

表 22 软件与原型状态

内容	当前状态	报告中的证据层级
自建数据与标注	已完成单台相机的多角度拍摄，图像与工件的对应关系未建立	项目组确认＋图像与标签清单
V5/V1 离线模型	已有配置、权重索引与测试记录	配置及 JSON/CSV
Web、统计与串口	已实现统一结果链路	软件实现及阶段材料
上下双相机、Orin NX、机构	第一代原型链路已连通；双路取或待实现，当前测试使用单路	实物与项目组确认
当前模型 NX 现场测试	简单测试，未记录数据	功能尝试，缺系统性能测量
NX 回放耗时	已测定位与划痕子系统，未含齿部缺损子系统	NX 回放耗时记录
人工复核流程	应用方向已明确，流程未定	设计需求
部署优化与节拍	定位模型已有 TensorRT FP16 引擎；检测子系统未做加速，整机节拍未测	回放记录与后续测量

G.2 整机测量

后续从相机原帧记录定位、ROI、缺陷判定、串口命令和实际分拣，将漏定位、未处理、错配、迟到及未执行纳入统计。各层级分别定义分母，避免仅在成功 ROI 上计算精度。

NX 测试先保持发布配置，记录取帧、定位、各成员模型、后处理和传输时间，以及温度、资源及长时运行；再决定检测子系统是否需要 FP16 或其他优化。第 2.3 节的回放耗时只覆盖定位和划痕子系统，且当前未确定每件处理窗口，本报告不据此设定整机每秒处理帧数（frames per second，FPS）指标。

G.3 后续实验与评价方法

表 23 后续实验与评价方法

待回答的问题	拟开展验证	主要输出
对新齿轮是否有效	建立工件 ID；按工件和拍摄批次分组，采集训练中未见的齿轮	新齿轮工件测试及样本构成
哪些缺陷实际拍得清	固定工件与相机，逐项比较照明、观察角和载台	原图、可见性、定位与困难子组变化
V5 输入与权重各自作用	同拆分和骨干，384/512×w1/w2	解耦后的候选与波动
成员模型校准和融合是否必要	固定成员模型参数，独立校准/开发比较，保存错误交集	NLL、可靠性图、识别收益与开销
复核流程怎样减少漏检	明确被判为无缺陷的工件处理、复核能力与新的判定阈值	P_D、P_{FA}、确认比例及复核时间
双相机能否减少漏检	实现两路各自检测后取或，在同批工件上对照单路与双路	工件级 P_D、P_{FA} 及新增耗时
NX 是否满足真实节拍	完整原型记录分项耗时和工件命令对应	时延分布、覆盖、资源与稳定性

大搜索空间可将随机搜索作为预算基线 [7]，昂贵训练可考虑贝叶斯优化 [8]。本轮只对齿部缺损已有验证分数做了 TPE 权重搜索，没有重新训练模型；划痕成员验证分数仍不完整。后续优先保证数据来源和实验问题明确，再决定搜索预算。

上线后如缺陷稀少、标注预算有限，可参考 Shang 等按预测结果分层抽样并校正精确率和 P_D 估计的研究 [9]。这涉及测试抽样，与训练正类复制不同；实际流程需包含被判为无缺陷的工件抽查，才能评价漏检。

附录 H 文献与证据的对应关系

表 24 文献支持与项目证据边界

文献	支撑内容	项目仍需提供的证据
[1] Raschka；[2] Cawley 与 Talbot	评价与选择区分，小样本选择风险	按工件分组划分数据、固定模型及判定参数、新数据评价
[3] Saito 与 Rehmsmeier；[33] Brabec 等	精确率受类别比例影响	实际缺陷比例及复核负担
[4] Guo 等	温度缩放与校准动机	校准前后质量、融合分数可靠性
[31] Scott 与 Nowak；[5] Tong 等；[6] Elkan	NP 约束、错误优先级与成本	复核流程、成本和正式目标；当前经验 NP 准则无总体误差保证
[7] Bergstra 与 Bengio；[8] Snoek 等；[32] Lévesque 等	搜索预算、贝叶斯优化与集成权重	齿部缺损已有分数搜索；仍需新开发数据复核
[9] Shang 等	未来生产抽检与抽样校正	实际抽样记录；当前区间不源于该抽样法
[10]–[13] 模型与方法原始文献	骨干、多尺度与 Focal 机制	齿轮候选对照，具体参数值依据
[14] MVTec 公司（德国机器视觉软件企业）官方资源	工业异常检测研究设定	自身正常样本多样性；本项目未使用该数据集
[15] Choi 与 Seong；[16] Kittler 等；[17] Wu 等	决策融合与分类器组合的已有用法	本项目自身的模型输出、融合公式及验证结果；文献不是历史参数来源

参考文献

[1] Raschka S. Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning. arXiv:1811.12808, 2018; v3, 2020. 预印本/综述教程，非正式同行评审论文。

[2] Cawley G C, Talbot N L C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. JMLR, 2010, 11:2079–2107.

[3] Saito T, Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 2015, 10(3):e0118432.

[4] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks. ICML, PMLR 70, 2017:1321–1330.

[5] Tong X, Feng Y, Li J J. Neyman-Pearson Classification Algorithms and NP Receiver Operating Characteristics. Science Advances, 2018, 4(2):eaao1659. 作者机构全文。

[6] Elkan C. The Foundations of Cost-Sensitive Learning. IJCAI, 2001:973–978.

[7] Bergstra J, Bengio Y. Random Search for Hyper-Parameter Optimization. JMLR, 2012, 13:281–305.

[8] Snoek J, Larochelle H, Adams R P. Practical Bayesian Optimization of Machine Learning Algorithms. Advances in Neural Information Processing Systems 25, 2012.

[9] Shang H, Langlois J M, Tsioutsiouliklis K, Kang C. Precision/Recall on Imbalanced Test Data. AISTATS, PMLR 206, 2023:9879–9891.

[10] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016:770–778.

[11] Tan M, Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML, PMLR 97, 2019:6105–6114.

[12] Lin T Y, Dollár P, Girshick R, He K, Hariharan B, Belongie S. Feature Pyramid Networks for Object Detection. CVPR, 2017:2117–2125.

[13] Lin T Y, Goyal P, Girshick R, He K, Dollár P. Focal Loss for Dense Object Detection. ICCV, 2017:2980–2988.

[14] MVTec Software GmbH. MVTec AD 工业异常检测数据集官方说明. 在线数据集资源，访问日期 2026-10-06；用于研究设定说明，项目未以该数据集训练。

[15] Choi K J, Seong J T. A Decision-Level Fusion Hybrid Deep Learning Framework for High-Precision Automated Optical Inspection of VCSEL Semiconductor Devices. AIMS Mathematics, 2026, 11(5):14487–14521. DOI:10.3934/math.2026594.

[16] Kittler J, Hatef M, Duin R P W, Matas J. On Combining Classifiers. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(3):226–239. DOI:10.1109/34.667881.

[17] Wu X, Zhang Q, Wang J, Yao J, Guo Y. Multiple Detection Model Fusion Framework for Printed Circuit Board Defect Detection. Journal of Shanghai Jiaotong University (Science), 2023, 28(6):717–727. DOI:10.1007/s12204-022-2471-0.

[18] Yu L, Wang Z, Duan Z. Detecting Gear Surface Defects Using Background-Weakening Method and Convolutional Neural Network. Journal of Sensors, 2019:3140980. DOI:10.1155/2019/3140980.

[19] Yan R, Zhang R, Bai J, Hao H, Guo W, Gu X, Liu Q. STMS-YOLOv5: A Lightweight Algorithm for Gear Surface Defect Detection. Sensors, 2023, 23(13):5992. DOI:10.3390/s23135992.

[20] Zhang S, He M, Zhong Z, Zhu D. An Industrial Interference-Resistant Gear Defect Detection Method Through Improved YOLOv5 Network Using Attention Mechanism and Feature Fusion. Measurement, 2023, 221:113433. DOI:10.1016/j.measurement.2023.113433.

[21] 陶显, 侯伟, 徐德. 基于深度学习的表面缺陷检测方法综述. 自动化学报, 2021, 47(5):1017–1034. DOI:10.16383/j.aas.c190811.

[22] Chen J, Liu Z, Wang H, Nunez A, Han Z. Automatic Defect Detection of Fasteners on the Catenary Support Device Using Deep Convolutional Neural Network. IEEE Transactions on Instrumentation and Measurement, 2018, 67(2):257–269. DOI:10.1109/TIM.2017.2775345.

[23] Tao X, Zhang D, Wang Z, Liu X, Zhang H, Xu D. Detection of Power Line Insulator Defects Using Aerial Images Analyzed With Convolutional Neural Networks. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(4):1486–1498. DOI:10.1109/TSMC.2018.2871750.

[24] Wei X, Yang Z, Liu Y, Wei D, Jia L, Li Y. Railway Track Fastener Defect Detection Based on Image Processing and Deep Learning Techniques: A Comparative Study. Engineering Applications of Artificial Intelligence, 2019, 80:66–81. DOI:10.1016/j.engappai.2019.01.008.

[25] Zhu X, Lyu S, Wang X, Zhao Q. TPH-YOLOv5: Improved YOLOv5 Based on Transformer Prediction Head for Object Detection on Drone-Captured Scenarios. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops, 2021:2778–2788. DOI:10.1109/ICCVW54120.2021.00312.

[26] Tang J, Fang W, Wang S, Qiu P, Wang H. PCB-YOLO: An Improved Detection Algorithm of PCB Surface Defects Based on YOLOv5. Sustainability, 2023, 15(7):5963. DOI:10.3390/su15075963.

[27] Kim S, Kim W, Noh Y, Park F C. Transfer Learning for Automated Optical Inspection. International Joint Conference on Neural Networks, 2017:2517–2524. DOI:10.1109/IJCNN.2017.7966162.

[28] Ren R, Hung T, Tan K C. A Generic Deep-Learning-Based Approach for Automated Surface Inspection. IEEE Transactions on Cybernetics, 2018, 48(3):929–940. DOI:10.1109/TCYB.2017.2668395.

[29] Chen W, Gao Y, Gao L, Li X. A New Ensemble Approach Based on Deep Convolutional Neural Networks for Steel Surface Defect Classification. Procedia CIRP, 2018, 72:1069–1072. DOI:10.1016/j.procir.2018.03.264.

[30] Stephen O, Sain M, Maduh U J, Jeong D-U. A Robust Deep Learning Ensemble-Driven Model for Defect and Non-Defect Recognition and Classification Using a Weighted Averaging Sequence-Based Meta-Learning Ensembler. Sensors, 2022, 22(24):9971. DOI:10.3390/s22249971.

[31] Scott C, Nowak R. A Neyman–Pearson Approach to Statistical Learning. IEEE Transactions on Information Theory, 2005, 51(11):3806–3819. DOI:10.1109/TIT.2005.856955.

[32] Lévesque J-C, Gagné C, Sabourin R. Bayesian Hyperparameter Optimization for Ensemble Learning. Proceedings of the Thirty-Second Conference on Uncertainty in Artificial Intelligence, 2016:437–446.

[33] Brabec J, Komárek T, Franc V, Machlica L. On Model Evaluation Under Non-Constant Class Imbalance. Computational Science – ICCS 2020, LNCS 12140:74–87. DOI:10.1007/978-3-030-50423-6_6.