齿轮外观缺陷检测

系统技术报告

自建数据·两类缺陷选型·参数依据·软件集成

GearPro 阶段记录日期：2026 年 10 月 7 日

摘要

本项目面向齿轮外观质检场景，自主采购或定制 50 个齿轮，进行多角度拍摄并标注划痕和齿部缺损。在早期分类探索的基础上，针对两类缺陷分别选择模型与判定参数，再合并检测结果。报告围绕两类缺陷分别探索标签、检测结构与分数组合。验证对照中，划痕融合比入选 EfficientNet 单模型多检出 1 张、少误报 4 张；齿部缺损融合主要减少误报，三模型并未在检出和误报计数上优于已比较的两模型方案。在同一批 150 张测试图像上，系统检出 63/71 张缺陷图像，误报 18/79 张无可见目标缺陷图像；相比已测试的统一缺陷分类模型，多检出 9 张、少误报 15 张。项目已完成软件集成及第一代原型链路，当前使用上下两台工业相机和 Jetson NX；新模型尚无系统记录的整机测试结果。现阶段应用方向是辅助人工复核，离线图像结果仍需通过新工件与现场测试验证。

关键词：齿轮外观检测；划痕；齿部缺损；模型融合；边缘计算

阅读说明：正文围绕任务、方法、实验依据和结果展开；完整配置与补充分析放在附录。项目事实、实验记录与历史报告的来源说明见附录 B；学术文献采用数字编号引用。本报告未新增训练或现场测试。

目录

1 项目背景与检测任务 1

2 技术路线与文献依据 2

3 关键发现与最终方案选择 3

4 参数来源与检测结果 7

5 项目贡献与后续验证 9

附录 A 文献与证据的对应关系 11

附录 B 关键固定训练参数与资料索引 11

附录 C 术语及方法名称 12

附录 D 数据检查与早期探索 13

附录 E 候选实验与未采用配置 16

附录 F 参数选择与补充结果 18

附录 G 软件、整机状态与后续测量 22

参考文献 25

1 项目背景与检测任务

1.1 应用目标与工作范围

制造业零件质检需要兼顾缺陷检出、检查效率和设备成本。本项目探索用深度学习识别与边缘计算辅助齿轮外观检查，并连接图像采集、结果显示、自动分拣和数据管理。降低成本、减少漏检和适应复杂环境是设计目标，尚无人工检查基线、完整成本清单或复杂工厂环境对照，不能视为已经验证的效果。

本人负责全部软件与模型工作，成员负责硬件及后续现场部署。报告以算法探索为重点，结合软件如何连接相机、Web 页面和 STM32 控制说明整机方案。目前保留上下两台工业相机，设备已升级为 Jetson NX；第一代输送、采集、显示与分拣链路已打通，新模型仅做过简单现场测试，未记录性能数据。

1.2 缺陷定义与自建数据

项目共有 50 个齿轮：正常 10 个、划痕 15 个、侧部缺损 15 个、齿角缺损 10 个，均自行采购或定制。采集使用流水线原型的工业摄像头，由人工摆放、调整齿轮姿态获得上下、旋转和侧面等角度，以模拟部分观察条件，尚未覆盖连续输送中的运动和姿态变化。明确可见的划痕和局部齿部缺损均按不合格区域标注，未建立按深度、尺寸或机械性能分级的合格标准。因此检测任务是识别已定义的外观缺陷，不能直接评价齿轮服役安全。



图 1 自建数据中的正常外观、划痕与齿部缺损示例。红框为人工标注，局部放大用于观察，均不是模型预测。（来源：划痕数据清单；齿部缺损数据清单）

划痕容易与加工纹、高光混淆；齿部缺损的可见性受位置和观察角度影响。标注以当前图像中的可见缺陷为依据。人工确认看不到目标缺陷的图像作为该任务的负样本；可见但难以辨认或准确标注边界的缺陷标为 difficult。difficult 表示识别困难，不表示缺陷是否存在尚未确定。缺陷工件的某个视角也可能是图像负样本。

表 1　自建图像数据划分

检测任务	训练图像	验证图像	测试图像
划痕	364	150	150
齿部缺损	397	99	150

两类检测使用同一批 150 张测试图：31 张含划痕，44 张含齿部缺损，其中 4 张同时含两类缺陷，即 71 张至少含一类缺陷、79 张无可见目标缺陷。（来源：划痕测试记录；齿部缺损及联合测试记录；划痕数据清单；齿部缺损数据清单）图像数量不能当作不同工件数量；当前只有图片顺序编号，尚不能确认同一齿轮的多角度图像是否分布在训练、验证和测试中。该限制影响对新工件泛化能力的判断，详细数据检查见附录 D。

2　技术路线与文献依据

2.1　从图像到检测结果

系统先定位齿轮并裁剪感兴趣区域（region of interest，ROI），减少背景干扰，再分别检测划痕与齿部缺损。每类缺陷使用两个图像分类模型和一个目标检测模型：前者判断整体外观，后者提供局部缺陷线索，并将最高预测框置信度用于图像级判断。

同类缺陷的三个模型分数经过温度缩放后加权平均，称为分数级加权融合。温度缩放调整分数尺度，使不同模型的分数更适合组合，但当前尚未证明融合分数等于真实缺陷概率。两类融合分数分别与各自阈值比较；只要任一类达到阈值，系统就标记为疑似缺陷。这是基于或规则的决策级融合，详见附录 F。

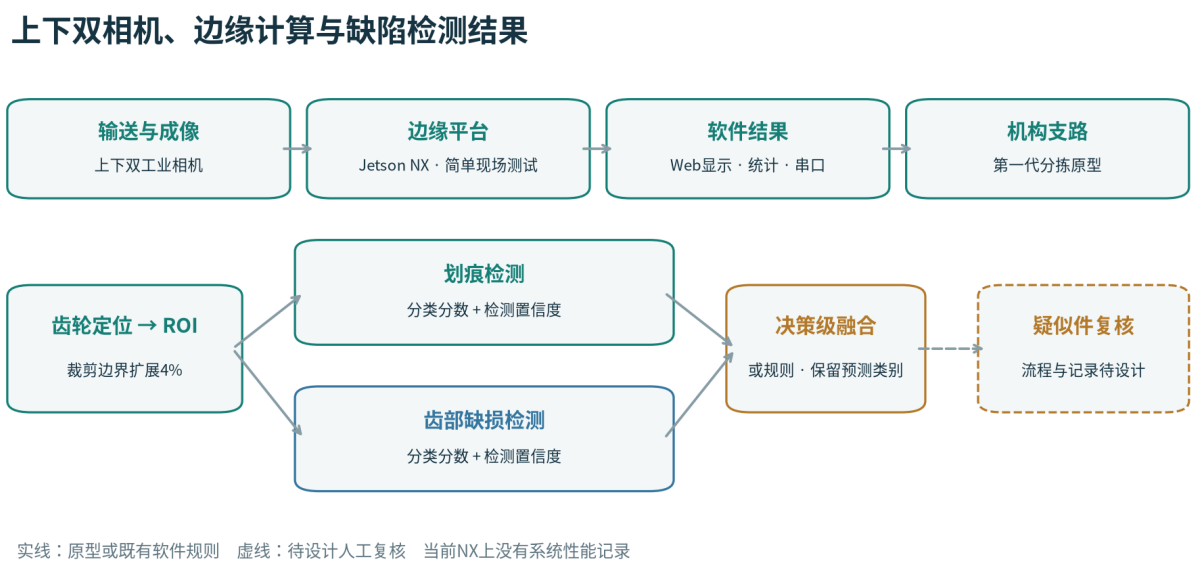


图 2　上下双相机、NX、检测软件与分拣机构的关系。虚线为尚待设计的人工复核环节；整机原型连接成功不等于最终模型已完成现场验证。（来源：项目事实说明；《GearPro 综合实验与部署技术报告》）

软件将同一次检测的分数、阈值、预测类别、预测框和耗时传给页面、统计和串口，避免各处采用不同的判断。历史代码字段 PASS/REJECT 在本文分别表示“模型未检出缺陷／疑似缺陷”。人工是否复核全部工件、疑似件或抽查模型未检出的工件，仍需确定。仅复核疑似件可以纠正误报，不能自动发现模型漏检。

2.2 相关研究如何支持设计

ResNet 和 EfficientNet 提供两种图像分类骨干 [10][11]，作为纹理与结构识别的候选；是否适合本项目由齿轮验证数据决定。FPN 的多尺度特征思想 [12] 为保留小缺陷细节提供背景，本项目据此比较原始 YOLO 模型与包含 P2 检测层的既有配置。P2 是较高空间分辨率的检测层，更多细节也可能使正常细纹引起误报。

模型组合已有成熟研究：Kittler 等讨论分类器输出的组合规则 [16]，工业外观检测也采用多检测模型融合 [17] 和按缺陷类别分别建模后的或规则决策融合 [15]。这些文献说明方法有研究基础，不能据此宣称本项目首创，也不能替代本项目对融合权重的验证。

Guo 等的温度缩放研究 [4] 支持对模型分数进行后处理。Saito 与 Rehmsmeier 强调不平衡数据下精确率–召回率分析的价值 [3]，因此本报告同时展示可见缺陷检出与图像误报。成本敏感学习及 Neyman–Pearson 分类研究 [5][6] 提示应根据错误代价确定选择目标；本项目只实施了验证集上的经验误报约束，没有实施带总体误差保证的 NP 算法。

模型评价与选择文献 [1][2] 还提醒：反复用同一验证集选模型、权重和阈值可能产生选择偏差。因此正文区分验证与测试结果，具体参数依据项目记录，论文仅支持方法动机。扩展文献与证据对应见附录 A。

3 关键发现与最终方案选择

3.1 V3：判断有无缺陷与定位缺陷是不同任务

问题与实验设计。系统既要判断图像中有无缺陷，也希望给出局部位置，供查看与复核。V3 使用分类模型区分正常、划痕和齿部缺损，另训练目标检测模型定位缺陷，并分别评价这两个任务。齿部缺损的测试记录如下。（来源：V3 测试与定位记录）

表 2 V3 图像判断与区域定位的不同评价单位

评价任务	判断对象	正确检出／参考数量	召回率
图像分类	图像中是否有齿部缺损	15/19 张图像	78.95%
缺陷定位	预测框是否正确对应缺损区域	25/52 个标注区域	48.08%

发现与设计意义。一张图像可能包含多个缺损区域；分类只需判断这张图有缺陷，定位则需要找到相应区域并满足匹配要求。因此两行分母不同，不能把召回率差值当作分类方法优于检测方法的证据。该实验明确了系统的两项职责：是否标记为疑似缺陷，与能否准确显示每个缺陷位置，应分别验证。

这一评价原则延续到 V5。目标检测模型的最高框分数可以参与图像判断，但不代表其预测框已经准确。划痕方案给检测分数 0.75 的融合系数，表示分数计算中的比例，既不是定位准确率，也不能解释为 75% 的检出来自检测模型。软件应按固定分数与阈值作出判定，将预测框作为辅助线索；不能根据有没有显示框改变判断。

V3 划痕的整体定位计数与另一套逐框匹配计数存在差异，尚未核清，正文不以其“零检出”作为论据，详细记录见附录 D。

3.2 V4：排序能力、阈值与集成收益需要分别评价

问题与实验设计。V4 将两类缺陷合并，尝试只判断“有无缺陷”，随后比较不同模型、训练预算和模型组合。下表展示同一既有留出集上的基线、扩展单模型和最终融合结果；具体阈值按验证

规则选择，并非在留出集上重新寻找。（来源：V4 初始基线记录；V4 最终融合记录；V4 发布配置；V4 候选评价记录；V4 详细技术报告）

表 3 V4 排序指标与所选工作点

方案	AUPRC	召回率	误报率	每图分类前向次数
基线模型	0.767	56.67%（17/30）	30.00%（6/20）	4
扩展单模型	0.899	约 46.7%	约 5.0%	4
三模型融合	0.814	63.33%（19/30）	35.00%（7/20）	12

表内基线及融合计数核对原始 JSON；扩展单模型的留出指标来自既有详细报告中的历史摘要，尚未由逐图预测重算。前向次数按保存的测试时增强配置推导，每个成员执行四次分类。完整实验名、阈值和来源见附录 D。

发现一：排序更好，不保证当前阈值下检出更多。 AUPRC 综合描述模型在不同分数阈值下的精确率–召回率表现；实际检出和误报则取决于采用哪个阈值。扩展单模型的历史 AUPRC 较高，但固定判定后的检出更少、误报也更少。因此模型选择与判定阈值选择需要分别说明，不能用单一排序指标替代使用效果，也不能仅凭召回降低断言模型整体变差。当前观察尚不能确定这种变化的唯一原因。

发现二：总体检出增加，划痕瓶颈仍在。从基线到三模型融合，多检出 2 张缺陷图像，同时增加 1 张无可见目标缺陷图像的误报。进一步按缺陷类别核对，划痕始终检出 4/11，齿部缺损由 13/19 升至 15/19。因此这次总体提升没有改善划痕检出数，推动后续单独组织划痕数据与模型实验。这里比较的是计数，不能据此认定各模型检出的是完全相同的图像。

发现三：模型组合有计算与误报代价。最大值融合保留成员中的最高分数，在相同成员分数和阈值下，任一成员高响应即可触发缺陷标记，既可能补检，也可能带入误报。本次基线与融合的成员、阈值均有变化，全部差异不能只归因于最大值规则。三模型各采用四路测试时增强，每图共 12 次前向；这说明分类计算次数增加，不能写成 NX 耗时或能耗增加三倍。

基线留出结果曾用于指导扩展方向，因此上述分析用于解释历史选择，不作为始终未查看的盲测证据。它对最终方案的启发是：先查清哪些缺陷没有改善，再决定是否继续增加模型；V5 重新比较配置与增强，最终未采用测试时增强。

3.3 划痕：组合整体纹理与局部线索

问题与尝试理由。针对 V4 组合后仍未改善的划痕检出，V5 重新比较整体纹理与局部线索。分类模型能识别整体纹理，却容易受加工纹影响；目标检测能提供局部线索，但细小划痕的预测框未必准确。实验比较不同模型及其分数组合，检查是否能改善图像级缺陷判断。

如何比较。划痕实验记录包含 6 个初步分类模型、2 个初步检测模型和 2 个增加训练轮数上限的分类模型。分类候选包括 ResNet18、EfficientNet-B0 及 YOLO 分类器；检测候选比较原始 YOLO26n 和含 P2 检测层的模型。模型、融合方案和阈值均依据验证集选择。（来源：划痕发布配置；划痕候选模型评价表）

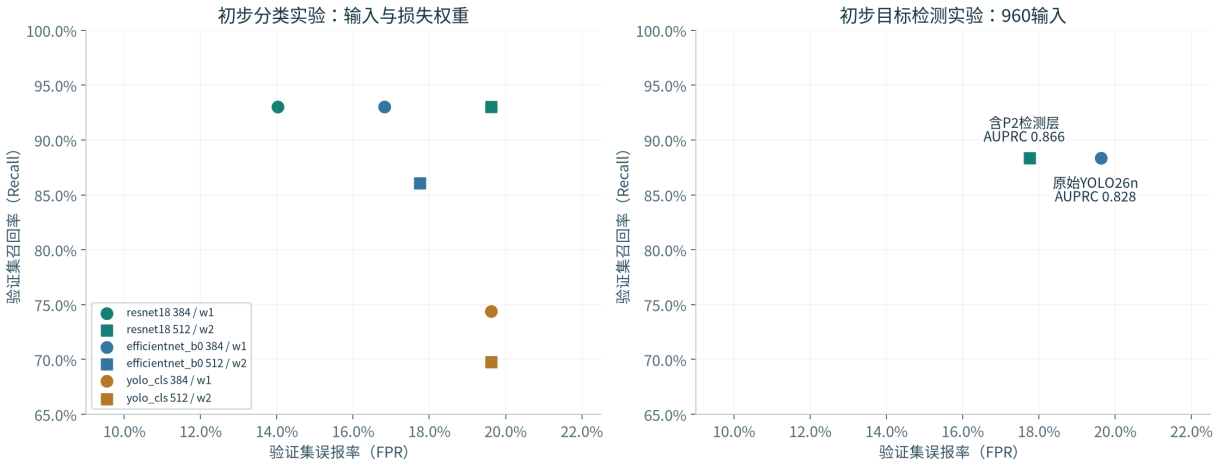


图 3 划痕候选在各自验证阈值下的召回率与误报率，采用当时 FPR≤0.20 的选择约束。图中是候选配置比较，不能把同时改变的输入尺寸、权重或 batch 分别解释为单因素效果。（来源：划痕候选模型评价表）

观察与选择。两个检测配置均检出 38/43 张划痕图像, 原始模型误报 21/107, P2 配置误报 19/107, 其精确率–召回率曲线下面积（AUPRC）也较高。因此采用 P2 配置，与两个分类模型组合。最终验证集检出 42/43、误报 9/107；固定配置后的测试集检出 25/31、误报 20/119。（来源：划痕发布配置；划痕测试记录）

表 4 划痕单模型与融合验证对照

划痕验证方案	成员数	正确检出／43 张可见划痕图	误报／107 张无可见划痕图
入选 EfficientNet 单模型	1	41	13
P2 检测模型	1	38	19
最终加权融合	3	42	9

各方案在同一验证集按既有 FPR≤0.20 规则选择各自阈值。融合比 EfficientNet 多检出 1 张、少误报 4 张，支持当前选型；它不是固定阈值的组件消融，也不是独立测试收益。来源见候选评价表与发布配置。

该结果支持当前配置选择，但两个检测实验的 batch 不同，尚不能把全部差异归因于 P2。目标检测分数可用于图像判断，也不意味着预测框准确；已有框匹配评价中仍存在大量误报。三个模型的错误是否互补，仍需同图错误交集与控制其他条件的消融验证。

3.4 齿部缺损：比较标签粒度与困难目标处理

问题与尝试理由。齿部缺损在不同位置有不同外观。细分标签可能帮助区分，也可能分散有限样本；困难目标是否保留，会改变训练监督。实验因此同时比较位置标签、困难标注处理及检测结构。

如何比较。初步检测实验共 12 组：三类／两类／单类标注，保留／排除困难目标，原始／含 P2 检测层的 YOLO 模型，均采用 960 输入、35 轮训练上限。后续还比较分类模型、更大输入和更高的训练轮数上限，完整记录见附录 E。（来源：齿部缺损候选模型评价表）

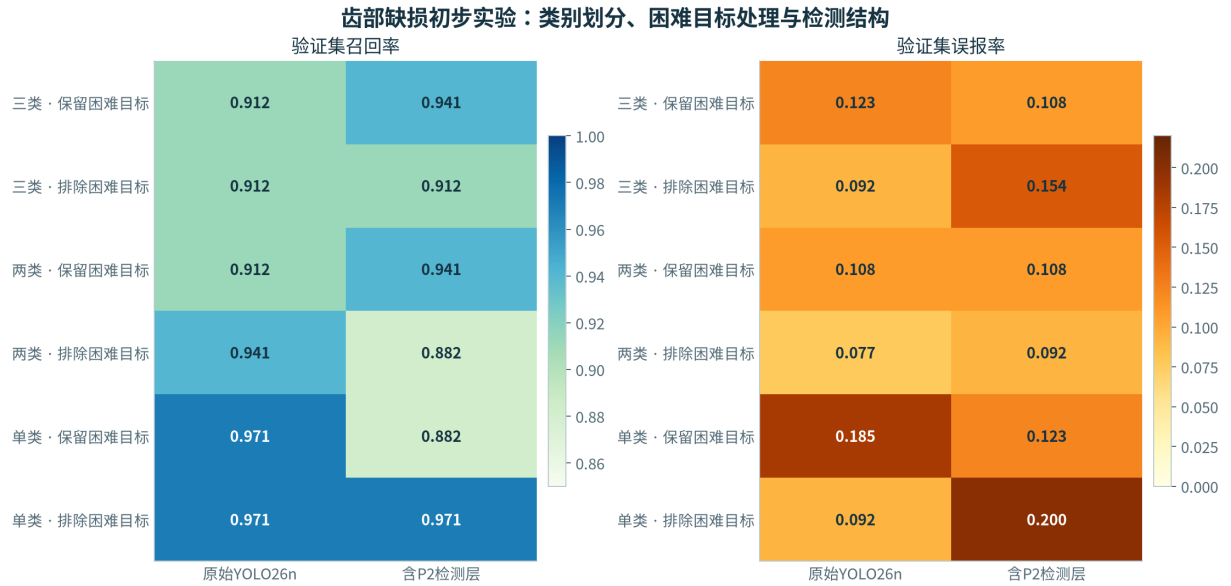


图 4　12 组检测配置在验证集上的召回率与误报率。每组采用自身验证阈值，batch 等条件未全部一致，因此该矩阵用于配置选择，不是严格隔离每个因素的消融。（来源：齿部缺损候选模型评价表）

观察与选择。单类、排除困难目标的两个结构均检出 33/34；原始模型误报 6/65，P2 配置误报 13/65。因此齿部缺损采用单类标注的原始 YOLO26n。这里“排除”只作用于训练：删除 21 个困难标注框，并移除 6 张仅含困难目标的图像，避免将已知缺陷图误作负样本；验证和测试仍保留完整标注。

最终组合中的分类模型采用不同输入和困难样本设置，检测模型采用初步实验保存的权重。提高训练轮数上限后重新训练的检测模型虽 AUPRC 更高，但既定选择规则优先比较各位置组中的最低召回率，初步模型约 0.917、重新训练模型约 0.909，因而前者入选。这一差别涉及少量样本，说明选择过程可核对，不能证明初步实验模型普遍更好。（来源：《GearPro 综合实验与部署技术报告》；齿部缺损发布配置）

表 5　齿部缺损单模型与融合验证对照

齿部缺损验证方案	成员数	正确检出／34 张可见缺损图	误报／65 张无可见缺损图
入选 EfficientNet 单模型	1	34	6
原始 YOLO 检测模型	1	33	6
两个分类模型分数均值	2	34	5
EfficientNet 与检测分数加权融合	2	34	4
最终加权融合	3	34	4

各方案在同一验证集按既有 FPR≤0.20 规则选择各自阈值。融合主要减少误报；两模型与最终三模型计数相同，后者因 AUPRC 约 0.9660 高于 0.9634 入选，不能证明三个成员都必要。完整配置见附录 F，来源为融合候选评价表。

3.5　分别检测是否值得增加模型数量

两个检测子系统完成后，又训练统一缺陷分类候选，在同一批 150 张测试图上比较“有无任意缺陷”。分别检测并合并结果的系统检出 63/71、误报 18/79；已选统一模型检出 54/71、误报 33/79。前者多检出 9 张、少误报 15 张，支持保留当前组合方案。（来源：齿部缺损及联合测试记录）

两者训练数据构造、模型数量和预算不同，因此比较说明哪套实际系统在当前测试图上更好，尚不能单独证明“分别建模”本身造成全部收益。模型文件也由统一模型约 15.6MB 增至两个检测子系统约 130MB；文件大小不等于 NX 的运行内存或耗时，部署代价仍需测量。

4 参数来源与检测结果

4.1 指标、权重与阈值各自是什么

召回率、精确率和误报率是通用评价指标，并非 YOLO 专属参数。为避免混淆，本报告区分学习得到的网络参数、组合分数的融合系数及最终判定阈值。

表 6 评价指标与模型参数的区别

名称	含义或作用	来源
召回率（Recall）	有可见目标缺陷图像中被检出的比例，TP/(TP+FN)	对照人工标注统计
精确率（Precision）	被判为有缺陷的图像中真正有缺陷的比例，TP/(TP+FP)	对照人工标注统计
误报率（FPR）	无可见目标缺陷图像中被误判的比例，FP/(FP+TN)	对照人工标注统计
网络参数	决定网络如何提取和判断特征	预训练初始化后通过训练更新
温度参数	调整模型分数尺度	选择验证集负对数似然最小的候选
融合系数	决定各模型分数的加权比例	比较预设融合候选的验证结果
判定阈值	将连续分数转换为疑似缺陷标记	固定模型与融合后扫描验证阈值

TP、FN 分别为正确检出与漏检的缺陷图像；FP、TN 分别为误报与正确排除的无可见目标缺陷图像。指标是评价结果，不直接决定某个权重应该取多少。

4.2 核心参数怎样确定

项目先训练候选模型，再用验证集选择模型、温度、融合和阈值，最后固定配置进行测试。两个分类模型的调整后分数先取平均，再与检测分数加权组合；最终展开系数如下。（来源：划痕发布配置；齿部缺损发布配置）

表 7 最终融合系数及判定阈值

检测任务	EfficientNet 分数系数	ResNet18 分数系数	检测分数系数	判定阈值（约）
划痕	0.125	0.125	0.750	0.3003
齿部缺损	0.250	0.250	0.500	0.3413

这些系数来自有限候选比较，并非人为指定的缺陷重要程度，也不是各模型因果贡献。齿部缺损两个候选均得到 34TP、4FP，最终方案因 AUPRC 约 0.966 高于另一方案约 0.963 而入选，不能据此宣称全局最优。运行配置保留完整阈值精度，正文仅为阅读取近似值。

历史阈值流程优先满足验证误报率 $\leq$0.20，再提高召回率，并结合位置组表现等规则选择。Recall$\geq$0.95、FPR$\leq$0.20 缺少正式业务需求与成本测算依据，只作为**历史实验目标及选择约束**，不作为生产验收标准。训练损失中的 γ=1.5、齿部缺损正类权重 2 及 ROI 边界扩展 4% 等属于预先设定的参数，未通过独立实验证明最优；完整来源与选择规则见附录 B、附录 F。

4.3 同一测试集上的结果

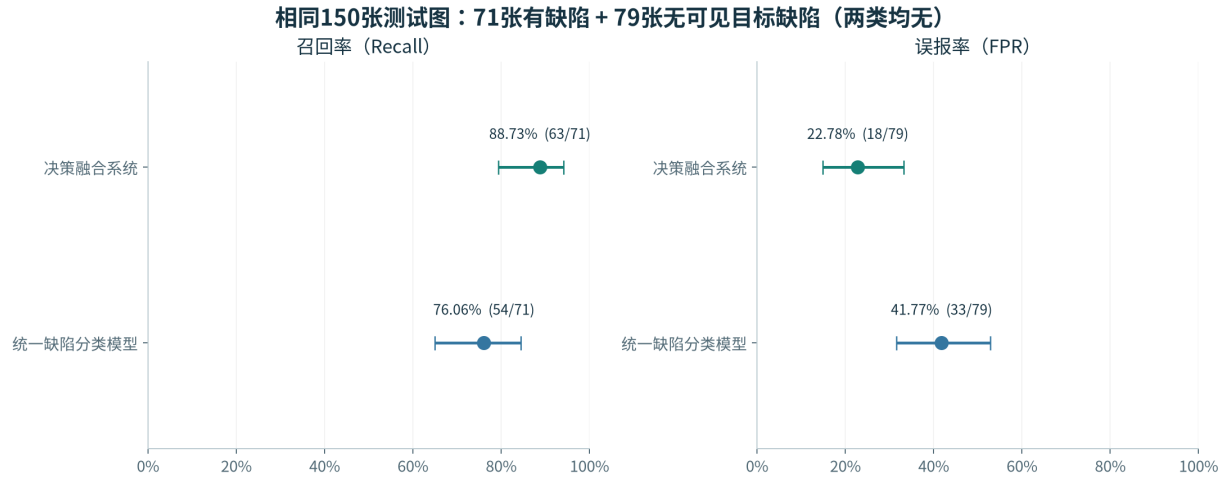


图 5 同一批 150 张图像、相同“任意缺陷”标签下的系统比较。误差线为按图像计数的 Wilson 95% 区间；工件内图像相关性未知，区间仅作描述性参考，不能据此判断差异具有统计显著性。（来源：齿部缺损及联合测试记录）

表 8 固定配置的图像级测试结果

检测方案	TP/FP/TN/FN	召回率	精确率	误报率
划痕检测	25/20/99/6	80.65%	55.56%	16.81%
齿部缺损检测	36/4/102/8	81.82%	90.00%	3.77%
两类结果合并	63/18/61/8	88.73%	77.78%	22.78%
统一缺陷分类模型	54/33/46/17	76.06%	62.07%	41.77%

前两行分别评价该类缺陷，其负样本中可能有另一类可见缺陷；后两行评价任意缺陷，负样本须无两类可见缺陷。因此只有后两行可直接比较。各类检测的误报约束也不能直接当作合并系统的误报约束。18/79 是图像误报计数，不是 18 个合格工件被误判；缺陷未进入画面属于观察覆盖问题，未计入当前图像级漏检。

验证和测试应分开解释：划痕验证召回为 42/43，测试为 25/31；齿部缺损验证为 34/34，测试为 36/44。两项测试召回均约 81%，低于用于选择配置的验证表现。选择偏差、拍摄条件和困难样本覆盖均可能影响差异，目前不能量化各因素贡献。

4.4 错误案例与使用取舍



图 6 两个划痕漏检和一个划痕误报案例。红框来自人工标注，模型分数来自固定配置的已有预测记录；局部放大不产生新的推理结果。“无划痕”不意味着无齿部缺损。（来源：划痕逐图预测与标注）

浅划痕及正常加工纹是下一步成像和识别的重点。齿部缺损的 8 张漏检中，7 张带有 oblique 位置标签，提示应重点检查这类缺陷的可见性；不能把标注位置直接等同于采购时的工件类型。

降低阈值可补检，却可能增加误报：历史划痕低阈值约 0.2038 对应测试召回约 93.5%、误报率约 58.8%。该记录用于解释取舍，不用于在旧测试集上重新挑选阈值。当前合并系统将 81/150 张图像标为疑似缺陷；尚未建立图像与工件对应及送复核规则，不能把这一比例当作工件送复核比例。研究数据中缺陷占 71/150，不能据此估计真实产线工作量，精确率也会随现场缺陷比例变化。[3]

5 项目贡献与后续验证

5.1 现阶段的项目贡献

本项目围绕两类外观缺陷分别探索标签、检测结构和分数组合：划痕采用 P2 配置并组合整体纹理与局部线索，齿部缺损采用单类标注的原始检测结构。验证对照中，划痕融合增加检出并减少误报，齿部缺损融合主要减少误报；这些是当前选型依据，不是新工件上的效果保证。软件将同次判断连接显示、统计与控制输出，形成原型应用链路。

这些工作采用主流网络和既有融合方法。现有证据支持当前图像上的方案选择，尚不足以证明算法首创、生产环境优势或对新齿轮的稳定泛化。尤其是检测框、图像判断和工件分拣应分别评价：图像检出缺陷不代表定位准确，也不代表对应工件已被正确分拣。

5.2 下一阶段优先回答的问题

表 9 下一阶段验证优先级

优先问题	后续验证
对新工件是否有效	建立齿轮编号，按工件与拍摄批次分组，用未参加训练的新齿轮测试
困难缺陷能否拍清	控制光照与观察角，记录原图、缺陷可见性和漏检变化
参数与模型组合是否必要	控制其他条件比较输入、权重、成员模型与校准，记录共同错误及资源开销
人工复核如何覆盖漏检	明确模型未检出工件的复核或抽查方式，测量确认比例和复核时间
NX 能否满足工件处理节拍	记录采集、定位、识别、传输与分拣对应关系，以及分项耗时和长时运行情况

当前尚未进行部署优化，也没有每件检测耗时记录，不设定未经测量的速度指标。下一阶段先完善工件来源管理、成像、复核和整机测量，再决定是否需要模型优化或更大参数搜索。详细验证建议与软件状态见附录 G。

附录 A 文献与证据的对应关系

表 10 文献支持与项目证据边界

文献	支撑内容	项目仍需提供的证据
[1] Raschka；[2] Cawley 与 Talbot	评价与选择区分，小样本选择风险	按工件分组划分数据、固定模型及判定参数、新数据评价
[3] Saito 与 Rehmsmeier	PR 解释及类别比例	实际缺陷比例及复核负担
[4] Guo 等	温度缩放与校准动机	校准前后质量、融合分数可靠性
[5] Tong 等；[6] Elkan	错误优先级、约束与成本	复核流程、成本和正式目标；当前无 NP 保证
[7] Bergstra 与 Bengio；[8] Snoek 等	后续搜索预算与昂贵实验选择	自身搜索过程及预算比较
[9] Shang 等	未来生产抽检与抽样校正	实际抽样记录；当前区间不源于该抽样法
[10]–[13] 模型与方法原始文献	骨干、多尺度与 Focal 机制	齿轮候选对照，具体参数值依据
[14] MVTec 官方资源	工业异常检测研究设定	自身正常样本多样性；本项目未使用该数据集
[15] Choi 与 Seong；[16] Kittler 等；[17] Wu 等	决策融合与分类器组合的已有用法	本项目自身的模型输出、融合公式及验证结果；文献不是历史参数来源

附录 B 关键固定训练参数与资料索引

表 11 固定训练参数摘要

参数组	Scratch V5	Missing Hole V1	来源性质
自定义分类初始化/输入	ImageNet；长宽比保留、灰色填充	同左；输入 384 或 512	外部初始化及工程输入设计
归一化	ImageNet mean/std	同左	预训练输入约定
自定义优化器	AdamW，lr=3e−4，weight_decay=5e−4	同左	脚本预先固定的参数
学习率调度	余弦，eta_min=1e−6	同左	脚本预先固定的参数
Focal 损失设置	γ=1.5，最终 w_pos=1	γ=1.5，w_pos=2	前者候选组合，后者固定
自定义 batch	384→24；512→12	同左	计算预算约束
检测输入	960	960；1280 候选未入选	实验变量
检测优化器	AdamW，lr0=7e−4，weight_decay=5e−4	同左	预先固定的参数
最终 TTA	无	无	验证选择

表 按《GearPro 综合实验与部署技术报告》第 8.3、9.4 节摘要；各实验的有效配置应结合对应 args/history 读取。检测结构、batch、增强与训练预算有版本差异，完整逐次表保留在综合报告。

项目事实说明。本报告中由项目负责人确认的内容包括：50 个齿轮工件构成、使用实际流水线工业摄像头人工摆拍多角度图像、按图像可见缺陷标注（确认不可见作为负样本，可见但难辨认或难标边界标为 difficult）、仅有图片顺序编号、明确缺陷均不合格、difficult 表示已确认存在但难辨认的缺陷、上下双相机、设备 NX、新模型简单测试未记录、人工复核方向与流程未定、软件/模型及硬件分工、历史目标无正式需求依据。

综合项目资料。GearPro 综合实验与部署技术报告，2026-10-03；其中第 17 节列明原始实验及阶段汇报来源。Git 的 main 分支中的阶段 PDF 作为历史状态补充，当前状态以项目负责人确认的信息更新。

表 12 实验资料与配置来源目录

资料名称	可核对文件	本文用途
划痕发布配置	V5 发布配置	成员、温度、融合、阈值、验证计数
齿部缺损发布配置	V1 发布配置	同上
划痕测试记录	V5 测试记录	测试计数、相似对提示
齿部缺损及联合测试记录	V1 及联合测试记录	检测任务、位置、OR 与统一模型
划痕数据清单	V5 数据清单	训练/验证拆分及缺少工件 ID 的状态
齿部缺损数据清单	V1 数据清单	各拆分、图像/标签及样例索引
划痕候选模型评价表	V5 候选模型评价表	划痕候选结果
齿部缺损候选模型评价表	V1 候选模型评价表	检测全因子及后续候选
齿部缺损融合候选评价表	V1 融合候选模型评价表	21 个融合候选及最终选择
划痕逐图预测与标注	V5 逐图预测及原图/XML	仅用于已记录错误的展示与解释
V3 测试与定位记录	V3 测试与定位记录	图像与区域两种评价、划痕计数差异
V4 初始基线记录	V4 初始基线记录	基线计数、指标与类别分组
V4 最终融合记录	V4 最终融合记录	融合计数、指标与类别分组
V4 发布配置	V4 发布配置	成员、增强及融合方式
V4 候选评价记录	V4 候选评价记录	扩展单模型验证阈值与增强方式
V4 详细技术报告	V4 详细技术报告	扩展单模型既有留出摘要及四路增强说明

图表由`build_report.py`读取上述记录生成，数值与来源汇总在`assets/chart_data.csv`，输入文件哈希和构建检查保存在`verification.json`。脚本只读取已有实验产物，不运行模型、不修改阈值。

附录 C 术语及方法名称

本报告采用中文名称，并在首次出现时给出英文或代码名。独立训练的网络称“成员模型”，两个面向同类缺陷的分类模型与一个目标检测模型构成“检测子系统”。方法名称按实际操作确定；有关名词的更完整说明见术语对照表。

表 13 术语与实际方法定义

中文名称	英文或代码名	本项目中的定义
齿部缺损	partial tooth damage；历史代码 missing_hole	齿侧或齿角等部位的局部缺失；不译为孔洞缺失
划痕检测子系统	Scratch V5	两个分类模型与一个目标检测模型的组合
齿部缺损检测子系统	Missing Hole V1	两个分类模型与一个目标检测模型的组合
分数级加权融合	score-level weighted fusion	对同类缺陷的模型分数进行加权平均
决策级融合	decision-level fusion	对两个子系统的二值判定进行合并
或规则	OR rule	任一子系统判为有缺陷，最终即判为有缺陷
温度缩放	temperature scaling	用正温度参数调整模型输出分数，参数根据验证集 NLL 选择
参考标注	ground truth annotations	人工标注的类别、边界框及困难目标标记
困难目标	difficult=1	确定存在缺陷但难以辨认的标注目标
正样本/负样本	positive/negative samples	含/不含当前任务可见目标缺陷的图像
精确率	precision	TP/(TP+FP)，与准确率 accuracy 不同
召回率	recall	TP/(TP+FN)，亦可解释为缺陷检出率
误报率	false positive rate	FP/(FP+TN)，与 FP/(TP+FP) 不同
预测为缺陷的样本比例	predicted-positive fraction	(TP+FP)/N；图像统计不能直接换算为工件送复核比例
目标级定位评价	object-level localization evaluation	基于预测框与标注框的匹配计算定位指标
初步实验	pilot experiment	以较低训练轮数上限比较候选配置
增加训练轮数上限的重新训练	retraining with a larger epoch limit	从预训练初始化重新训练，区别于从初步实验 checkpoint 接续训练
对照实验	comparative experiment	比较候选配置；多项因素同时变化时不解释为单因素效应
消融实验	ablation study	在控制其他条件下移除或改变某个组件，检验其作用；按实际设计使用

附录 D 数据检查与早期探索

正文的数据规模见第 1 章；以下保留构成、标注、拆分及早期方案的详细说明。

D.1 工件构成与位置标签

项目共有 50 个齿轮工件：正常 10 个，划痕 15 个，侧部缺损 15 个，齿角缺损 10 个。工件由项目自行采购或定制，采用上下、旋转、侧面等多个角度拍摄。

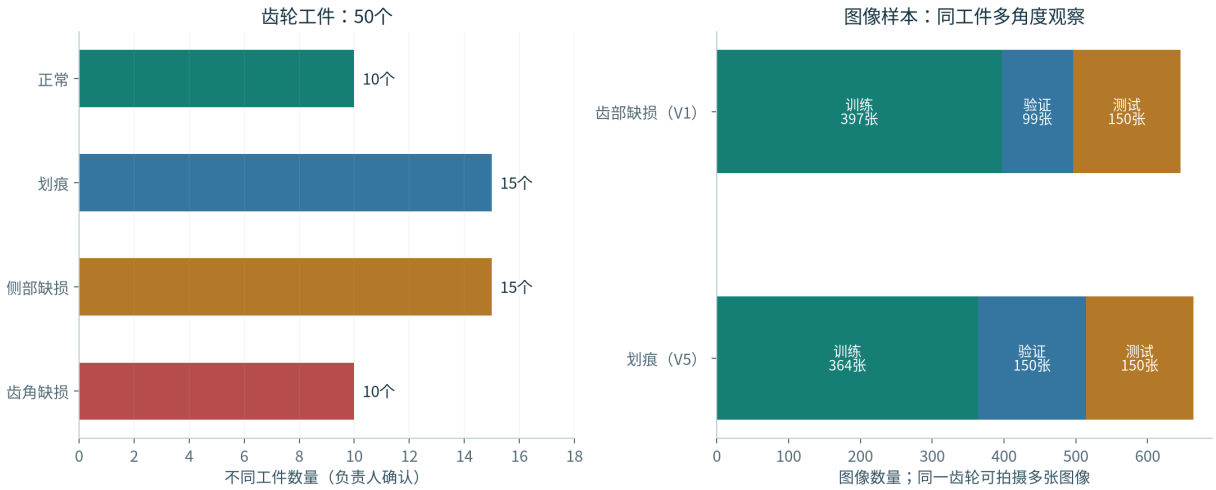


图 7　左侧为负责人确认的齿轮工件构成，右侧为两类缺陷的数据清单中的图像数量。多角度拍摄增加观察条件，不增加不同齿轮工件数量；图像尚未可靠对应到具体工件 ID。（来源：项目事实说明；划痕数据清单；齿部缺损数据清单）

需要区分三个概念：工件的缺陷类型、采集时的观察角度、XML 中的位置标签。采购时的“侧部缺损/齿角缺损”不能直接等同于 V1 的 bottom/oblique/side 标注，也不同于其他版本按宽高比推断的视角。本文保持原始定义，不自行建立未经核对的映射。

D.2　数据规模与类别定义

表 14　数据规模及各任务正负样本定义

检测任务	训练图	验证图	测试图	正负样本定义
Scratch V5	364	150	150	有可见划痕 / 无可见划痕
Missing Hole V1	397	99	150	有可见齿部缺损 / 无可见齿部缺损

表　训练、验证数量来自清单（来源：划痕数据清单；齿部缺损数据清单），测试计数来自（来源：划痕测试记录；齿部缺损及联合测试记录）。两个检测子系统使用同一批 150 张测试图，但负样本定义不同。V1 排除困难目标后的训练集另有 391 张图。

150 张测试图中，划痕 31 张、齿部缺损 44 张、二者同时存在 4 张，因此含至少一类缺陷的图像为 71 张，无可见划痕或齿部缺损的图像为 79 张。无划痕图可能具有齿部缺损，无齿部缺损图可能具有划痕；两个检测子系统 FPR 的分母不能直接用于联合 FPR。

缺少某类标注不能自动解释为不含该类缺陷。统一模型的数据构建曾排除 59 张划痕状态未知且无齿部缺损的候选图像，保留类别状态已确定的数据。（来源：《GearPro 综合实验与部署技术报告》第 10.1.2 节）

D.3　近重复检查与工件划分限制

历史实验使用 SHA256、dHash、序号、宽高比及灰度相关性等方法识别相同或近重复图像，并据此审计拆分。当前只有图片顺序编号，清单没有可靠的图像与 50 个齿轮工件的对应关系，无法确认同一齿轮的不同角度是否跨训练、验证和测试。（来源：项目事实说明；划痕数据清单；齿部缺损数据清单）

项目负责人认为独特缺陷形态可用于辨识部分工件；正常工件及缺陷不可见的照片无法可靠辨识。本轮没有恢复或改写工件对应关系，完整工件独立性仍未知；只检查可辨识照片，未发现交叉也不能证明全体独立。

V5 测试记录未发现字节级重复，但存在 75 个 dHash≤2 跨集合相似对（来源：划痕测试记录）。相似外形和背景可能触发这些提示，尚不能直接认定泄漏；结合工件编号缺失，当前测试结果仅反映所评价图像上的表现，以及已执行的近重复图像检查结果。报告保留“固定模型、温度、融合权重及阈值后评价”的流程记录，按工件划分数据的独立性仍待确认。

这一区分直接影响结论力度：测试图上的检出能力，尚不能自动转为新采购齿轮、不同批次或新生产线的泛化能力。后续采集应为每个齿轮工件建立 ID，其所有角度、照明和连续帧进入同一数据组。

D.4 训练、验证与测试职责

训练集用于更新网络参数；验证数据用于选候选、温度、融合及阈值；测试记录用于配置固定后的结果评价。测试一旦查看，后续调整需要新的开发数据和新的未查看测试，而现有集合可保留为历史回归集。[1][2]

本报告在现有证据上解释结果，不重新训练或调整运行阈值。多个阶段的数据和标签不同，跨版本仅讨论设计认识，不将各版指标连成同一条性能提升曲线。

D.5 早期方案与转向依据

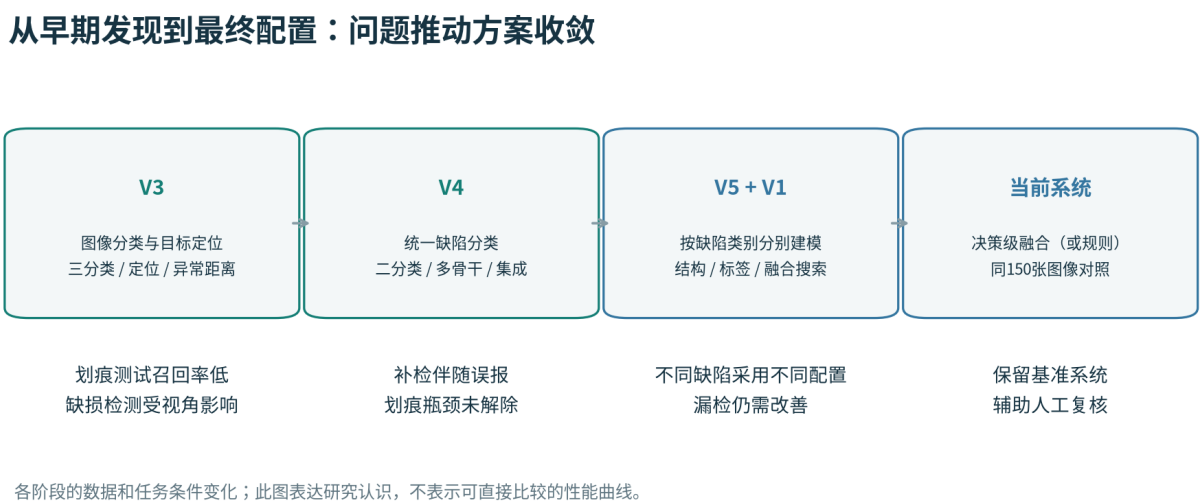


图 8 V3/V4 提供研究转向依据，V5/V1 承担重点技术探索。该图表示问题和设计演进，非同一数据上的性能趋势。（来源：《GearPro 综合实验与部署技术报告》第 3、6–10 节）

V3 用分类模型区分正常、划痕与齿部缺损，并用独立模型定位缺陷，并尝试增强、P2 和正常特征距离。它揭示低对比划痕与不同视角下的齿部缺损的困难，也建立了判定与定位分别评价的框架。V4 将两类合并为“至少一类缺陷”，探索多模型、纹理和集成。（来源：《GearPro 综合实验与部署技术报告》第 6–7 节）

V4 最终留出测试集的结果为正确检出 19/30 张缺陷图像、误报 7/20 张无可见目标缺陷图像；11 个漏检中 7 个来自划痕。模型组合补检了部分缺陷，也增加了误报，划痕漏检仍是主要问题。后续因而针对划痕与齿部缺损分别组织数据、检测结构及判定规则。V4 曾用第一次留出结果判断扩

展方向，本文明确说明该留出测试集曾用于指导后续实验，不能视为始终未查看的最终测试集。（来源：《GearPro 综合实验与部署技术报告》第 7.7 节）

D.6 V3 划痕定位计数的未解释差异

原始测试 JSON 的划痕图像分类检出 4/11 张；整体定位评价记录 TP=0、FP=6、FN=19。另一个按视角逐框匹配的结果在 oblique 组、IoU=0.5 时记录 TP=1、FP=5、FN=9，其他视角 TP=0。（来源：V3 测试与定位记录）两套定位计数不能相加或互相替换，差异原因尚未核清。因此正文采用齿部缺损数据解释图像判定与定位的任务区别，不作“划痕完全无法定位”的结论。

D.7 V4 新增比较的配置与资料来源

表 15 V4 配置与历史结果来源

正文名称	实验或配置	验证选择阈值（约）	留出指标来源
基线模型	`p_resnet18_512_w4`；四路增强	0.640567	基线 JSON 的 test.overall V4 初始基线记录
扩展单模型	`xfull_resnet18_384_w1_s73_r1`；四路增强	0.571126	详细报告 §7.2 历史测试摘要V4 详细技术报告；阈值及增强另核对候选 JSON V4 候选评价记录
三模型融合	三个分类成员，分别四路增强，分数取最大值	0.702842	最终 JSON 的 test.overall V4 最终融合记录；发布配置V4 发布配置

扩展单模型的验证 AUPRC 约 0.860，正文表中的 0.899 是详细报告记载的既有留出 AUPRC，不能混用；该留出摘要本轮没有逐图预测重算证据。这里保留已有记录，不运行模型或重选阈值。

基线与最终融合的划痕召回均为 4/11；齿部缺损分别为 13/19 和 15/19。两个增加的检出计数来自齿部缺损，但尚未按逐图集合确认哪些图像被补检或丢失。前向次数 4 与 12 是配置推导，不是现场计时；所有结果仍受既有留出反馈、样本规模和工件划分限制。

附录 E 候选实验与未采用配置

E.1 划痕候选与比较限制

问题与假设。图像分类可以识别纹理变化，却可能受加工纹和高光影响；目标检测可以预测局部缺陷区域，但定位并不总可靠。划痕检测实验比较两类模型的输出能否共同改善图像级分类结果。

对照设计。正式记录包含 6 个分类模型初步实验、2 个目标检测模型初步实验和 2 个增加训练轮数上限的分类模型重新训练实验。初步分类实验比较 ResNet18、EfficientNet-B0、YOLO 分类器及 384/w1、512/w2 配置；目标检测实验比较 960 输入的原始 YOLO26n 与包含 P2 检测层的模型。实验还比较是否使用测试时增强（test-time augmentation，TTA），随后进入温度参数与融合规则选择。（来源：《GearPro 综合实验与部署技术报告》第 8 节；划痕候选模型评价表）

原始 YOLO26n 检测模型的召回率为 38/43、FPR 为 21/107，P2 对应 38/43 和 19/107；精确率–召回率曲线下面积（AUPRC）约 0.828 与 0.866。在相同召回率下，P2 误报更少，排序指标更高，进入最终组合。最终分类成员为增加训练轮数上限后重新训练的 EfficientNet-B0 与初步实验中的 ResNet18，两者 384 输入、w1、无 TTA。（来源：划痕发布配置；划痕候选模型评价表）

设计认识。当前结果支持选择 P2 配置，但原始 YOLO26n 与包含 P2 检测层的模型采用不同批量大小（batch size），因此该对照未单独隔离结构变化的影响。384/w1 与 512/w2 同时改变输入和权

重，也不能单独断言 w2 或 512 必然较差。融合方案的验证结果支持该模型组合，成员模型的错误互补情况还需要统计各模型在同一图像上的共同错误，并通过消融实验验证。

P2 模型的预测框最大置信度可用于图像分类，与准确定位是两个结论。原报告在 IoU=0.3 匹配中记录大量 FP，框仅作辅助线索。（来源：《GearPro 综合实验与部署技术报告》第 8.8–8.9 节）

E.2 齿部缺损候选与选择规则

问题与假设。齿部缺损在不同位置有不同外观。细分位置标签可能帮助学习，也可能分散有限监督；困难目标的保留或排除影响训练标注的组成。V1 用交叉矩阵比较这些选择。

对照设计。初步目标检测实验采用三类/两类/单类 × 保留/排除困难目标 × 原始 YOLO26n/包含 P2 检测层的模型，共 12 组，统一 960 输入和 35 轮训练上限。随后进行 12 个初步分类实验、增加训练轮数上限的重新训练、第二个随机种子的验证、1280 输入对照及困难样本重采样与 CLAHE 增强实验，总计 34 个实验记录。（来源：《GearPro 综合实验与部署技术报告》第 9 节；齿部缺损候选模型评价表）

三类标注区分 bottom/oblique/side，两类合并 bottom 与 oblique，单类将位置归为一个齿部缺损目标。单类、排除困难目标的原始 YOLO26n 模型与包含 P2 检测层的模型均检出 33/34，原始 YOLO26n 检测模型误报 6/65，P2 误报 13/65。采用单类标注的原始 YOLO26n 模型以较低误报成为入选方向，说明细分标签或增加高分辨率特征层并未自动改善判定。

exclude_difficult 只修改训练集：删除 21 个困难目标的标注框，6 张仅含困难目标的图像整体排除，训练图 397→391、框 498→477。这样避免把已知缺陷图误当作负样本；验证与测试保留完整参考标注。（来源：《GearPro 综合实验与部署技术报告》第 9.3 节）

最终 EfficientNet 采用 512、排除仅含困难目标的训练图像，ResNet18 采用 384、保留困难目标，检测器采用单类标注的原始 YOLO26n 模型、960、排除困难目标。不同成员保留不同训练配置；它们的互补程度仍需逐图对照。（来源：齿部缺损发布配置）

选择规则带来的取舍。最终检测模型采用初步实验保存的权重。增加训练轮数上限后重新训练的模型具有相同总体召回率和 FPR，选择规则先比较各位置组中的最低召回率：初步实验约 0.917，重新训练约 0.909，随后才比较 AUPRC。因此按既定规则选择初步实验模型。这个小差别对应很少样本，体现规则遵守，不证明初步实验模型具有稳定的统计优势。（来源：《GearPro 综合实验与部署技术报告》第 9.11 节）

E.3 未采用配置

表 16 未采用配置及已有观察

探索	预期作用	现有观察与选择
V4 纹理三通道	强调亮度、局部对比和边缘	已有比较未支持替换 RGB 输入，最终方案保留 RGB
V5 四路 TTA	减轻外观变化	最终模型未采用测试时增强
V1 1280 输入	增加局部细节像素	所比较的重新训练配置该对照未支持替换最终模型，输入规模更大
V1 困难样本重采样与 CLAHE 增强	改善困难区域的学习	未替换当前最终检测器
V1 增加训练轮数上限后的重新训练	更充分拟合数据	最低位置组召回率的排序未优于初步实验模型，虽 AUPRC 更高

表 依据《GearPro 综合实验与部署技术报告》第 7–9 节。结论针对已有配置与数据；保留这些实验，是为了说明方案怎样收敛，而非宣称相应方法在所有场景无效。

附录 F 参数选择与补充结果

F.1 训练参数、采样与框架配置

分类网络从 ImageNet 预训练参数初始化，替换输出层后训练；YOLO 采用官方初始化或框架 P2 配置加载可迁移权重。最终 checkpoint 来自对应训练实验的保存及验证选择，并不是人为给每层设一个“识别权重”。（来源：《GearPro 综合实验与部署技术报告》第 8–9 节）

自定义分类器使用 Focal BCE：$L = \text{mean}[w_y(1-p_t)^\gamma \,\text{BCE}(z,y)]$，其中`p_t`为真实类别的预测分数。Focal 机制降低易样本的损失权重，方法动机来自 Lin 等 [13]；项目 γ=1.5 为预先固定的参数。V5 在组合候选中比较 w1/w2，最终分类器 w1；V1 正类权重 2 在本轮固定，没有独立网格证明其最优。

逆频率采样 $w_i = 1/n_{(\text{label, view or position})}$ 改变样本出现频率，与损失权重是不同机制。FN×3、FP×2 难例乘数为脚本设定；V5 本轮实际额外加权仅一张训练 FP，不能据策略存在就宣称困难样本学习带来主要收益。（来源：《GearPro 综合实验与部署技术报告》第 8.5 节）

YOLO 分类候选的 w2 通过复制正类文件改变训练经验分布，并非直接给其分类损失乘以 2。检测 args 记录 box/cls/dfl 配置 7.5/0.5/1.5，属于框架配置，未独立消融；通用字段是否实际生效须结合任务实现和 loss 日志解释。（来源：《GearPro 综合实验与部署技术报告》第 5.2、8.5、9.1 节）

F.2 温度参数选择

项目将原始分数 p 转换为 $\text{logit}(p) = \ln[p/(1-p)]$，计算 $p_T = \text{sigmoid}(\text{logit}(p)/T)$。温度 T 在 [0.35,4.00] 的 147 个等距候选中，以验证 NLL 最小选择，边界分数按发布实现处理。（来源：《GearPro 综合实验与部署技术报告》第 5、8.3.4 节）

温度缩放借鉴 [4]。正温度保持单个模型的样本分数排序，因此不能独立提升该成员模型理想排序下的 AUROC/AUPRC；它可以改变融合中的相对尺度。当前做过温度选择，校准质量及融合概率可靠性仍需要校准前后 NLL、可靠性图与分箱样本量评价。

F.3 融合公式、候选与完整阈值

将两个分类模型经温度缩放后的分数先取平均 $c = (s_{\text{Eff}} + s_{\text{Res}})/2$，再比较 $f_\alpha = \alpha c + (1-\alpha)s_{\text{det}}$，$\alpha \in \{0.25, 0.50, 0.75\}$，同时比较单模型、分类分数平均/最大值及与检测模型分数取最大值的方案。V5 记录 20 个融合候选规则，V1 保留 21 个候选成绩。（来源：《GearPro 综合实验与部署技术报告》第 8.2、9.6 节；齿部缺损融合候选评价表）

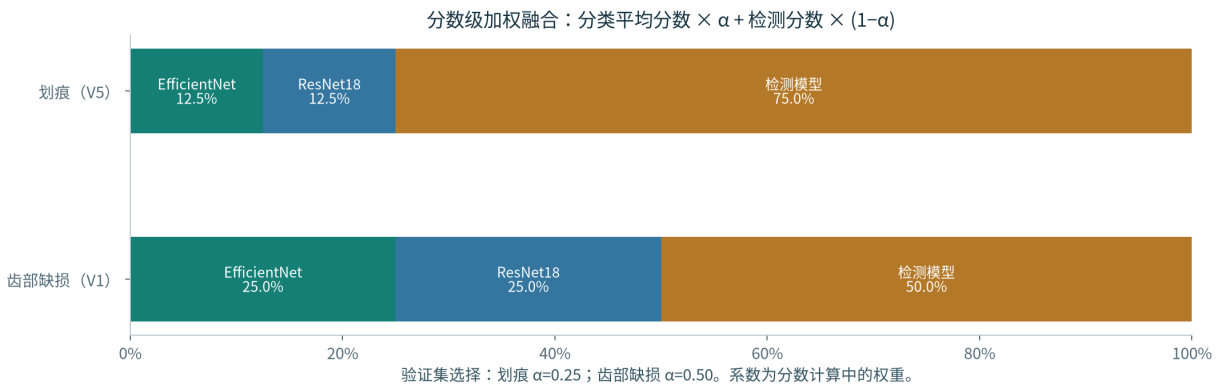


图 9 发布配置（来源：划痕发布配置；齿部缺损发布配置）中的融合公式展开。划痕 α=0.25，所以分类器分别 0.125、检测器 0.75；齿部缺损 α=0.50，所以分类器分别 0.25、检测器 0.50。系数表示分数计算规则，不能解释为因果贡献或定位精度。

表 17 最终成员系数、温度及阈值

检测任务	分类模型 1：EfficientNet	分类模型 2：ResNet18	目标检测模型	温度参数 T（同序）	判定阈值（展示值）
划痕 V5	0.125	0.125	0.750	0.700/2.050/2.125	0.3003
齿部缺损 V1	0.250	0.250	0.500	1.000/2.375/1.850	0.3413

V1 最终将分类平均分数与检测分数等权融合的方案，与仅使用 EfficientNet 分类分数并赋予其 0.25 权重的方案，均为 34TP、4FP；其 AUPRC 分别约 0.966 和 0.963，前者在优先评价指标相同时，按 AUPRC 排序被选中。（来源：齿部缺损融合候选评价表）这为 0.50 提供了选择记录，而非全局最优或稳定优势证明。

部署使用 JSON 完整精度：划痕阈值 0.300273610279458，齿部缺损阈值 0.3413327979078584。正文四位小数方便阅读，运行时不据正文舍入重建阈值。（来源：划痕发布配置；齿部缺损发布配置）

F.4 阈值选择与两类结果合并

历史流程在固定候选分数上扫描验证阈值，优先满足 FPR≤0.20，再最大化 Recall，随后按项目规则比较位置、FPR 和 AUPRC 等量。齿部缺损流程特别考虑各位置组中的最低召回率，图像选择目标与基于边界框匹配的 mAP 不同。（来源：《GearPro 综合实验与部署技术报告》第 8.3.4、9.2 节）

Recall≥0.95、FPR≤0.20 没有正式产线需求或成本测算依据，本文将其保留为**历史实验目标及选择约束**。0.20 解释当时阈值如何被选出；0.95 解释历史目标，不作为本项目当前生产验收标准。结果继续保留真实数值，评价重点转向检出能力及人工复核负担。

决策级融合采用或规则：$\mathrm{REJECT} = (s_{\mathrm{scratch}} \geq \tau_{\mathrm{scratch}}) \vee (s_{\mathrm{missing}} \geq \tau_{\mathrm{missing}})$。这里 OR 表示逻辑或：任一检测子系统判为有缺陷，最终即判为有缺陷。两个子系统的分数针对不同缺陷，负样本定义和温度参数估计所用的数据不同，因此分别进行阈值判定，再合并二值结果。每个任务的 FPR 约束不自动成为融合系统的 FPR 约束，不含这两类缺陷的图像上的误报需单独统计。工业外观检测已有采用缺陷类别独立建模与或规则决策融合的研究 [15]；该文献用于方法命名及相关工作比较，不是历史参数来源。

F.5 复核评价框架

漏检优先的使用方向需要同时呈现：**主指标召回率，配套指标误报率、精确率和预测为缺陷的样本比例**。对同一集合，预测为缺陷的样本比例为 $q = (\mathrm{TP} + \mathrm{FP})/N$，它在当前记录中只表示图像预测比例。只有评价单位与工件一一对应，且全部疑似工件送复核时，才等于工件送复核比例；多视角图像不能直接作此换算。

表 18 人工复核评价框架

评价问题	当前可以给出的证据	尚需明确的信息
有多少缺陷漏检	FN 计数、总体及困难目标所在图像的 Recall	被判为无缺陷的工件是否复核或抽查
正常件增加多少检查	FP 计数和 FPR	人工复核时间、处理能力
一共需要检查多少件	当前数据上的预测为缺陷的样本比例	真实缺陷比例、复核流程
应选择哪个判定阈值	历史阈值对应的验证结果及误差分析	两类缺陷标签完整的新开发数据、可接受漏检与复核负担

成本敏感和优先错误约束提供目标制定思想 [5][6]，不能直接给出新的合格百分比。当前权重和阈值维持历史配置，今后在流程明确后用新的开发数据选择判定阈值，旧测试留作回归。

F.6 参数来源完整表

表 19 参数来源完整表

参数	采用值/方法	来源类型与证据
网络参数	预训练初始化后微调	外部初始化＋对应训练实验保存
分类骨干与输入	V5 两个分类模型均为 384；V1 为 512/384	验证候选选择；V5 输入与 w 同时变化
检测结构	V5 含 P2 检测层；V1 单类原始 YOLO26n	两类任务分别对照；batch 等条件仍有差异
Focal 聚焦参数 γ / V1 正类权重	1.5 / 2	预先固定的训练参数，未独立消融
采样与难例乘数	逆频率；FN3、FP2	预先设定的采样规则，实际使用范围见附录 F.1
温度参数	每个检测子系统的三个成员模型分别估计 T	验证 NLL 估计，数值见划痕发布配置；齿部缺损发布配置
融合系数	α=0.25/0.50	验证有限候选搜索与均值展开
判定阈值	约 0.3003/0.3413	固定融合的验证扫描
ROI 裁剪边界扩展	4%	实现设定，未独立消融
候选框保留下限 / NMS IoU	0.001 / 0.7	推理配置；不同于判定及框显示门槛
学习率、优化器、增强范围	各训练脚本预先设定的值	完整归档见附录 B，未逐项证明最优

F.7 验证与测试差异

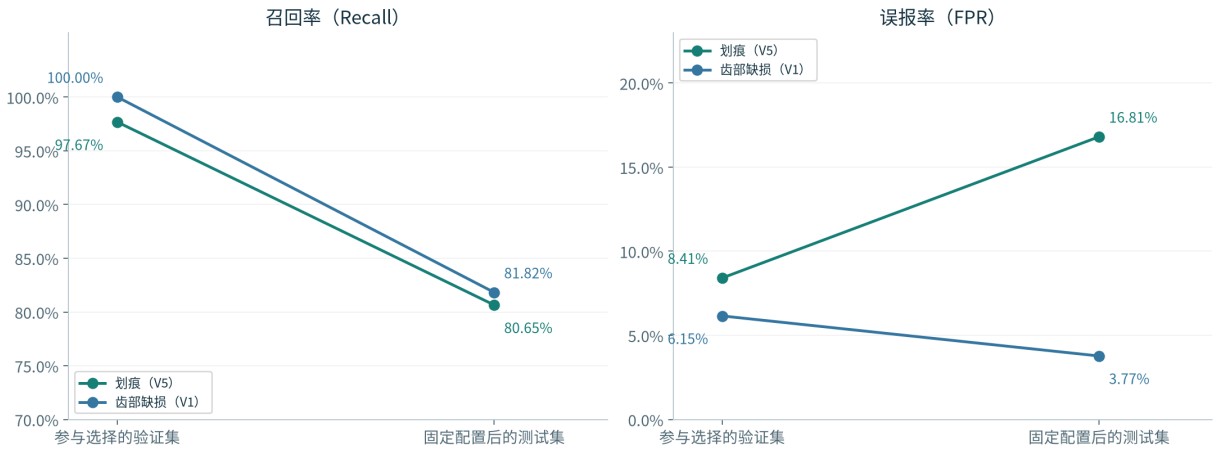


图 10 每条线连接同一缺陷类别的验证与测试指标。两任务分母不同；验证参与多层选择，线条不表示时间上的退化。数据来自（来源：划痕发布配置；齿部缺损发布配置；划痕测试记录；齿部缺损及联合测试记录）。

划痕验证集正确检出 42/43、误报 9/107，测试集正确检出 25/31、误报 20/119；齿部缺损验证集正确检出 34/34、误报 4/65，测试集正确检出 36/44、误报 4/106。测试召回均约 81%，明显低于参与选择的验证表现。

差异可能涉及验证选择偏差、拍摄条件变化和困难样本覆盖不足，当前数据不能量化各因素贡献。按图像计数的 Wilson 95% 召回区间：划痕约 63.7%–90.8%，齿部缺损约 68.0%–90.5%；同一工件图像间的相关性未知，区间仅作描述性参考。

F.8 位置分组结果

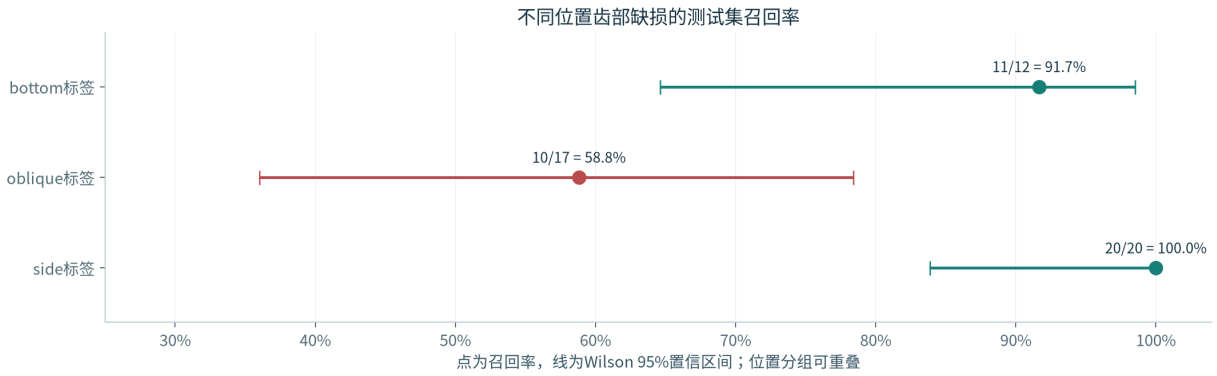


图 11 bottom 为 11/12、oblique 为 10/17、side 为 20/20。位置分组可重叠，数量之和 49 大于 44，不能相加算总体召回；区间按图像计数推导。（来源：齿部缺损及联合测试记录）

齿部缺损 8 个漏检中 7 个属于 oblique，说明这类位置是当前采集和可见性检查的重点。side 的 20/20 也应结合样本量理解。包含困难目标、忽略困难目标和仅评价非困难样本这三种条件下，召回率均约 0.81，困难目标标记并不能充分解释测试结果下降。（来源：《GearPro 综合实验与部署技术报告》第 9.7 节；齿部缺损及联合测试记录）

F.9 缺陷比例与复核负担

联合测试可见目标缺陷图像比例 71/150，是富含缺陷的研究数据，不代表生产线。假设可见缺陷图像的召回率和无可见目标缺陷图像的误报率保持不变，Precision $= \pi R/[\pi R + (1-\pi)\mathrm{FPR}]$，预测为缺陷的样本比例为 $q = \pi R + (1-\pi)\mathrm{FPR}$，$\pi$ 为应用条件下的可见目标缺陷图像比例，并非整件缺陷率。[3]

由此，论文与实验不能单凭 77.78% 测试 Precision 证明生产复核可靠性。下一步需分别测量应用图像与工件的缺陷比例、被判为无缺陷的工件中的漏检情况、疑似缺陷工件的人工确认比例与复核时间，再确定适用的判定阈值。当前可确认的是研究图像上的计数，人工复核效果未测量。

F.10 合并结果的类别解释与划痕分组统计

齿部缺损检测本身检出 36/44 张正样本；两类结果合并后，这 44 张图像中有 41 张被标为疑似缺陷。其中 5 张由划痕检测判为有缺陷，不能据此将齿部缺损检测的正确检出数改为 41。（来源：齿部缺损及联合测试记录）

历史划痕分析中，漏检组的分类模型平均分数约 0.455、检测模型平均分数约 0.144；误报组的分类模型平均分数约 0.814。结合图像外观，加工纹和高光是值得检查的误报来源，但分组均值不能直接解释每张图像的错误原因。（来源：《GearPro 综合实验与部署技术报告》第 8.6.3 节）

F.11 正文新增单模型与融合对照的完整记录

下表均为同一任务验证集、既有 FPR≤0.20 选择规则下各方案的工作点。α 表示分类分数系数，检测分数系数为 $1-\alpha$；两个分类分数均值作为一项时，共有三个成员。候选采用各自阈值，不能解释成阈值固定的组件移除实验。划痕发布配置未给出最终融合 AUPRC，此处不补造。

表 20 单模型与融合完整验证记录

任务	实验名／配置	组合规则	TP ／ FP	完整阈值	AUPRC	来源
划痕	f_efficientnet_b0_384_w1_s20260911	单模型	41 ／ 13	0.542919409017341	0.893870	候选评价表
划痕	p_detector_p2_960	单模型	38 ／ 19	0.18610403292287162	0.866130	候选评价表
划痕	发布配置中的两个分类模型及 P2 检测模型	分类均值与检测分数加权，α=0.25	42 ／ 9	0.300273610279458	未载明	发布配置
齿部缺损	f_cls_efficientnet_b0_512_exclude_difficult_s20260913	单模型	34 ／ 6	0.3809993863105774	0.924740	融合候选评价表
齿部缺损	p_det_one_class_exclude_difficult_standard_960	单模型	33 ／ 6	0.12059450038989711	0.944733	融合候选评价表
齿部缺损	classifier_mean	两个分类分数均值	34 ／ 5	0.5251138191759659	0.894532	融合候选评价表
齿部缺损	weighted_f_cls_efficientnet_b0_512_exclude_difficult_s20260913_0.25	EfficientNet 与检测分数加权，α=0.25	34 ／ 4	0.20599650265366867	0.963388	融合候选评价表
齿部缺损	weighted_classifier_mean_0.5	分类均值与检测分数加权，α=0.50	34 ／ 4	0.3413327979078584	0.965955	融合候选评价表

单模型与融合的逐图补检／丢失样本尚未在本轮核对，计数差是净变化。齿部缺损两模型与三模型的 34TP、4FP 相同，不代表预测图像集合相同，也不证明两者部署代价或稳定性相同。当前配置维持不变，成员必要性与 NX 开销仍待验证。

附录 G 软件、整机状态与后续测量

G.1 软件输出链路

项目负责人承担软件与模型工作，成员承担硬件、现场部署等后续工作。软件以采集和推理线程处理图像，Model1 生成 ROI 后执行两个检测子系统，结果保留成员模型分数、实际阈值、预测的缺陷类别、预测框及耗时。

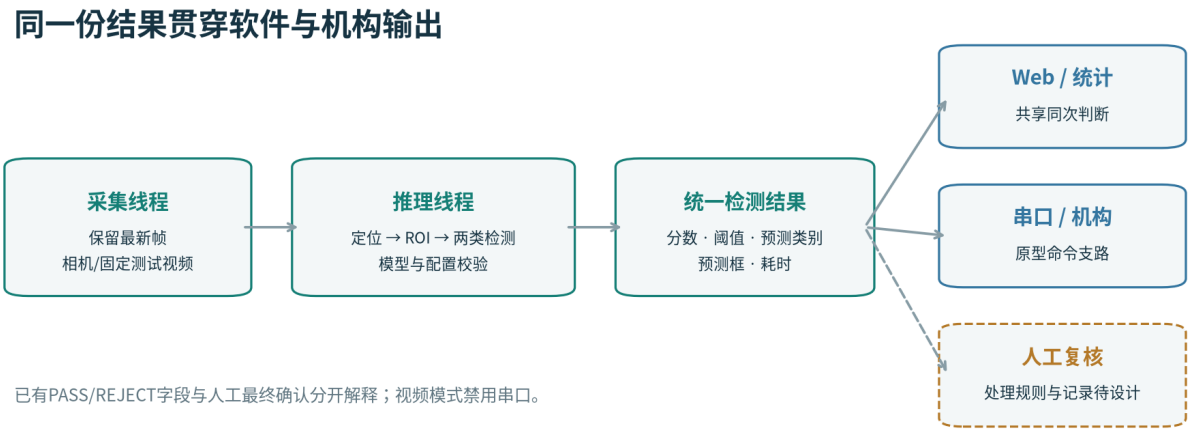


图 12 阶段材料记载的软件链路：同次结果供页面、统计与串口共享；原型分拣支路已打通，人工复核规则及记录尚待设计。结构图据《GearPro 综合实验与部署技术报告》第 13 节及负责人确认绘制。

统一检测结果对象（代码名称 Observation）使页面、统计和串口使用同一次判断，避免多处阈值逻辑不一致。模型加载时校验配置、版本和文件哈希，暂停恢复复用模型。必要检测子系统运行失败或分数非法时停止有效检测输出，避免错误路径产生有效通过结果。（来源：《GearPro 综合实验与部署技术报告》第 13 节）

G.2 原型状态

当前硬件仍为上下两台工业相机的旧方案，设备已经升级为 NX；新模型只做过简单现场测试，未记录测试数据。第一代实物完成输送、采集、显示与分拣链路，表示原型功能可连接，不代表当前模型已经经过完整现场验收。

历史最新帧策略与 5 秒重复计数抑制间隔可以限制积压和重复统计，但仍需工件级验证；一帧多个齿轮时的整帧结果，也不同于每个齿轮工件独立分拣。当前没有完整跨帧工件 ID 追踪、检测时间和分拣对应测量。（来源：《GearPro 综合实验与部署技术报告》第 13.1–13.4 节）

表 21 软件与原型状态

内容	当前状态	报告中的证据层级
自建数据与标注	已完成多角度拍摄，图像与工件的对应关系未建立	项目负责人确认＋图像与标签清单
V5/V1 离线模型	已有配置、权重索引与测试记录	配置及 JSON/CSV
Web、统计与串口	已实现统一结果链路	阶段材料记载的实现
上下双相机、NX、机构	第一代原型链路	实物与负责人确认
当前模型 NX 现场测试	简单测试，未记录数据	功能尝试，缺系统性能测量
人工复核流程	应用方向已明确，流程未定	设计需求
部署优化与节拍	尚未开展相应模型优化及时间考虑	后续测量与优化

G.3 整机测量

后续从相机原帧记录定位、ROI、缺陷判定、串口命令和实际分拣，将漏定位、未处理、错配、迟到及未执行纳入统计。各层级分别定义分母，避免仅在成功 ROI 上计算精度。

NX 测试先保持发布配置，记录取帧、定位、各成员模型、后处理和传输时间，以及温度、资源及长时运行；再决定是否需要 FP16 或其他优化。当前未确定每件处理窗口，本报告不设造 FPS 或毫秒指标。

G.4 后续实验与评价方法

表 22 后续实验与评价方法

待回答的问题	拟开展验证	主要输出
对新齿轮是否有效	建立工件 ID；按工件和拍摄批次分组，采集训练中未见的齿轮	新齿轮工件测试及样本构成
哪些缺陷实际拍得清	固定工件与相机，逐项比较照明、观察角和载台	原图、可见性、定位与困难子组变化
V5 输入与权重各自作用	同拆分和骨干，384/512×w1/w2	解耦后的候选与波动
成员模型校准和融合是否必要	固定成员模型参数，独立校准/开发比较，保存错误交集	NLL、可靠性图、识别收益与开销
复核流程怎样减少漏检	明确被判为无缺陷的工件处理、复核能力与新的判定阈值	Recall、FPR、确认比例及复核时间
NX 是否满足真实节拍	完整原型记录分项耗时和工件命令对应	时延分布、覆盖、资源与稳定性

大搜索空间可将随机搜索作为预算基线 [7]，昂贵训练可考虑贝叶斯优化 [8]；这两种方法在当前流程中尚未实施。优先级是数据来源和实验问题明确，再选择搜索工具。

上线后如缺陷稀少、标注预算有限，可参考 Shang 等按预测结果分层抽样并校正 P/R 估计的研究 [9]。这涉及测试抽样，与训练正类复制不同；实际流程需包含被判为无缺陷的工件抽查，才能评价漏检。

参考文献

[1] Raschka S. Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning. arXiv:1811.12808, 2018; v3, 2020. 预印本/综述教程，非正式同行评审论文。

[2] Cawley G C, Talbot N L C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. JMLR, 2010, 11:2079–2107.

[3] Saito T, Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 2015, 10(3):e0118432.

[4] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks. ICML, PMLR 70, 2017:1321–1330.

[5] Tong X, Feng Y, Li J J. Neyman-Pearson Classification Algorithms and NP Receiver Operating Characteristics. Science Advances, 2018, 4(2):eaao1659. 作者机构全文。

[6] Elkan C. The Foundations of Cost-Sensitive Learning. IJCAI, 2001:973–978.

[7] Bergstra J, Bengio Y. Random Search for Hyper-Parameter Optimization. JMLR, 2012, 13:281–305.

[8] Snoek J, Larochelle H, Adams R P. Practical Bayesian Optimization of Machine Learning Algorithms. Advances in Neural Information Processing Systems 25, 2012.

[9] Shang H, Langlois J M, Tsioutsiouliklis K, Kang C. Precision/Recall on Imbalanced Test Data. AISTATS, PMLR 206, 2023:9879–9891.

[10] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016:770–778.

[11] Tan M, Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML, PMLR 97, 2019:6105–6114.

[12] Lin T Y, Dollár P, Girshick R, He K, Hariharan B, Belongie S. Feature Pyramid Networks for Object Detection. CVPR, 2017:2117–2125.

[13] Lin T Y, Goyal P, Girshick R, He K, Dollár P. Focal Loss for Dense Object Detection. ICCV, 2017:2980–2988.

[14] MVTec Software GmbH. MVTec AD 工业异常检测数据集官方说明. 在线数据集资源，访问日期 2026-10-06；用于研究设定说明，项目未以该数据集训练。

[15] Choi K J, Seong J T. A Decision-Level Fusion Hybrid Deep Learning Framework for High-Precision Automated Optical Inspection of VCSEL Semiconductor Devices. AIMS Mathematics, 2026, 11(5):14487–14521. DOI:10.3934/math.2026594.

[16] Kittler J, Hatef M, Duin R P W, Matas J. On Combining Classifiers. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(3):226–239. DOI:10.1109/34.667881.

[17] Wu X, Zhang Q, Wang J, Yao J, Guo Y. Multiple Detection Model Fusion Framework for Printed Circuit Board Defect Detection. Journal of Shanghai Jiaotong University (Science), 2023, 28(6):717–727. DOI:10.1007/s12204-022-2471-0.