

GearPro 项目视觉系统技术报告

从齿轮定位到双专项缺陷判定

应用基线: main-web, 提交 de608d9

研究基线: dataset, 提交 9dfcc71

报告日期: 2026 年 9 月 22 日

适用对象: GearPro 项目组内部成员

本报告只描述仓库中已经实现或已经留下实验记录的视觉能力。

阅读提示

这份报告的目标不是把所有训练日志重新抄一遍，而是让队员快速弄清楚三件事：现在的视觉链路究竟怎么跑、实验数据说明了什么、下一步最值得把时间花在哪里。正文尽量用直白语言解释，必要的公式、配置和测试口径集中放在表格中。

先给出最重要的结论：当前视觉系统已经完成“齿轮定位+划痕专项+缺齿缺口专项”的可运行闭环，但还不能称为最终生产模型。锁定测试集上，双专项 OR 的任意缺陷 Recall 为 0.8873，FPR 为 0.2278，尚未达到 Recall 不低于 0.95 且 FPR 不高于 0.20 的目标。最明显的瓶颈不是训练轮数不够，而是低对比划痕、斜视缺口和真实高光负样本不足。

文中会反复区分三类数字：专项离线成绩、双专项联合成绩、产线端到端成绩。前两类已有记录；第三类仍需要在 Jetson NX、真实相机、真实照明和传送结构上重新验收，不能用离线测试数字代替。

目录

阅读提示	I
一 项目视觉任务与当前结论	1
1 视觉部分到底要做什么	1
2 一句话描述当前系统	1
3 目前最值得记住的四个数字	2
二 当前视觉处理链路	3
1 从一帧图像到最终结果	3
2 多个齿轮时怎么处理	3
3 辅助框与结果框	3
4 错误如何处理	3
三 模型原理与实际配置	4
1 为什么每个专项都由三路模型组成	4
2 温度校准与融合公式	4
3 发布配置逐项对照	5
4 P2 为什么只出现在划痕专项	5
四 数据集与实验方法	6

1	几轮实验使用的不是同一批数据	6
2	为什么要按组拆分	6
3	Difficult 样本怎么处理	6
4	指标怎么读	7
5	阈值选择的原则	7
五	实验演进与结果	8
1	从 V3 到双专项的演进	8
2	核心锁定测试结果	8
3	为什么联合后 Recall 上升, FPR 也上升	9
4	验证集和测试集为什么差得多	9
5	哪些尝试没有带来稳定收益	10
六	当前代码实现与部署	11
1	模型如何加载和复用	11
2	线程边界为什么重要	11
3	结果如何进入统计和硬件输出	11
4	PT 与 TensorRT Engine 的边界	12
5	上板前还缺哪些数字	12
七	局限与下一步	13
1	现状分成三类看	13
2	第一优先级是改采集和补数据	13
3	第二优先级是几何归一化	14
4	第三优先级才是部署加速	14
5	建议的下一轮验收门槛	14
八	结语	14
A	关键配置摘要	15
B	术语和口径速查	15
C	资料来源与版本	16

一 项目视觉任务与当前结论

1 视觉部分到底要做什么

GearPro 的视觉任务可以拆成三步。第一步是找到画面里的整颗齿轮，这一步由 Model1 完成；第二步是在齿轮 ROI 中判断是否有划痕；第三步是在同一个 ROI 中判断是否有缺齿或缺口。后两步不是一个统一模型，而是两个各自独立的专项模型包。

这种拆法的原因很直接：划痕通常很小、对比度低，缺齿缺口则更偏结构性变化。把整张相机画面直接缩到分类或检测输入尺寸，会进一步压缩微小缺陷。先定位齿轮，再裁出 ROI，可以把模型的像素预算集中到真正需要检查的区域。与此同时，把两种缺陷拆开训练，也比一个“任意缺陷”统一模型更符合现有数据条件 [1, 4]。

表 1 三个视觉任务及其当前角色

任务	当前模型	输入与输出	在最终判定中的作用
齿轮定位	Model1 YOLO	整帧输入，输出齿轮框与置信度	产生 ROI；没有齿轮时不计数、不发串口
划痕识别	Scratch V5	ROI 输入，输出融合概率与辅助框	概率达到划痕阈值时判废
缺齿缺口识别	Missing Hole V1	同一 ROI 输入，输出融合概率与辅助框	概率达到缺齿缺口阈值时判废

2 一句话描述当前系统

当前方案可以概括为：先定位，再让两个专项分别投票；任何一个专项过自己的阈值，整颗齿轮就判为不合格。两个辅助检测框用于给人看“模型可能在关注哪里”，但最终是否剔除始终由融合概率决定，而不是由“有没有框”决定。

表 2 当前结论的边界

状态	可以说	不能说
已完成	双专项已进入 main-web 运行时；配置、权重哈希、阈值和 OR 判定均有代码与测试	已达到无人值守产线要求
部分完成	离线锁定测试能够衡量专项及联合判定的相对水平	离线测试就是相机原帧到串口剔除的端到端成绩
尚未完成	Jetson NX 的真实 CUDA 延迟、峰值显存、功耗和整链路稳定性尚待验收	已完成所有模型 TensorRT、INT8 或零拷贝优化

3 目前最值得记住的四个数字

Scratch V5 的锁定测试 Recall 为 0.8065，FPR 为 0.1681；Missing Hole V1 的 Recall 为 0.8182，FPR 为 0.0377。两个专项按 OR 合并后，任意缺陷 Recall 提高到 0.8873，但 FPR 也提高到 0.2278。作为对照，统一单模型的 Recall 只有 0.7606，FPR 达到 0.4177。因此，现阶段保留两个专项是合理的，但仍需继续改善召回与误报平衡 [2, 3, 4]。

二 当前视觉处理链路

1 从一帧图像到最终结果

图1 展示了当前代码中的真实处理顺序。相机线程只维护最新帧，推理线程获取尚未处理的最新帧，避免形成积压队列。Model1 先给出齿轮框，代码再在宽高方向各扩展 4% 后裁出 ROI。每个 ROI 依次送入 Scratch V5 和 Missing Hole V1。两个专项各自完成分类、检测、温度校准和融合，最后才做独立阈值比较与 OR 判定 [1, 7]。




图 1 当前视觉处理流水线

2 多个齿轮时怎么处理

Model1 可能在一帧中给出多个齿轮框。代码会逐个生成 ROI，并对每个 ROI 完整执行两个专项。只要其中任意齿轮的任意专项命中，整帧结果就是“不合格”。如果一个齿轮同时命中划痕和缺齿缺口，拒绝原因会同时保留，但统计和串口输出仍只发生一次。

当前统计采用“帧结果 + 冷却时间”，并没有做跨帧目标跟踪。因此，默认 5 秒冷却用于避免同一齿轮在连续帧中被重复计数。这个机制适合现阶段单设备基线，但不等同于真正的逐工件 ID 跟踪。

3 辅助框与结果框

齿轮主框的颜色由最终 OR 判定决定：合格为绿色，不合格为红色。Scratch 检测器的最高置信度达到 0.05 时绘制划痕辅助框；Missing Hole 检测器采用相同的显示门槛绘制缺口辅助框。专项检测器实际推理的最低置信度为 0.001，这样融合阶段可以使用低概率信息，而显示阶段不会把极低置信框画满画面。

辅助框先在 ROI 坐标系中产生，再加上 ROI 左上角偏移，映射回原图坐标系。检测框缺失并不代表专项概率一定为零，因为两个分类器仍然参与融合。

4 错误如何处理

当前视觉运行时把空 ROI、权重缺失、哈希不匹配、非法配置、NaN/Inf、CUDA OOM 和任一必要专项失败视为错误。错误会停止当前检测任务，不会静默降级成“只

运行一个专项后仍输出合格”。这样做牺牲了一部分可用性，但避免把不完整模型链路误当成安全结果。

三 模型原理与实际配置

1 为什么每个专项都由三路模型组成

分类器适合回答“整张 ROI 看起来像不像缺陷”，检测器适合回答“局部是否存在一个像缺陷的区域”。两者的错误模式不同：分类器可能受整体视角影响，检测器可能被反光或加工纹干扰。当前方案让 EfficientNet-B0、ResNet18 和 YOLO 检测器分别给出概率，再进行校准和加权融合。




图2 单个专项模型包的融合方式

2 温度校准与融合公式

各分支先输出原始概率 p ，再用温度 T 做校准：

$$\hat{p} = \sigma \left(\frac{\text{logit}(\text{clip}(p, 10^{-6}, 1 - 10^{-6}))}{T} \right). \quad (1)$$

这里的温度不是运行时随意调的参数，而是模型选择阶段在验证集上确定并写入发布配置的数值。

两个分类器校准后取均值：

$$p_{cls} = \frac{\hat{p}_{c1} + \hat{p}_{c2}}{2}. \quad (2)$$

Scratch V5 更依赖局部检测器，其融合公式为：

$$p_{scratch} = 0.25p_{cls} + 0.75\hat{p}_{det}. \quad (3)$$

Missing Hole V1 对分类器和检测器等权：

$$p_{missing} = 0.50p_{cls} + 0.50\hat{p}_{det}. \quad (4)$$

最终判定为：

$$reject = (p_{scratch} \geq 0.300273610279458) \vee (p_{missing} \geq 0.3413327979078584). \quad (5)$$

3 发布配置逐项对照

表 3 两个专项模型包的配置

专项	分支	输入尺寸	温度	作用
Scratch V5	EfficientNet-B0	384	0.700	分类器 1
	ResNet18	384	2.050	分类器 2
	YOLO26-P2	960	2.125	单类划痕检测
Missing Hole V1	EfficientNet-B0	512	1.000	分类器 1
	ResNet18	384	2.375	分类器 2
	standard YOLO26n	960	1.850	单类缺口检测

两个检测器均使用 `conf=0.001`、`iou=0.7`，辅助框显示门槛均为 0.05。分类器使用 RGB、保持长宽比的 LANCZOS 缩放、居中放入 (238, 238, 238) 灰色方形画布，再执行 ImageNet 均值和标准差归一化。OpenCV 提供的是 BGR ROI，因此代码会在进入分类器前显式转换为 RGB；检测器仍接收原始 BGR 数组 [8, 9]。

4 P2 为什么只出现在划痕专项

P2 检测头保留更高空间分辨率，理论上更适合很小的划痕，但计算量也更高。实验结果并不支持“所有缺陷都应该用 P2”：Scratch V5 最终选择了 P2 检测器，而 Missing Hole V1 的标准单类检测器在验证集上更稳。结论是结构要由任务和数据决定，不能仅凭“目标小”就默认 P2 一定更好。

四 数据集与实验方法

1 几轮实验使用的不是同一批数据

V3、V4、Scratch V5 和 Missing Hole V1 的任务定义、数据规模和测试口径不同。直接把不同阶段的 Recall 排在一起很容易误解，因此表4 把主要差异放在同一页。

表 4 主要实验阶段的数据与目标

阶段	数据规模	拆分	任务	评价注意点
V3	343 张	243/50/50	normal、scratch、missing_tooth 判定与独立定位	50 张锁定测试，接近重复组隔离
V4	343 张	243/50/50	normal/defect 二分类	扩展方向参考过早期测试，最终留出集不再是严格盲测
Scratch V5	514 张训练验证池；另有 150 张测试	364/150；测试 31 正、119 负	scratch 专项	测试与训练验证无 SHA256 重复，但有近似图提示项
Missing Hole V1	496 张训练池；150 张测试	397/99/150	missing_hole 专项	建立 270 个近重复组；锁定测试只用一次

2 为什么要按组拆分

工业视觉数据经常来自连续拍摄，同一颗齿轮、相邻帧和相近角度之间非常像。如果把这些图片随机分到 train、val 和 test，模型可能只是记住同一工件的纹理，验证分数会虚高。研究分支通过 SHA256、dHash、相邻序号、宽高比和灰度相关性建立近重复组，再保证同组不跨集合。

Missing Hole V1 的训练池与独立 test 之间没有 SHA256 重复，也没有 dHash 距离不超过 2 的近重复。V3/V4 的指定近重复泄漏同样被清零。这个处理让测试更接近“新工件、新拍摄批次”，也解释了为什么验证集接近满分时，独立测试仍会明显下降 [5, 4]。

3 Difficult 样本怎么处理

Missing Hole 数据包含 difficult 框。实验同时生成 include 和 exclude 两套训练标签。exclude 只影响训练：删掉 difficult 框；如果一张训练图只含 difficult 框，就整张排除，不能把它误当成正常负样本。本轮共有 6 张这种图片。验证集与测试集始终保留完整真值。

最终测试中，包含 difficult、忽略 difficult 和纯易样本三种统计口径的总体 Recall 分

别为 0.8182、0.8140 和 0.8205，差距很小。因此 difficult 不是当前主要瓶颈，oblique 视角才是更明显的问题。

4 指标怎么读

表 5 本报告使用的主要指标

指标	含义	本项目中的重点
Recall	真实缺陷中被检出的比例	漏检敏感，优先级最高
Precision	判为缺陷的结果中真正缺陷的比例	反映剔除结果的可信程度
FPR	正常样本被误判为缺陷的比例	对应正常品误剔除率
F1	Precision 与 Recall 的调和平均	便于单点比较，但不能代替业务约束
mAP50 / mAP50-95	检测框位置与类别质量	用于辅助定位诊断，不是最终剔除首要指标
AUROC / AUPRC	全部阈值下的排序能力	AUPRC 更适合类别不均衡、关注缺陷类的情况

5 阈值选择的原则

模型、温度、融合权重和阈值只允许在训练集与验证集上确定。锁定 test 只用于最终评价，不能在看过结果后重新选阈值。V5 的激进阈值可以把 test Recall 提到 0.935，但 FPR 会达到 0.588，这正说明“为了测试分数临时调阈值”会破坏实际误报约束。

五 实验演进与结果

1 从 V3 到双专项的演进




图 3 核心实验与应用集成时间线

V3 首次把“是否剔除”和“缺陷在哪里”拆开，方向是对的，但旧划痕数据无法支撑跨组泛化。V4 尝试直接做任意缺陷二分类，三模型最大概率融合的 Recall 为 0.633，FPR 为 0.350，而且扩展实验参考过早期测试结果，不能再当严格盲测。

Scratch V5 重新整理了划痕专项数据并采用三模型融合；Missing Hole V1 则系统比较类别方案、difficult 策略、standard/P2、384/512 和 960/1280。最后两个专项分别锁定配置，再用 OR 合并。这个路线在同一批 150 张测试图上明显优于统一单模型 [4, 3]。

2 核心锁定测试结果

表 6 核心模型在锁定测试上的结果

方案	Recall	Precision	FPR	TP/FP/TN/FN
Scratch V5 专项	0.8065	0.5556	0.1681	25/20/99/6
Missing Hole V1 专项	0.8182	0.9000	0.0377	36/4/102/8
双专项 OR 任意缺陷	0.8873	0.7778	0.2278	63/18/61/8
统一 EfficientNet-B0	0.7606	0.6207	0.4177	54/33/46/17




图 4 核心方案的 Recall、Precision 与 FPR 对比

3 为什么联合后 Recall 上升，FPR 也上升

OR 规则只要任一专项命中就判废，因此它能补回另一专项漏掉的部分缺陷。例如 Missing Hole 缺陷被任一专项剔除的 Recall 达到 0.9318，高于 Missing Hole 专项自身的 0.8182。但 OR 同样会把两个专项的误报合并，所以任意缺陷 FPR 上升到 0.2278。这个结果符合逻辑，并不是统计错误。

专项 FPR 的负样本定义也不同：Scratch 专项的负样本是“无 scratch”，其中可能包含 missing hole；Missing Hole 专项的负样本是“无 missing hole”，其中可能包含 scratch；联合 FPR 的负样本才是“无任意缺陷”。因此不能把两个专项 FPR 直接相加，也不能不加说明地横向比较。

4 验证集和测试集为什么差得多

Scratch V5 在验证集上的 Recall 为 0.9767、FPR 为 0.0841，但锁定测试变为 0.8065 和 0.1681。Missing Hole V1 的验证 Recall 为 1.000、FPR 为 0.0615，锁定测试变为 0.8182 和 0.0377。验证集参与过模型选择、温度校准和阈值选择，天然会更乐观；测试集还包含新的拍摄分布和更难视角。

Scratch 的 6 张 FN 主要是正视或斜视、小面积、低对比划痕；20 张 FP 主要来自侧齿高光和正常加工纹。Missing Hole 的位置子组 Recall 为 bottom 0.9167、oblique 0.5882、side 1.0000。oblique 是最明确的缺口瓶颈。

5 哪些尝试没有带来稳定收益

已有实验表明，单纯把检测输入从 960 提升到 1280、继续增加 epoch、重复使用 CLAHE 加难例重采样、普通滑窗局部检测，以及把两类缺陷塞进一个统一模型，都没有稳定解决泛化问题。P2 对划痕有用，但在 Missing Hole 上没有胜过 standard。下一轮不应该简单重复这些组合。

六 当前代码实现与部署

1 模型如何加载和复用

视觉模型在第一次启动检测时加载。Model1 由 Ultralytics YOLO 接口加载；Scratch V5 和 Missing Hole V1 分别读取 JSON 配置，验证版本、模型类型、输入尺寸、温度、融合规则、阈值及权重 SHA256。两个分类器以 `weights=None` 构造网络，再载入 `checkpoint`，避免运行时下载 ImageNet 权重。

加载后会执行一次预热：分类器用对应尺寸的全零张量前向，检测器用全零图像跑一次预测。后续暂停和恢复检测时复用同一批模型实例，不会为每帧或每个浏览器连接重新加载。

2 线程边界为什么重要

OpenCV 采集和神经网络推理都不在 FastAPI 事件循环中运行。相机线程维护最新帧，推理线程按间隔处理最新未处理帧，运行时再缓存原图与标注图 JPEG。这样慢浏览器或临时断线不会阻塞相机和检测，也不会让浏览器成为检测任务的所有者 [1]。

表 7 视觉相关模块职责

模块	主要职责
<code>gp/camera.py</code>	OpenCV V4L2 采集，只保留最新帧
<code>gp/worker.py</code>	独立推理线程，加载模型并处理相机或视频帧
<code>gp/models.py</code>	Model1 定位、ROI 裁剪、两个专项编排、辅助框回映与绘制
<code>gp/scratch_v5.py</code>	划痕配置校验、预处理、三路推理、校准与融合
<code>gp/missing_hole.py</code>	缺齿缺口配置校验、预处理、三路推理、校准与融合
<code>gp/runtime.py</code>	结果快照、统计、JPEG 缓存及串口结果衔接

3 结果如何进入统计和硬件输出

同一次推理结果会同时用于页面显示、统计与串口，避免不同模块重新计算判定。检测到齿轮且最终为合格时发送 ASCII 01，不合格时发送 ASCII 02。没有检测到齿轮时不计数、不发送结果；视频测试模式始终禁用串口。

API 状态保留两个专项的概率、阈值、命中原因、分类器概率、检测器概率、辅助框和分项耗时。这样用户修改阈值后，旧结果不会被悄悄按新阈值重新解释；每个

observation 都保存了推理时实际使用的阈值。

4 PT 与 TensorRT Engine 的边界

当前运行只约定两种格式：`.pt` 用于开发和精度基线，`.engine` 是在目标 Jetson NX 上编译的 TensorRT 产物。优先转换耗时更大的 Model1，Scratch V5 与 Missing Hole V1 的六个专项分支目前继续使用 `.pt`。应用层的相机、计数、页面和串口不绑定模型格式 [6]。

表 8 模型格式的实际使用建议

格式	优点	约束
<code>.pt</code>	与训练路径最接近，便于精度回归和跨电脑调试	在 NX 上吞吐通常低于 FP16 TensorRT
<code>.engine</code>	在目标 NX 上通常更快，适合定位模型加速	与 GPU、JetPack、TensorRT 版本绑定，必须在目标板重编

ONNX 只作为导出中间产物，当前不提供 ONNX 运行入口。INT8、专项 `engine`、结构化剪枝、零拷贝和自定义 CUDA 尚未形成已验收能力，不能写成已完成优化。

5 上板前还缺哪些数字

训练侧记录过 RTX 4060 Laptop GPU 的利用率与显存，但这些不能代表 Jetson NX。上板时至少要记录 Model1、两个专项的分项延迟、总延迟、吞吐、峰值显存、功耗、温度，以及相机取帧、预处理、JPEG 编码和 Web 传输的非模型开销。还要在真实传送结构和照明下验证 ROI 是否稳定覆盖齿轮。

七 局限与下一步

1 现状分成三类看

表 9 视觉工作的完成状态

状态	内容	说明
已完成	两阶段 ROI 流程、双专项常驻运行、独立阈值、OR 判定、辅助框回映、权重哈希校验	已进入 main-web, 代码和轻量测试均有依据
已完成	V3/V4/V5/Missing Hole 的主要数据审计、模型比较和锁定测试	能作为研究与迁移回归基线
部分完成	几何归一化、hard-case、P2、高分辨率、difficult 策略	部分方向已有实验，但没有组成完整的严格单变量矩阵
部分完成	Model1 TensorRT	工程支持 .engine 路径，但报告没有目标 NX 的最终实测表
尚未完成	多相机或多视角聚合、齿圈极坐标展开、完整工件跟踪	目前属于建议方向，不是现有功能
尚未完成	专项 TensorRT FP16/INT8、知识蒸馏、结构化剪枝、零拷贝、自定义 CUDA	应在精度基线稳定后再做
尚未完成	$Recall \geq 0.95$ 且 $FPR \leq 0.20$	当前双专项 OR 为 0.8873 / 0.2278 的最终生产指标

2 第一优先级是改采集和补数据

对 oblique 缺口，如果单帧中缺陷肉眼都很难看见，更大的模型无法凭空恢复信息。建议优先增加低角度环形光、背光轮廓、转台多角度或第二相机，并把同一颗实体齿轮的所有视角作为一个 group 管理。生产判定可以在多个视角之间做 OR，但需要用新的验证集确定聚合规则。

Scratch 需要补充两类数据：一类是低对比、小面积的真实划痕正样本；另一类是相同视角下的侧齿高光、圆周加工纹、灰尘和轻微失焦正常负样本。后者对降低 20 张 FP 所代表的误报模式尤其重要。

3 第二优先级是几何归一化

在 Model1 ROI 后进一步估计齿轮中心与直径、统一尺度、裁出齿圈区域，必要时尝试旋转校正或极坐标展开。对划痕，可以比较整图分类与 2×2 、 3×3 重叠局部块的多实例分类；对缺口，可以把圆周结构展开成近似直线纹理，再做小分类器或周期异常分析。所有方案都应在新数据上进行单变量对照。

4 第三优先级才是部署加速

精度没有稳定之前，过早进入 INT8、剪枝或自定义 CUDA 会增加变量，也可能放大微小缺陷损失。推荐顺序是：**.pt** 精度基线、Model1 FP16 engine、分项性能剖析、必要时再转换专项模型。只有速度仍不满足时，才进入 INT8、蒸馏或结构化剪枝。

5 建议的下一轮验收门槛

1. 按实体齿轮和拍摄批次分组，保留全新批次作为一次性 blind test。
2. 固定相机、照明、传送结构和 ROI 规则后再训练，避免训练与部署成像不一致。
3. 离线报告同时给出总体 Recall、Precision、FPR，以及 scratch、bottom、oblique、side 和高光负样本子组结果。
4. 端到端验收从原始相机帧开始，包括 Model1 漏定位、ROI 偏移、两个专项、冷却计数和串口输出。
5. 在目标 Jetson NX 上记录延迟、吞吐、峰值显存、功耗和长时间稳定性，不引用桌面 RTX 数据替代。

八 结语

GearPro 当前最可靠的视觉路线已经比较明确：先用 Model1 稳定定位齿轮，再让 Scratch V5 和 Missing Hole V1 分别做专项判断，两个专项独立校准、独立过阈值，最后用 OR 合并。这条路线比统一单模型更符合现有数据，也已经在 main-web 中形成可运行实现。

现阶段最需要避免的误区，是把验证集高分或单个专项的离线成绩直接当成生产能力。双专项 OR 的锁定测试 Recall 为 0.8873、FPR 为 0.2278，离目标仍有明确差距；端到端 Jetson 数据也尚未完成。下一轮最有效的投入应放在成像可见性、独立新数据、多视角、低对比划痕和真实高光负样本，而不是继续无差别增加分辨率和训练轮数。

从工程角度看，现有代码已经提供了一个可追溯、可替换、出错会停机的基线。后续工作应围绕同一套评价口径迭代，确保每次改动都能回答两个问题：漏检是否真的减少，正常品误剔除是否仍在可接受范围内。

A 关键配置摘要

表 10 当前视觉运行时关键参数

项目	当前值
Model1 默认资产	model/model1.pt; 也可通过 GEARPRO_MODEL1 指向目标 NX 编译的 engine
Scratch V5 配置	model/model2/inference_config.json
Missing Hole V1 配置	model/missing_hole_v1/inference_config.json
Model1 运行参数	当前应用默认置信度 0.70、IoU 0.45; 与早期研究报告的测试配置不是同一概念
ROI 外扩	定位框宽、高方向各 4%
Scratch 阈值	0.300273610279458
Missing Hole 阈值	0.3413327979078584
专项检测参数	conf floor 0.001, NMS IoU 0.7, 辅助框显示门槛 0.05
推理间隔	默认 0.10 秒
结果冷却	默认 5.0 秒
相机默认值	index 2, 640×480, 30 FPS
串口默认值	/dev/ttyHS1, 9600 baud; 合格 01, 不合格 02
模型错误策略	缺失、哈希错误、空 ROI、NaN/Inf、OOM 或专项失败时停止当前检测, 不静默降级

B 术语和口径速查

ROI

Region of Interest, 感兴趣区域。这里指 Model1 定位后裁出的齿轮图像。

专项模型

只负责一种业务缺陷的模型包。当前有 Scratch V5 和 Missing Hole V1 两套。

温度校准

对模型概率做后处理, 使验证集上的概率尺度更适合融合和选阈值, 不改变样本排序的基本方向。

辅助框

专项检测器输出的最高置信框，用于人工复核和解释，不独立决定合格或不合格。

锁定测试集

在模型、融合和阈值全部确定后才使用的测试集；查看结果后不得再用它调参。

端到端测试

从真实相机原帧开始，经过定位、ROI、两个专项、统计和硬件输出的完整链路测试。

oblique

斜视或斜向位置子组。Missing Hole V1 在该子组的 Recall 为 0.5882，是当前主要短板。

C 资料来源与版本

本报告以仓库内文档、配置和代码为事实依据，路径均按对应分支解释。版本如下：

- 应用侧基线：main-web，提交 de608d9f96366ca1f06c88b99ddf10cefab35eee；
- 研究侧基线：dataset，提交 9dfcc71a388c6b5b029e044c24b42b9df5f10e3b。

参考文献

- [1] GearPro 项目组，*GearPro Web* 系统架构，docs/architecture.md，main-web 分支。
- [2] GearPro 项目组，*Scratch V5* 运行说明，docs/scratch-v5.md，main-web 分支。
- [3] GearPro 项目组，*Missing Hole V1* 最终实验报告，docs/missing_hole_v1/FINAL_REPORT.md，dataset 分支。
- [4] GearPro 项目组，齿轮缺陷识别 V3、V4、V5 与 *Missing Hole V1* 总实验流程报告，dataset 分支。
- [5] GearPro 项目组，*Missing Hole V1* 数据审计与实验设计，dataset 分支。
- [6] GearPro 项目组，模型格式：.pt 与 .engine，docs/model-formats.md，main-web 分支。
- [7] GearPro 项目组，gp/models.py 与 gp/types.py，main-web 分支。
- [8] GearPro 项目组，gp/scratch_v5.py 与 model/model2/inference_config.json，main-web 分支。
- [9] GearPro 项目组，gp/missing_hole.py 与 model/missing_hole_v1/inference_config.json，main-web 分支。