齿轮外观缺陷检测

系统技术报告

自建数据·两类缺陷选型·参数依据·软件集成

GearPro 阶段记录日期：2026 年 10 月 7 日

摘要

本项目面向齿轮外观检查，重点检测划痕和局部齿部缺损。我们自行采购或定制 50 个齿轮，拍摄多角度图像并标注可见缺陷。在早期分类实验的基础上，分别比较两类缺陷的标签划分、检测结构和模型组合，利用验证集选择模型与判定参数。最终方案将分类模型与目标检测模型的分数加权组合，再合并两类缺陷的判断。在 150 张离线测试图像上，检出 63/71 张缺陷图像，召回率为 88.73%；误报 18/79 张无可见目标缺陷图像，误报率为 22.78%。相比已测试的统一缺陷分类模型，检出数净增加 9 张，误报数减少 15 张；两套方案的训练数据和计算预算不同。项目已完成软件集成和第一代原型联调，目前使用上下两台工业相机和 Jetson NX。新模型只做过简单现场测试，没有系统记录的整机性能数据。现阶段面向辅助人工复核，后续还需用新齿轮和现场测试检验效果。

关键词：齿轮外观检测；划痕；齿部缺损；模型融合；边缘计算

阅读说明：正文围绕任务、方法、实验依据和结果展开；完整配置与补充分析放在附录。项目事实、实验记录与历史报告的来源说明见附录 B；学术文献采用数字编号引用。本报告未新增训练或现场测试。

目录

1 项目要解决什么问题 1

2 系统怎样完成检测 2

3 我们怎样探索并选择方案 3

4 参数怎么确定，最终结果怎样 7

5 目前完成了什么，下一步验证什么 9

附录 A 文献与证据的对应关系 11

附录 B 关键固定训练参数与资料索引 11

附录 C 术语及方法名称 12

附录 D 数据检查与早期探索 13

附录 E 候选实验与未采用配置 16

附录 F 参数选择与补充结果 18

附录 G 软件、整机状态与后续测量 23

参考文献 25

1 项目要解决什么问题

1.1 应用目标与分工

本项目要解决的问题是：在齿轮输送检查中，利用工业相机采集的图像自动筛查划痕和局部齿部缺损，并将疑似缺陷结果传递给分拣模块和后续人工复核。系统设计既要尽量检出缺陷图像，也要控制误报、处理时间和设备成本。已有汽车齿轮研究将双相机扫描、缺陷检测和齿轮级判定组成检查流程 [18]，说明图像识别结果还需与采集和工件处理流程配合。

降低成本、减少漏检和适应复杂环境是项目的工程目标。目前尚无人工检查对照、完整成本清单和复杂工厂环境测试，因此本报告不将这些目标写为已验证的效果。

我负责软件和模型，其他成员负责硬件及后续现场部署。这份报告重点解释模型实验，也介绍软件如何连接相机、Web 页面和 STM32 控制器。目前使用上下两台工业相机，计算设备已升级为 Jetson NX。第一代原型已完成输送、采集、显示和分拣模块的联调；新模型只做过简单现场测试，未记录性能数据。

1.2 检测哪些缺陷，数据怎样采集

项目共有 50 个齿轮：正常 10 个、划痕 15 个、侧部缺损 15 个、齿角缺损 10 个，均自行采购或定制。拍摄使用流水线原型的工业摄像头，由人工摆放齿轮并调整姿态，获得上下、旋转和侧面等角度的图像。这些图像覆盖了部分观察条件，还没有覆盖连续输送中的运动和姿态变化。

我们将明确可见的划痕和局部齿部缺损标为不合格区域。目前没有按缺陷深度、尺寸或机械性能划分的合格标准，因此本项目检测的是这两类外观缺陷，齿轮能否安全使用还需其他检查。



图 1 自建数据中的正常外观、划痕与齿部缺损示例。红框为人工标注，局部放大用于观察，均不是模型预测。（来源：划痕数据清单；齿部缺损数据清单）

划痕可能与加工纹、高光混淆，齿部缺损是否能看见则受位置和观察角度影响。因此，我们按当前图像中的可见缺陷标注：人工确认看不到目标缺陷时，将图像作为该任务的负样本；缺陷可见但难辨认或难以标出边界时，标为困难目标（原始字段为 difficult）。困难目标表示缺陷的存在已经确认，但识别或边界标注较困难。这样，同一个缺陷齿轮在某些视角下也可能得到负样本图像。

表 1　自建图像数据划分

检测任务	训练图像	验证图像	测试图像
划痕	364	150	150
齿部缺损	397	99	150

两类检测使用同一批 150 张测试图：31 张含划痕，44 张含齿部缺损，其中 4 张同时含两类缺陷，共 71 张至少含一类缺陷、79 张无可见目标缺陷。

这些数量统计的是照片。由于目前只有图片顺序编号，还没确认同一齿轮的多角度照片是否分布在训练、验证和测试中，所以现有测试还不足以判断模型对新齿轮的效果。详细数据检查见附录 D。（来源：划痕测试记录；齿部缺损及联合测试记录；划痕数据清单；齿部缺损数据清单）

2　系统怎样完成检测

2.1　从图像到检测结果

系统先找到齿轮，再裁剪齿轮所在的区域，称为感兴趣区域（region of interest，ROI），以减少背景干扰。随后分别检测划痕和齿部缺损。每类缺陷使用两个图像分类模型和一个目标检测模型：分类模型判断整张图是否含该类缺陷，目标检测模型给出疑似缺陷框，并取最高框置信度作为图像判断的一个分数。

同类缺陷的三个模型分数先经过温度缩放 [4]，再参照分类器输出组合的思路 [16] 加权平均，这一步称为分数级加权融合。温度缩放用于调整输出分数的尺度，温度参数根据验证集选择；调整后的分数是否更可靠，还需要校准前后对照。两类综合分数分别与各自阈值比较，只要任一类达到阈值，就标记为疑似缺陷。这种采用或规则的合并判断属于决策级融合，工业外观检测中已有按缺陷类别分别建模后合并判断的实例 [15]，本项目的具体公式见附录 F。

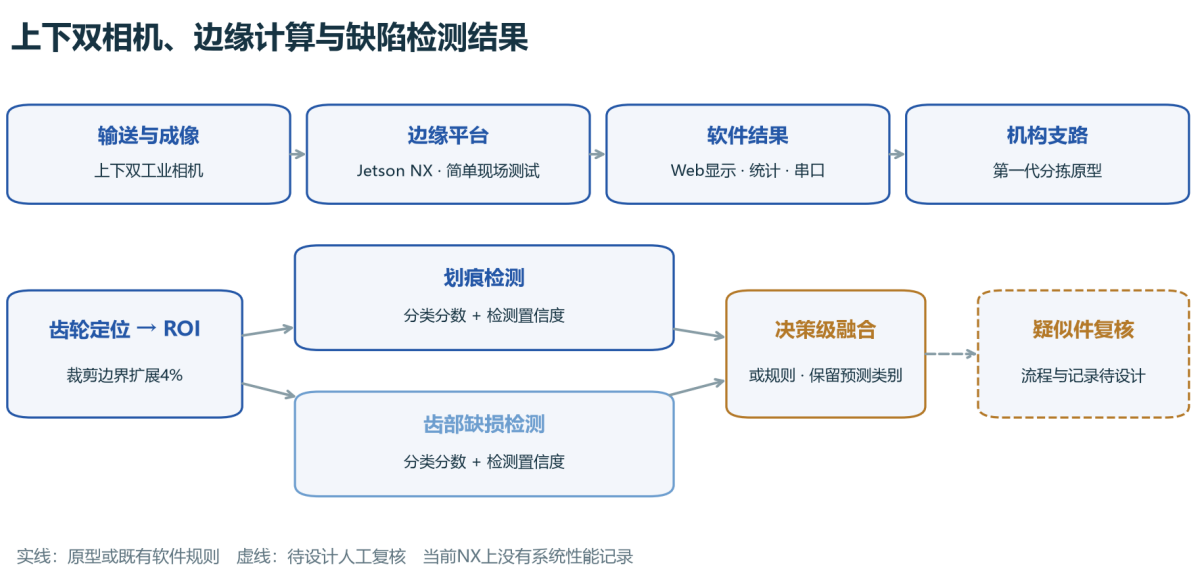


图 2　上下双相机、NX、检测软件与分拣机构的关系。虚线表示尚待设计的人工复核环节；当前模型的整机性能还需现场测试。（来源：项目事实说明；《GearPro 综合实验与部署技术报告》）

软件把同一次检测的分数、阈值、类别、预测框和耗时传给页面、统计模块和串口，让各处使用同一个结果。代码中的 PASS 表示“模型未检出缺陷”，REJECT 表示“疑似缺陷”。人工复核哪

些工件、是否抽查模型未检出的工件，还需要确定。只复核疑似件能够纠正误报，但漏检件也需要安排复核或抽查。

在已有齿轮检查研究中，图像检测结果还需结合连续图像规则形成齿轮级判定 [18]。本项目目前缺少跨帧工件编号和完整现场记录，因此现有离线结果只评价图像级判断，不等同于工件级质检性能。

2.2 方法参考了哪些研究

我们参考 ResNet 和 EfficientNet 的图像分类方法 [10][11]，将它们作为候选网络，再用齿轮验证数据比较。FPN 的多尺度特征思想 [12] 为小缺陷检测提供了参考，因此实验还比较了原始 YOLO 模型和含 P2 检测层的既有配置。P2 层的空间分辨率较高，目的是保留更多细小缺陷信息；正常细纹也可能因此引起误报，需要通过实验选择。

工业外观检测中也有多检测模型融合的做法 [17]。第 2.1 节引用的研究用于说明温度缩放、分类器组合和分缺陷判定均有相关方法基础，不证明本项目的融合已经优于单模型。具体使用哪些模型、怎样分配权重，仍由本项目的验证结果决定。

Guo 等的研究 [4] 提供了温度缩放的方法参考。Saito 与 Rehmsmeier 的研究 [3] 说明，在类别不平衡时需要结合精确率和召回率看结果，所以报告同时列出缺陷检出和误报。成本敏感学习及 Neyman–Pearson 分类研究 [5][6] 提醒我们考虑漏检与误报的代价；当前只在验证集上设置经验误报约束，未采用带总体误差保证的 NP 算法。

反复用同一验证集挑选模型、权重和阈值，可能让验证结果偏乐观 [1][2]。因此，报告分别列出验证和测试结果：验证用于选择配置，固定配置后再测试。论文解释方法思路，参数的具体数值则来自项目记录。对应关系见附录 A。

3 我们怎样探索并选择方案

3.1 判断有无缺陷与找到缺陷位置（V3）

系统需要回答两个问题：图像中有没有缺陷，以及缺陷在哪里。V3 阶段，我们用分类模型区分正常、划痕和齿部缺损，另训练目标检测模型标出缺陷位置，分别评价这两项任务。下面列出齿部缺损的结果。（来源：V3 测试与定位记录）

表 2 V3 图像判断与区域定位的不同评价单位

评价任务	判断对象	正确检出／参考数量	召回率
图像分类	图像中是否有齿部缺损	15/19 张图像	78.95%
缺陷定位	预测框是否正确对应缺损区域	25/52 个标注区域	48.08%

两项评价数的是不同对象。一张图可能包含多个缺损区域，分类判断这张图是否有缺陷，定位则要找到具体区域并满足框匹配要求。因此 15/19 张图像和 25/52 个区域应分别解释，两个召回率的差值不能用来判断哪种方法更好。后续我们也分别检查缺陷判断与位置显示。

V5 沿用了这种区分：检测模型的最高框分数参与图像判断，预测框供查看和复核。划痕综合分数中，检测分数的系数为 0.75，两个分类分数的系数各为 0.125。这些数字说明分数怎样组合，不表示定位精度或各模型实际贡献。软件按综合分数和阈值判断是否疑似缺陷，显示框只作为辅助线索。

V3 划痕的两套定位统计存在差异，原因还没核清，相关记录保留在附录 D。本节采用齿部缺损结果说明两种评价单位，不使用存在冲突的划痕定位计数。

3.2 模型分数、阈值与融合的关系（V4）

V4 阶段，我们将两类缺陷合并为“有缺陷”，尝试统一二分类，再比较不同模型、训练预算和模型组合。下表是在同一留出集上的结果。判定阈值由验证规则选择，留出集用于评价，没有在这批图像上重新挑选阈值。（来源：V4 初始基线记录；V4 最终融合记录；V4 发布配置；V4 候选评价记录；V4 详细技术报告）

表 3 V4 排序指标与所选工作点

方案	AUPRC	召回率	误报率	每图分类前向次数
基线模型	0.767	56.67%（17/30）	30.00%（6/20）	4
扩展单模型	0.899	约 46.7%	约 5.0%	4
三模型融合	0.814	63.33%（19/30）	35.00%（7/20）	12

基线和融合计数已核对原始 JSON；扩展单模型的结果来自既有详细报告，尚未由逐图预测重算。表中的前向次数指每张图像执行分类网络的次数，由保存的测试时增强配置推导。完整配置与来源见附录 D。

模型分数的排序表现与所选阈值要分开看。表中的 AUPRC 概括不同阈值下精确率与召回率的表现，实际检出和误报还取决于最后选用的阈值。扩展单模型的 AUPRC 较高，但在所选阈值下检出更少、误报也更少。因此选模型时，既要看排序指标，也要看采用该阈值后能检出多少、误报多少。AUPRC 的实际计算方式见附录 C。

总体检出增加，划痕仍是主要问题。三模型融合比基线的检出数净增加 2 张，误报数增加 1 张。按类别看，划痕都是 4/11，齿部缺损由 13/19 升至 15/19。也就是说，总体改善并没有增加划痕检出数，这促使我们后续单独组织划痕实验。这里比较的是汇总计数，具体哪些图像被补充检出或丢失，还需逐图核对。

增加模型还要考虑误报和计算量。最大值融合取成员模型的最高分数。对固定成员和相同阈值，它既可能增加检出，也可能引入其他成员的误报。本次比较还改变了成员和阈值，因此观察到的差异是整套配置的结果。三模型各执行四路测试时增强，每图共 12 次前向计算；实际 NX 耗时和能耗需要另行测量。

这批留出结果曾帮助我们决定后续扩展方向，所以这里用它解释探索过程，不将它当作始终未查看的最终测试。V4 的经验是：增加模型前，先看哪类缺陷还没有改善，以及额外计算是否值得。V5 重新比较了配置和测试时增强，最终没有采用测试时增强。

3.3 划痕：比较分类、检测与分数融合

V4 融合后，划痕检出数没有增加。V5 因此重点比较分类判断与局部检测线索，尝试融合两者的分数。划痕可能与加工纹混淆，细小划痕的预测框也可能不准；我们希望先检查这种组合能否改善图像级判断，再分别评价定位效果。

划痕实验包括 6 个初步分类模型、2 个初步检测模型，以及 2 个提高训练轮数上限后重新训练的分类模型。分类候选包括 ResNet18、EfficientNet-B0 和 YOLO 分类器；检测候选包括原始 YOLO26n 和含 P2 检测层的模型。随后用验证集选择模型、融合方式和阈值。（来源：划痕发布配置；划痕候选模型评价表）

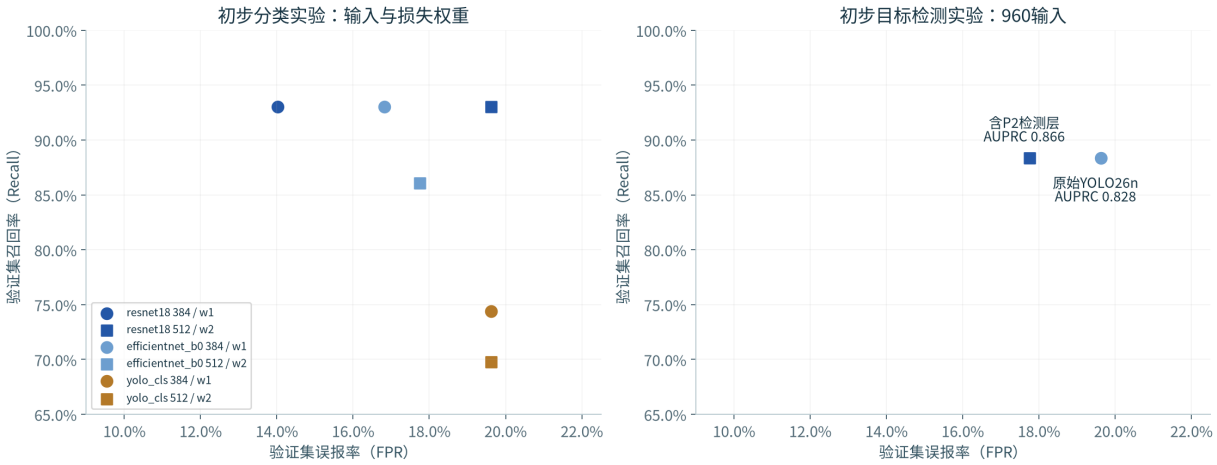


图 3 各划痕候选在自身验证阈值下的召回率与误报率，按当时 FPR≤0.20 的规则选择。部分实验同时改变输入尺寸、权重或批量大小（batch），各因素的单独作用还需控制条件比较。（来源：划痕候选模型评价表）

两个检测配置都检出 38/43 张划痕图像；原始模型误报 21/107，P2 配置误报 19/107，P2 的 AUPRC 也较高。因此我们采用 P2 配置，再与两个分类模型组合。融合后的验证结果为检出 42/43、误报 9/107；固定配置后的测试结果为检出 25/31、误报 20/119。（来源：划痕发布配置；划痕测试记录）

表 4 划痕单模型与融合验证对照

划痕验证方案	成员数	正确检出／43 张可见划痕图	误报／107 张无可见划痕图
入选 EfficientNet 单模型	1	41	13
P2 检测模型	1	38	19
最终加权融合	3	42	9

各方案都在同一验证集上按 FPR≤0.20 规则选择各自阈值。相较 EfficientNet，融合的检出数净增加 1 张，误报数减少 4 张。这个对照用于选择配置，融合的独立测试收益还需另行比较。来源见候选评价表与发布配置。

我们据此选择了当前配置，但原始模型与 P2 模型的 batch 不同，P2 结构本身带来多少改善还需单独验证。已有框匹配评价仍有大量误报，因此图像判断与定位继续分别评价。后续还应核对三个模型在同一图像上的共同错误，并通过控制条件的消融实验检查成员是否必要。

3.4 齿部缺损：比较标签划分与困难目标处理

齿部缺损在不同位置有不同外观。我们想知道：将位置分成多个类别是否更容易学习，还是合并为一类更适合现有样本？难辨认或难标框的目标是否适合保留在训练中？为此，实验比较了标签划分、困难目标处理和检测结构。

初步检测实验共 12 组：三类／两类／单类标注，保留／排除困难目标，原始／含 P2 检测层的 YOLO 模型，均采用 960 输入和 35 轮训练上限。其中三类指 bottom、oblique、side 位置标签，两类合并 bottom 与 oblique，单类只区分是否为齿部缺损。后续还比较了分类模型、更大输入和更高训练轮数上限，完整记录见附录 E。（来源：齿部缺损候选模型评价表）

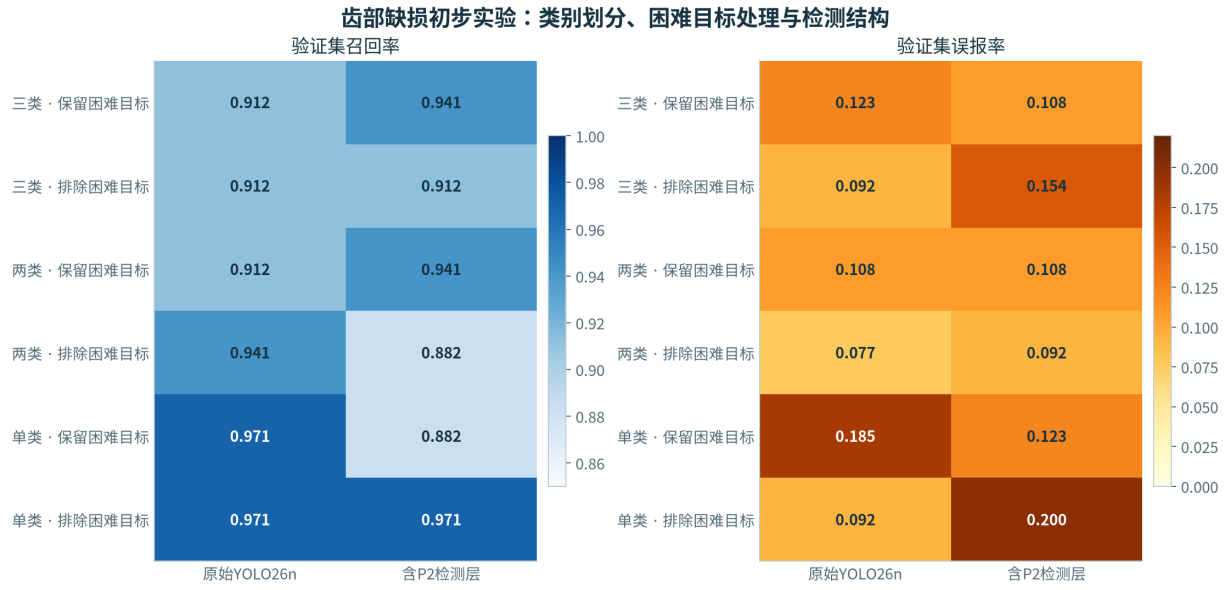


图 4　12 组检测配置的验证召回率与误报率。各组采用自身验证阈值，batch 等条件也有差异；图中结果用于比较候选配置，各因素的单独作用还需进一步实验。（来源：齿部缺损候选模型评价表）

采用单类标注并排除困难目标时，两个结构都检出 33/34，原始模型误报 6/65，P2 配置误报 13/65。因此齿部缺损选择单类标注的原始 YOLO26n。

困难目标只从训练中排除：删除 21 个困难标注框，并移除 6 张仅含困难目标的图像，避免把这些已知缺陷图作为负样本。验证和测试仍保留完整标注。

最终分类模型采用不同输入尺寸和困难样本设置，检测模型则保留了初步实验权重。提高训练轮数上限后重新训练的检测模型 AUPRC 较高，但选择规则先比较各位置组中的最低召回率：初步模型约 0.917，重新训练模型约 0.909，所以初步模型入选。这个差别涉及少量样本，其稳定性还需重复实验检查。（来源：《GearPro 综合实验与部署技术报告》；齿部缺损发布配置）

表 5　齿部缺损单模型与融合验证对照

齿部缺损验证方案	成员数	正确检出／34 张可见缺损图	误报／65 张无可见缺损图
入选 EfficientNet 单模型	1	34	6
原始 YOLO 检测模型	1	33	6
两个分类模型分数均值	2	34	5
EfficientNet 与检测分数加权融合	2	34	4
最终加权融合	3	34	4

各方案都在同一验证集上按 FPR≤0.20 规则选择各自阈值。融合主要减少误报；两模型与三模型均为 34TP、4FP，三模型因 AUPRC 约 0.9660 高于 0.9634 入选。这还不能证明三个成员都必要，后续需要比较逐图结果和计算开销。完整配置见附录 F，来源为融合候选评价表。

3.5　分别检测是否值得增加模型数量

确定两类检测方案后，我们又训练了统一缺陷分类候选，在同一批 150 张测试图上比较是否存在任意缺陷。分别检测并合并结果的方案检出 63/71、误报 18/79；所选统一模型检出 54/71、误报 33/79。前者检出数净增加 9 张、误报数减少 15 张，因此目前保留分别检测的组合方案。（来源：齿部缺损及联合测试记录）

这项比较评价的是两套现有方案。它们的训练数据构造、模型数量和预算不同，所以分别建模本身带来多少收益还需要控制条件比较。组合方案的模型文件约 130MB，统一模型约 15.6MB；运行内存、NX 耗时和实际部署代价需要实测。

4 参数怎么确定，最终结果怎样

4.1 指标、权重与阈值各自是什么

评价指标告诉我们结果怎样，模型参数决定怎样计算，阈值决定怎样判断。召回率、精确率和误报率都是通用指标，不只用于 YOLO。下面将它们与训练得到的网络参数、融合比例和判定阈值分开说明。

表 6 评价指标与模型参数的区别

名称	含义或作用	来源
召回率（Recall）	有可见目标缺陷图像中被检出的比例，TP/(TP+FN)	对照人工标注统计
精确率（Precision）	被判为有缺陷的图像中真正有缺陷的比例，TP/(TP+FP)	对照人工标注统计
误报率（FPR）	无可见目标缺陷图像中被误判的比例，FP/(FP+TN)	对照人工标注统计
网络参数	决定网络如何提取和判断特征	预训练初始化后通过训练更新
温度参数	调整模型分数尺度	选择验证集负对数似然最小的候选
融合系数	决定各模型分数的加权比例	比较预设融合候选的验证结果
判定阈值	将连续分数转换为疑似缺陷标记	固定模型与融合后扫描验证阈值

TP 表示正确检出的缺陷图像，FN 表示漏检的缺陷图像；FP 表示误报，TN 表示正确判为无可见目标缺陷的图像。这些计数用于评价方案，融合权重仍需通过候选比较确定。

4.2 核心参数怎样确定

参数选择分三步：先训练候选模型，再用验证集比较模型、温度、融合方式和阈值，最后固定配置进行测试。计算综合分数时，两个分类模型经过温度缩放后的分数先取平均，再与检测分数加权组合。下表列出展开后各成员的比例。（来源：划痕发布配置；齿部缺损发布配置）

表 7 最终融合系数及判定阈值

检测任务	EfficientNet 分数系数	ResNet18 分数系数	检测分数系数	判定阈值（约）
划痕	0.125	0.125	0.750	0.3003
齿部缺损	0.250	0.250	0.500	0.3413

这些比例来自有限候选比较，说明综合分数怎样计算。例如划痕检测分数乘以 0.750，两个分类分数各乘以 0.125，再相加。它们不表示缺陷的重要程度或模型实际贡献。齿部缺损的两个候选都是 34TP、4FP，最终按 AUPRC 约 0.966 与 0.963 的排序入选。运行时使用配置文件里的完整阈值，表中只显示近似值。

当时的阈值选择先要求验证误报率 $\leq$0.20，再尽量提高召回率，并结合位置组表现等规则。Recall$\geq$0.95、FPR$\leq$0.20 是**历史实验目标及选择约束**，没有正式业务需求或成本测算依据，因此不作为生产验收标准。

另一些参数在实验前就已设定：自定义分类器的 Focal 损失聚焦参数 γ=1.5，用于调整易样本的损失占比；齿部缺损分类器的正类损失权重为 2；ROI 裁剪边界扩展 4%。这些值没有逐项验证最优。参数作用、具体来源和完整选择规则见附录 B、附录 F。

4.3 同一测试集上的结果

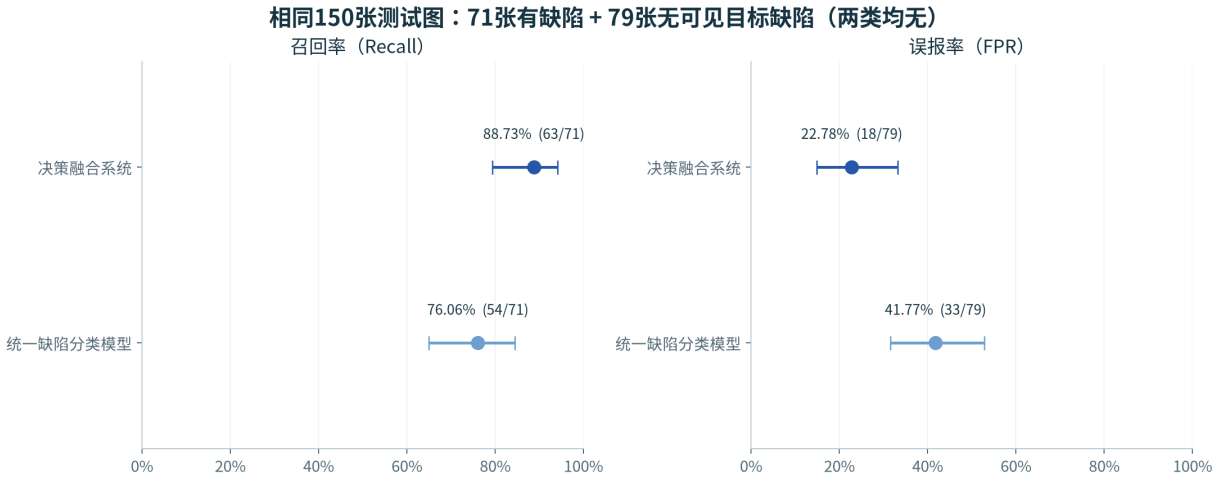


图 5 同一批 150 张图像上，按“任意缺陷”标签比较两套方案。误差线为按图像计数的 Wilson 95% 区间。由于同一工件照片之间的相关性未知，这些区间仅供描述结果，不用于判断差异是否具有统计显著性。（来源：齿部缺损及联合测试记录）

表 8 固定配置的图像级测试结果

检测方案	TP/FP/TN/FN	召回率	精确率	误报率
划痕检测	25/20/99/6	80.65%	55.56%	16.81%
齿部缺损检测	36/4/102/8	81.82%	90.00%	3.77%
两类结果合并	63/18/61/8	88.73%	77.78%	22.78%
统一缺陷分类模型	54/33/46/17	76.06%	62.07%	41.77%

表的前两行分别评价划痕和齿部缺损，无该类缺陷的图像可能含另一类缺陷。后两行都评价任意缺陷，使用同一正负样本定义，可以直接比较。各类模型满足的误报约束，仍需在合并结果后重新检查。

18/79 是图像误报计数，不能换算为 18 个合格工件。当前漏检统计只针对图像中可见的目标缺陷；缺陷没有进入画面时，需要另外评价拍摄覆盖情况。

测试表现低于验证表现：划痕由验证检出 42/43 变为测试检出 25/31，齿部缺损由 34/34 变为 36/44，两项测试召回率均约 81%。验证数据参与了多轮选择，拍摄条件和困难样本也可能有差异。目前还无法区分这些因素各有多大影响，详细结果见附录 F。

4.4 错误案例与使用取舍



图 6 两个划痕漏检和一个划痕误报案例。红框是人工标注，模型分数取自固定配置的已有预测记录，局部放大只供观察。图中的“无划痕”表示该任务的负样本，图像仍可能有齿部缺损。（来源：划痕逐图预测与标注）

后续应重点检查浅划痕是否拍得清，以及正常加工纹为何引起误报。齿部缺损的 8 张漏检中，7 张带有 oblique 位置标签，值得针对这组图像检查可见性。这里的位置标签与采购时的工件类型不同，具体定义见附录 D。

降低阈值能增加检出，也会增加误报。已有划痕记录中，阈值约 0.2038 时，测试召回约 93.5%，误报率约 58.8%。这组结果用于说明取舍，后续选择新阈值需要新的开发数据。

当前合并方案将 81/150 张图像标为疑似缺陷。由于还没有建立图像与工件的对应及复核规则，这个比例只能描述图像结果。测试数据中缺陷占 71/150，也不代表产线缺陷比例；实际复核工作量需要现场测量，精确率也会随缺陷比例变化。[3]

5 目前完成了什么，下一步验证什么

5.1 目前的成果与认识

目前完成的工作包括自建数据与标注、两类缺陷的模型比较，以及检测软件与原型集成。划痕实验比较分类与局部检测分数，齿部缺损实验比较标签划分和困难目标处理，再分别选择配置。我们也记录了权重和阈值怎样确定，让方案选择可以追溯到实验结果。

实验带来的认识是：两类缺陷值得分别比较配置，增加模型需要同时看检出、误报和计算代价。图像中是否有缺陷、框是否准确、工件是否正确分拣，也需要分别检查。项目采用主流网络和已有融合方法，现阶段成果主要是针对齿轮任务的探索、选择依据及软件实现。对新齿轮和生产现场的效果，还需后续验证。

5.2 下一阶段优先回答的问题

表 9 下一阶段验证优先级

优先问题	后续验证
对新工件是否有效	建立齿轮编号，按工件与拍摄批次分组，用未参加训练的新齿轮测试
困难缺陷能否拍清	控制光照与观察角，记录原图、缺陷可见性和漏检变化
参数与模型组合是否必要	控制其他条件比较输入、权重、成员模型与校准，记录共同错误及资源开销
人工复核如何覆盖漏检	明确模型未检出工件的复核或抽查方式，测量确认比例和复核时间
NX 能否满足工件处理节拍	记录采集、定位、识别、传输与分拣对应关系，以及分项耗时和长时运行情况

下一阶段先补齐工件编号、成像条件、复核流程和整机测量，再决定是否需要模型优化或扩大参数搜索。目前没有部署优化和每件检测耗时记录，速度目标应在测量后确定。详细建议与软件状态见附录 G。

附录 A 文献与证据的对应关系

表 10 文献支持与项目证据边界

文献	支撑内容	项目仍需提供的证据
[1] Raschka；[2] Cawley 与 Talbot	评价与选择区分，小样本选择风险	按工件分组划分数据、固定模型及判定参数、新数据评价
[3] Saito 与 Rehmsmeier	PR 解释及类别比例	实际缺陷比例及复核负担
[4] Guo 等	温度缩放与校准动机	校准前后质量、融合分数可靠性
[5] Tong 等；[6] Elkan	错误优先级、约束与成本	复核流程、成本和正式目标；当前无 NP 保证
[7] Bergstra 与 Bengio；[8] Snoek 等	后续搜索预算与昂贵实验选择	自身搜索过程及预算比较
[9] Shang 等	未来生产抽检与抽样校正	实际抽样记录；当前区间不源于该抽样法
[10]–[13] 模型与方法原始文献	骨干、多尺度与 Focal 机制	齿轮候选对照，具体参数值依据
[14] MVTec 官方资源	工业异常检测研究设定	自身正常样本多样性；本项目未使用该数据集
[15] Choi 与 Seong；[16] Kittler 等；[17] Wu 等	决策融合与分类器组合的已有用法	本项目自身的模型输出、融合公式及验证结果；文献不是历史参数来源
[18] Allam 等	双相机齿轮扫描、缺陷检测与齿轮级判定实例	本项目的成像覆盖、跨帧工件编号、复核规则及整机测量

附录 B 关键固定训练参数与资料索引

表 11 固定训练参数摘要

参数组	Scratch V5	Missing Hole V1	来源性质
自定义分类初始化/输入	ImageNet；长宽比保留、灰色填充	同左；输入 384 或 512	外部初始化及工程输入设计
归一化	ImageNet mean/std	同左	预训练输入约定
自定义优化器	AdamW，lr=3e−4，weight_decay=5e−4	同左	脚本预先固定的参数
学习率调度	余弦，eta_min=1e−6	同左	脚本预先固定的参数
Focal 损失设置	γ=1.5，最终 w_pos=1	γ=1.5，w_pos=2	前者候选组合，后者固定
自定义 batch	384→24；512→12	同左	计算预算约束
检测输入	960	960；1280 候选未入选	实验变量
检测优化器	AdamW，lr0=7e−4，weight_decay=5e−4	同左	预先固定的参数
最终 TTA	无	无	验证选择

表 按《GearPro 综合实验与部署技术报告》第 8.3、9.4 节摘要；各实验的有效配置应结合对应 args/history 读取。检测结构、batch、增强与训练预算有版本差异，完整逐次表保留在综合报告。

项目事实说明。本报告中由项目负责人确认的内容包括：50 个齿轮工件构成、使用实际流水线工业摄像头人工摆拍多角度图像、按图像可见缺陷标注（确认不可见作为负样本，可见但难辨认或难标边界时记为困难目标）、仅有图片顺序编号、明确缺陷均不合格、上下双相机、设备 NX、新模型简单测试未记录、人工复核方向与流程未定、软件/模型及硬件分工、历史目标无正式需求依据。

综合项目资料。GearPro 综合实验与部署技术报告，2026-10-03；其中第 17 节列明原始实验及阶段汇报来源。Git 的 main 分支中的阶段 PDF 作为历史状态补充，当前状态以项目负责人确认的信息更新。

表 12 实验资料与配置来源目录

资料名称	可核对文件	本文用途
划痕发布配置	V5 发布配置	成员、温度、融合、阈值、验证计数
齿部缺损发布配置	V1 发布配置	同上
划痕测试记录	V5 测试记录	测试计数、相似对提示
齿部缺损及联合测试记录	V1 及联合测试记录	检测任务、位置、OR 与统一模型
划痕数据清单	V5 数据清单	训练/验证拆分及缺少工件 ID 的状态
齿部缺损数据清单	V1 数据清单	各拆分、图像/标签及样例索引
划痕候选模型评价表	V5 候选模型评价表	划痕候选结果
齿部缺损候选模型评价表	V1 候选模型评价表	检测全因子及后续候选
齿部缺损融合候选评价表	V1 融合候选模型评价表	21 个融合候选及最终选择
划痕逐图预测与标注	V5 逐图预测及原图/XML	仅用于已记录错误的展示与解释
V3 测试与定位记录	V3 测试与定位记录	图像与区域两种评价、划痕计数差异
V4 初始基线记录	V4 初始基线记录	基线计数、指标与类别分组
V4 最终融合记录	V4 最终融合记录	融合计数、指标与类别分组
V4 发布配置	V4 发布配置	成员、增强及融合方式
V4 候选评价记录	V4 候选评价记录	扩展单模型验证阈值与增强方式
V4 详细技术报告	V4 详细技术报告	扩展单模型既有留出摘要及四路增强说明

图表由`build_report.py`读取上述记录生成，数值与来源汇总在`assets/chart_data.csv`，输入文件哈希和构建检查保存在`verification.json`。脚本只读取已有实验产物，不运行模型、不修改阈值。

附录 C 术语及方法名称

正文优先使用中文名称，必要时补充英文或代码名。独立训练的网络称为“成员模型”；针对同一类缺陷的两个分类模型和一个目标检测模型合称“检测子系统”。下表解释这些名称在项目中的含义，更多代码对应见术语对照表。

报告保留实验记录中的字段名 AUPRC。实际脚本先按分数从高到低逐样本排序，再累计“召回增量 × 当前精确率”，即 ΣΔRecall×Precision，属于 AP 式阶梯求和，并非梯形积分；相同分数按输入顺序处理，未按并列阈值成组。因此这些数值用于复现项目内的排序比较，与其他实现比较时应先统一计算方式。计算代码见划痕评价函数和V4 评价函数，V1 复用划痕函数。

表 13 术语与实际方法定义

中文名称	英文或代码名	本项目中的定义
齿部缺损	partial tooth damage；历史代码 missing_hole	齿侧或齿角等部位的局部缺失；不译为孔洞缺失
划痕检测子系统	Scratch V5	两个分类模型与一个目标检测模型的组合
齿部缺损检测子系统	Missing Hole V1	两个分类模型与一个目标检测模型的组合
分数级加权融合	score-level weighted fusion	对同类缺陷的模型分数进行加权平均
决策级融合	decision-level fusion	对两个子系统的二值判定进行合并
或规则	OR rule	任一子系统判为有缺陷，最终即判为有缺陷
温度缩放	temperature scaling	用正温度参数调整模型输出分数，参数根据验证集 NLL 选择
参考标注	ground truth annotations	人工标注的类别、边界框及困难目标标记
困难目标	difficult=1	确定存在缺陷但难以辨认的标注目标
正样本/负样本	positive/negative samples	含/不含当前任务可见目标缺陷的图像
精确率	precision	TP/(TP+FP)，与准确率 accuracy 不同
召回率	recall	TP/(TP+FN)，亦可解释为缺陷检出率
误报率	false positive rate	FP/(FP+TN)，与 FP/(TP+FP) 不同
预测为缺陷的样本比例	predicted-positive fraction	(TP+FP)/N；图像统计不能直接换算为工件送复核比例
目标级定位评价	object-level localization evaluation	基于预测框与标注框的匹配计算定位指标
初步实验	pilot experiment	以较低训练轮数上限比较候选配置
增加训练轮数上限的重新训练	retraining with a larger epoch limit	从预训练初始化重新训练，区别于从初步实验 checkpoint 接续训练
对照实验	comparative experiment	比较候选配置；多项因素同时变化时不解释为单因素效应
消融实验	ablation study	在控制其他条件下移除或改变某个组件，检验其作用；按实际设计使用

附录 D 数据检查与早期探索

正文的数据规模见第 1 章；以下保留构成、标注、拆分及早期方案的详细说明。

D.1 工件构成与位置标签

项目共有 50 个齿轮工件：正常 10 个，划痕 15 个，侧部缺损 15 个，齿角缺损 10 个。工件由项目自行采购或定制，采用上下、旋转、侧面等多个角度拍摄。

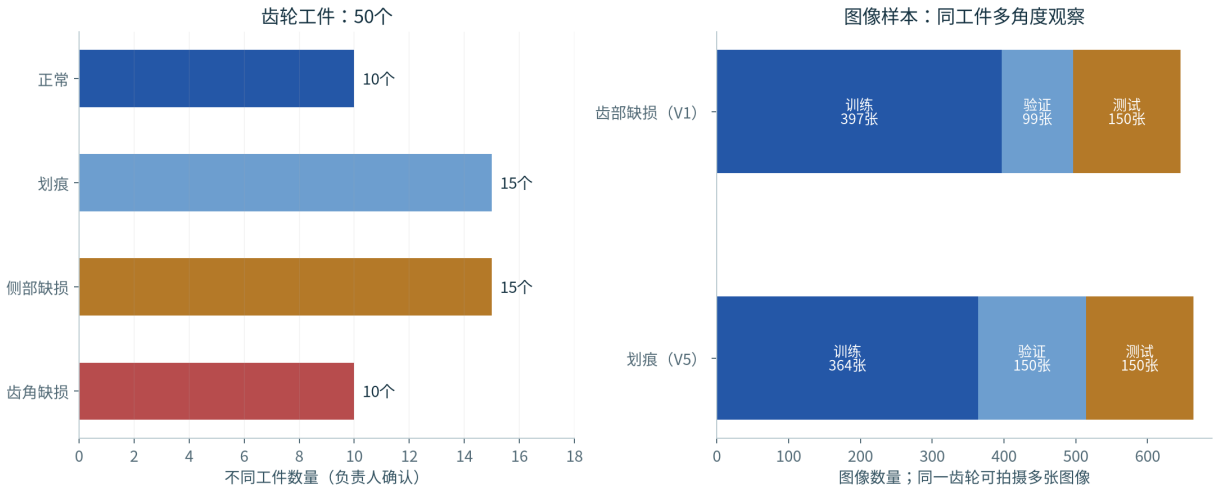


图 7　左侧为负责人确认的齿轮工件构成，右侧为两类缺陷的数据清单中的图像数量。多角度拍摄增加观察条件，不增加不同齿轮工件数量；图像尚未可靠对应到具体工件 ID。（来源：项目事实说明；划痕数据清单；齿部缺损数据清单）

这里有三个不同概念：采购齿轮时记录的缺陷类型、拍摄时的观察角度，以及 XML 中的位置标签。采购分类为“侧部缺损/齿角缺损”，V1 位置标注为 bottom/oblique/side；其他版本还使用按宽高比推断的视角。它们之间的对应关系还没有核对，所以报告分别保留原有定义。

D.2　数据规模与类别定义

表 14　数据规模及各任务正负样本定义

检测任务	训练图	验证图	测试图	正负样本定义
Scratch V5	364	150	150	有可见划痕 / 无可见划痕
Missing Hole V1	397	99	150	有可见齿部缺损 / 无可见齿部缺损

表　训练、验证数量来自清单（来源：划痕数据清单；齿部缺损数据清单），测试计数来自（来源：划痕测试记录；齿部缺损及联合测试记录）。两个检测子系统使用同一批 150 张测试图，但负样本定义不同。V1 排除困难目标后的训练集另有 391 张图。

150 张测试图中，划痕 31 张、齿部缺损 44 张、二者同时存在 4 张，因此含至少一类缺陷的图像为 71 张，无可见划痕或齿部缺损的图像为 79 张。无划痕图可能具有齿部缺损，无齿部缺损图可能具有划痕；两个检测子系统 FPR 的分母不能直接用于联合 FPR。

缺少某类标注不能自动解释为不含该类缺陷。统一模型的数据构建曾排除 59 张划痕状态未知且无齿部缺损的候选图像，保留类别状态已确定的数据。（来源：《GearPro 综合实验与部署技术报告》第 10.1.2 节）

D.3　近重复检查与工件划分限制

已有实验用 SHA256 检查相同文件，并用 dHash、序号、宽高比和灰度相关性检查相似图像。这些检查有助于发现重复，但当前清单只有图片顺序编号，没有照片与 50 个齿轮的可靠对应关系，同一齿轮的不同角度是否跨训练、验证和测试仍无法确认。（来源：项目事实说明；划痕数据清单；齿部缺损数据清单）

部分齿轮的缺陷形态独特，可能用于辨识工件；正常齿轮和缺陷不可见的照片则无法可靠辨识。本轮没有恢复或改写工件对应关系，因此完整的工件独立性仍未知。即使可辨识的照片没有跨集重复，也还需要检查其余照片。

V5 测试记录没有发现字节级重复，但提示 75 个 dHash≤2 的跨集合相似对。齿轮外形和背景相似也可能产生这种提示，需要逐图核对；目前还不能确定是否存在数据泄漏。现有记录能够确认配置固定后进行了图像评价，按工件分组的独立性还需补查。（来源：划痕测试记录）

现有测试描述的是这些图像上的检测效果。要判断对新采购齿轮、不同批次或新生产线是否有效，后续应给每个齿轮建立 ID，并将其所有角度、照明条件和连续帧放入同一个数据组。

D.4　训练、验证与测试职责

训练集用于学习网络参数，验证集用于选择模型、温度、融合方式和阈值，测试集用于评价固定配置。如果查看测试结果后继续调整方案，后续需要新的开发数据和未查看的测试数据，旧集合可用于检查修改后是否退步。[1][2]

这次整理只解释已有结果，没有重新训练或调整运行阈值。各阶段的数据和标签不同，所以跨版本比较主要解释思路如何变化，性能数值仍分别报告。

D.5　早期方案与转向依据



图 8　V3/V4 提供研究转向依据，V5/V1 承担重点技术探索。该图表示问题和设计演进，非同一数据上的性能趋势。（来源：《GearPro 综合实验与部署技术报告》第 3、6–10 节）

V3 用分类模型区分正常、划痕和齿部缺损，另用目标检测模型定位缺陷，还尝试了增强、P2 和正常特征距离。实验关注低对比划痕和不同视角下的缺损，也促使我们分别评价图像判断与区域定位。V4 随后合并两类缺陷，尝试统一二分类、多模型、纹理方法和融合。（来源：《GearPro 综合实验与部署技术报告》第 6–7 节）

V4 最终在留出集上检出 19/30 张缺陷图像，误报 7/20 张无可见目标缺陷图像；11 个漏检中 7 个来自划痕。这说明后续需要重点检查划痕，我们因此分别组织两类缺陷的数据与模型实验。第一次留出结果曾用于决定扩展方向，这批数据已参与探索，后续最终评价需要另选未查看的数据。（来源：《GearPro 综合实验与部署技术报告》第 7.7 节）

D.6 V3 划痕定位计数的未解释差异

原始测试 JSON 的划痕图像分类检出 4/11 张；整体定位评价记录 TP=0、FP=6、FN=19。另一个按视角逐框匹配的结果在 oblique 组、IoU=0.5 时记录 TP=1、FP=5、FN=9，其他视角 TP=0。（来源：V3 测试与定位记录）两套定位计数不能相加或互相替换，差异原因尚未核清。因此正文采用齿部缺损数据解释图像判定与定位的任务区别，不作“划痕完全无法定位”的结论。

D.7 V4 比较方案的配置与资料来源

表 15 V4 配置与历史结果来源

正文名称	实验或配置	验证选择阈值（约）	留出指标来源
基线模型	`p_resnet18_512_w4`；四路增强	0.640567	基线 JSON 的 test.overall V4 初始基线记录
扩展单模型	`xfull_resnet18_384_w1_s73_r1`；四路增强	0.571126	详细报告 §7.2 历史测试摘要V4 详细技术报告；阈值及增强另核对候选 JSON V4 候选评价记录
三模型融合	三个分类成员，分别四路增强，分数取最大值	0.702842	最终 JSON 的 test.overall V4 最终融合记录；发布配置V4 发布配置

扩展单模型的验证 AUPRC 约 0.860，正文表中的 0.899 是详细报告记载的既有留出 AUPRC，不能混用；该留出摘要本轮没有逐图预测重算证据。这里保留已有记录，不运行模型或重选阈值。

基线与最终融合的划痕召回均为 4/11；齿部缺损分别为 13/19 和 15/19。两个增加的检出计数来自齿部缺损，但尚未按逐图集合确认哪些图像被补检或丢失。前向次数 4 与 12 是配置推导，不是现场计时；所有结果仍受既有留出反馈、样本规模和工件划分限制。

附录 E 候选实验与未采用配置

E.1 划痕候选与比较限制

划痕实验尝试结合图像分类与局部检测线索。加工纹和高光可能与划痕混淆，局部预测框也可能不准，因此先比较两类模型及其分数组合对图像判断的影响，定位效果另行检查。

对照设计。正式记录包含 6 个分类模型初步实验、2 个目标检测模型初步实验和 2 个增加训练轮数上限的分类模型重新训练实验。初步分类实验比较 ResNet18、EfficientNet-B0、YOLO 分类器及 384/w1、512/w2 配置；目标检测实验比较 960 输入的原始 YOLO26n 与包含 P2 检测层的模型。实验还比较是否使用测试时增强（test-time augmentation，TTA），随后进入温度参数与融合规则选择。（来源：《GearPro 综合实验与部署技术报告》第 8 节；划痕候选模型评价表）

原始 YOLO26n 检测模型的召回率为 38/43、FPR 为 21/107，P2 对应 38/43 和 19/107；记录中的 AUPRC 约 0.828 与 0.866（计算定义见附录 C）。在相同召回率下，P2 误报更少，排序指标更高，进入最终组合。最终分类成员为增加训练轮数上限后重新训练的 EfficientNet-B0 与初步实验中的 ResNet18，两者 384 输入、w1、无 TTA。（来源：划痕发布配置；划痕候选模型评价表）

我们根据验证结果选择 P2 配置，但两个检测配置的 batch 不同，结构的单独作用还需要对照。384/w1 与 512/w2 也同时改变输入和权重。后续应固定其他条件比较这些设置，并核对模型在同一图像上的共同错误，检查融合成员是否必要。

P2 模型的最高框置信度参与图像判断，预测框是否准确则单独评价。原报告在 IoU=0.3 的框匹配中记录了大量 FP，所以目前显示框只供辅助观察。（来源：《GearPro 综合实验与部署技术报告》第 8.8–8.9 节）

E.2 齿部缺损候选与选择规则

我们比较标签划分和困难目标处理，是为了检查有限样本下哪种设置更合适。位置标签细分后可能更容易区分外观，也可能使每类样本不足；保留或排除困难目标会改变训练标注。V1 因此组合这些设置进行比较。

对照设计。初步目标检测实验采用三类/两类/单类 × 保留/排除困难目标 × 原始 YOLO26n/包含 P2 检测层的模型，共 12 组，统一 960 输入和 35 轮训练上限。随后进行 12 个初步分类实验、增加训练轮数上限的重新训练、第二个随机种子的验证、1280 输入对照及困难样本重采样与 CLAHE 增强实验，总计 34 个实验记录。（来源：《GearPro 综合实验与部署技术报告》第 9 节；齿部缺损候选模型评价表）

三类标注区分 bottom/oblique/side，两类合并 bottom 与 oblique，单类将位置归为一个齿部缺损目标。单类、排除困难目标的原始 YOLO26n 模型与包含 P2 检测层的模型均检出 33/34，原始 YOLO26n 检测模型误报 6/65，P2 误报 13/65。采用单类标注的原始 YOLO26n 模型以较低误报成为入选方向，说明细分标签或增加高分辨率特征层并未自动改善判定。

exclude_difficult 只修改训练集：删除 21 个困难目标的标注框，6 张仅含困难目标的图像整体排除，训练图 397→391、框 498→477。这样避免把已知缺陷图误当作负样本；验证与测试保留完整参考标注。（来源：《GearPro 综合实验与部署技术报告》第 9.3 节）

最终 EfficientNet 采用 512、排除仅含困难目标的训练图像，ResNet18 采用 384、保留困难目标，检测器采用单类标注的原始 YOLO26n 模型、960、排除困难目标。不同成员保留不同训练配置；它们的互补程度仍需逐图对照。（来源：齿部缺损发布配置）

最终保留初步实验的检测权重。重新训练模型的总体召回率和 FPR 相同，AUPRC 更高，但选择规则先比较各位置组中的最低召回率：初步实验约 0.917，重新训练约 0.909，所以初步模型入选。这个差别涉及少量样本，还需要重复实验检查是否稳定。（来源：《GearPro 综合实验与部署技术报告》第 9.11 节）

E.3 未采用配置

表 16 未采用配置及已有观察

探索	预期作用	现有观察与选择
V4 纹理三通道	强调亮度、局部对比和边缘	已有比较未支持替换 RGB 输入，最终方案保留 RGB
V5 四路 TTA	减轻外观变化	最终模型未采用测试时增强
V1 1280 输入	增加局部细节像素	所比较的重新训练配置该对照未支持替换最终模型，输入规模更大
V1 困难样本重采样与 CLAHE 增强	改善困难区域的学习	未替换当前最终检测器
V1 增加训练轮数上限后的重新训练	更充分拟合数据	最低位置组召回率的排序未优于初步实验模型，虽 AUPRC 更高

表 依据《GearPro 综合实验与部署技术报告》第 7–9 节。结论针对已有配置与数据；保留这些实验，是为了说明方案怎样收敛，而非宣称相应方法在所有场景无效。

附录 F 参数选择与补充结果

F.1 训练参数、采样与框架配置

分类网络从 ImageNet 预训练参数初始化，替换输出层后训练。YOLO 使用官方初始化，或从已有权重加载可迁移参数到 P2 配置。最终使用的 checkpoint 由训练保存和验证选择得到，网络各层的参数通过训练更新。（来源：《GearPro 综合实验与部署技术报告》第 8–9 节）

自定义分类器使用 Focal BCE：$L = \text{mean}[w_y(1-p_t)^\gamma \,\text{BCE}(z,y)]$，其中`p_t`为真实类别的预测分数。Focal 机制降低易样本的损失占比，参考 Lin 等 [13]。项目预设 γ=1.5；V5 在候选组合中比较 w1/w2，最终使用 w1；V1 固定正类权重 2，其单独作用还未验证。

逆频率采样 $w_i = 1/n_{(\text{label, view or position})}$ 调整样本被抽到的频率，损失权重则调整抽到后对训练损失的影响。脚本另设 FN×3、FP×2 的困难样本乘数，但 V5 这轮实际只对一张训练 FP 额外加权。因此目前还没有证据说明困难样本加权带来了主要收益。（来源：《GearPro 综合实验与部署技术报告》第 8.5 节）

YOLO 分类候选的 w2 通过复制正类文件增加正类的出现频率，自定义分类器则使用损失权重。检测 args 中的 box/cls/dfl 设置为 7.5/0.5/1.5，来自框架配置，没有逐项消融；哪些字段实际参与训练，需要结合任务实现和 loss 日志核对。（来源：《GearPro 综合实验与部署技术报告》第 5.2、8.5、9.1 节）

F.2 温度参数选择

温度缩放先将原始分数 p 转换为 $\text{logit}(p) = \ln[p/(1-p)]$，再计算 $p_T = \text{sigmoid}(\text{logit}(p)/T)$。我们在 [0.35,4.00] 中比较 147 个等距温度候选，选择验证集负对数似然（NLL）最小的 T。NLL 衡量分数与真实标签的符合程度，越小越好；边界分数按发布实现处理。（来源：《GearPro 综合实验与部署技术报告》第 5、8.3.4 节）

温度缩放参考 Guo 等 [4]。正温度不会改变单个模型分数的排序，但会改变融合时各模型分数的相对尺度。当前记录了温度选择，还需要比较校准前后的 NLL、可靠性图和分箱样本量，检查分数是否更可靠。

F.3 融合公式、候选与完整阈值

将两个分类模型经温度缩放后的分数先取平均 $c = (s_{\text{Eff}} + s_{\text{Res}})/2$，再比较 $f_\alpha = \alpha c + (1-\alpha)s_{\text{det}}$，$\alpha \in \{0.25, 0.50, 0.75\}$，同时比较单模型、分类分数平均/最大值及与检测模型分数取最大值的方案。V5 记录 20 个融合候选规则，V1 保留 21 个候选成绩。（来源：《GearPro 综合实验与部署技术报告》第 8.2、9.6 节；齿部缺损融合候选评价表）

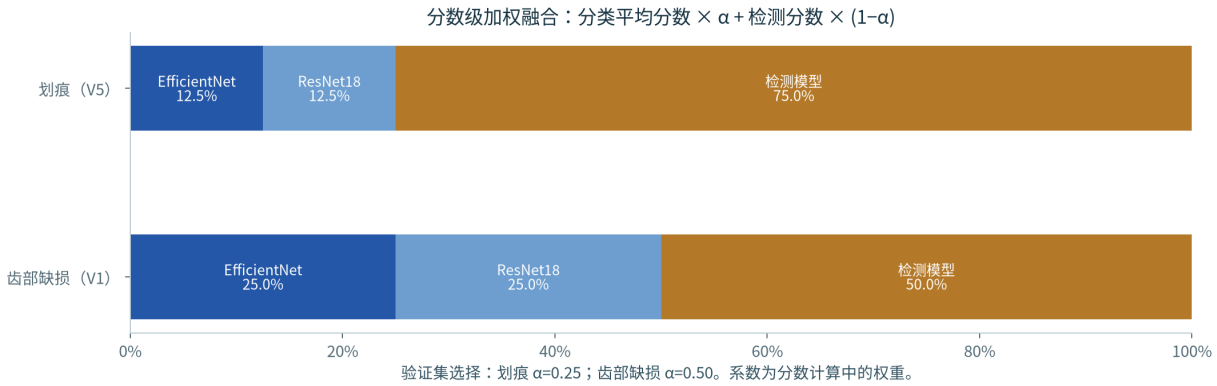


图 9 发布配置（来源：划痕发布配置；齿部缺损发布配置）中的融合公式展开。划痕 α=0.25，所以分类器分别 0.125、检测器 0.75；齿部缺损 α=0.50，所以分类器分别 0.25、检测器 0.50。系数表示分数计算规则，不能解释为因果贡献或定位精度。

表 17 最终成员系数、温度及阈值

检测任务	分类模型 1：EfficientNet	分类模型 2：ResNet18	目标检测模型	温度参数 T（同序）	判定阈值（展示值）
划痕 V5	0.125	0.125	0.750	0.700/2.050/2.125	0.3003
齿部缺损 V1	0.250	0.250	0.500	1.000/2.375/1.850	0.3413

V1 的分类平均分数与检测分数等权融合时，结果为 34TP、4FP；仅将 EfficientNet 分数以 0.25 权重与检测分数组合时，计数也相同。两者 AUPRC 约为 0.966 和 0.963，所以按既定排序选择前者。这是采用 0.50 的记录依据，其稳定优势还需要进一步比较。（来源：齿部缺损融合候选评价表）

运行时使用 JSON 中的完整阈值：划痕为 0.300273610279458，齿部缺损为 0.3413327979078584。正文显示四位小数方便阅读，运行配置保持原值。（来源：划痕发布配置；齿部缺损发布配置）

F.4 阈值选择与两类结果合并

阈值选择先扫描固定候选的验证分数，优先满足 FPR≤0.20，再提高 Recall，并按规则比较位置组召回、FPR 和 AUPRC。齿部缺损还优先考虑各位置组中的最低召回率。这里选择的是图像判断配置，目标框的 mAP 需要另外评价。（来源：《GearPro 综合实验与部署技术报告》第 8.3.4、9.2 节）

Recall≥0.95、FPR≤0.20 没有正式产线需求或成本测算依据，本文将其保留为**历史实验目标及选择约束**。0.20 解释当时阈值如何被选出；0.95 解释历史目标，不作为本项目当前生产验收标准。结果继续保留真实数值，评价重点转向检出能力及人工复核负担。

决策级融合采用或规则：REJECT $= (s_{\text{scratch}} \geq \tau_{\text{scratch}}) \vee (s_{\text{missing}} \geq \tau_{\text{missing}})$。这里 OR 表示逻辑或：任一检测子系统判为有缺陷，最终即判为有缺陷。两个子系统的分数针对不同缺陷，负样本定义和温度参数估计所用的数据不同，因此分别进行阈值判定，再合并二值结果。每个任务的 FPR 约束不自动成为融合系统的 FPR 约束，不含这两类缺陷的图像上的误报需单独统计。工业外观检测已有采用缺陷类别独立建模与或规则决策融合的研究 [15]；该文献用于方法命名及相关工作比较，不是历史参数来源。

F.5 复核评价框架

漏检优先的使用方向需要同时呈现：**主指标召回率，配套指标误报率、精确率和预测为缺陷的样本比例**。对同一集合，预测为缺陷的样本比例为 $q = (\text{TP} + \text{FP})/N$，它在当前记录中只表示图像预测比例。只有评价单位与工件一一对应，且全部疑似工件送复核时，才等于工件送复核比例；多视角图像不能直接作此换算。

表 18 人工复核评价框架

评价问题	当前可以给出的证据	尚需明确的信息
有多少缺陷漏检	FN 计数、总体及困难目标所在图像的 Recall	被判为无缺陷的工件是否复核或抽查
正常件增加多少检查	FP 计数和 FPR	人工复核时间、处理能力
一共需要检查多少件	当前数据上的预测为缺陷的样本比例	真实缺陷比例、复核流程
应选择哪个判定阈值	历史阈值对应的验证结果及误差分析	两类缺陷标签完整的新开发数据、可接受漏检与复核负担

成本敏感学习和错误约束研究 [5][6] 帮助确定需要优先控制哪类错误。具体接受多少漏检、承担多少复核，还要根据实际流程确定。当前保留历史权重和阈值，后续用新的开发数据选择阈值，旧测试用于回归检查。

F.6 参数来源完整表

表 19 参数来源完整表

参数	采用值/方法	来源类型与证据
网络参数	预训练初始化后微调	外部初始化＋对应训练实验保存
分类骨干与输入	V5 两个分类模型均为 384；V1 为 512/384	验证候选选择；V5 输入与 w 同时变化
检测结构	V5 含 P2 检测层；V1 单类原始 YOLO26n	两类任务分别对照；batch 等条件仍有差异
Focal 聚焦参数 γ / V1 正类权重	1.5 / 2	预先固定的训练参数，未独立消融
采样与难例乘数	逆频率；FN3、FP2	预先设定的采样规则，实际使用范围见附录 F.1
温度参数	每个检测子系统的三个成员模型分别估计 T	验证 NLL 估计，数值见划痕发布配置；齿部缺损发布配置
融合系数	α=0.25/0.50	验证有限候选搜索与均值展开
判定阈值	约 0.3003/0.3413	固定融合的验证扫描
ROI 裁剪边界扩展	4%	实现设定，未独立消融
候选框保留下限 / NMS IoU	0.001 / 0.7	推理配置；不同于判定及框显示门槛
学习率、优化器、增强范围	各训练脚本预先设定的值	完整归档见附录 B，未逐项证明最优

F.7 验证与测试差异

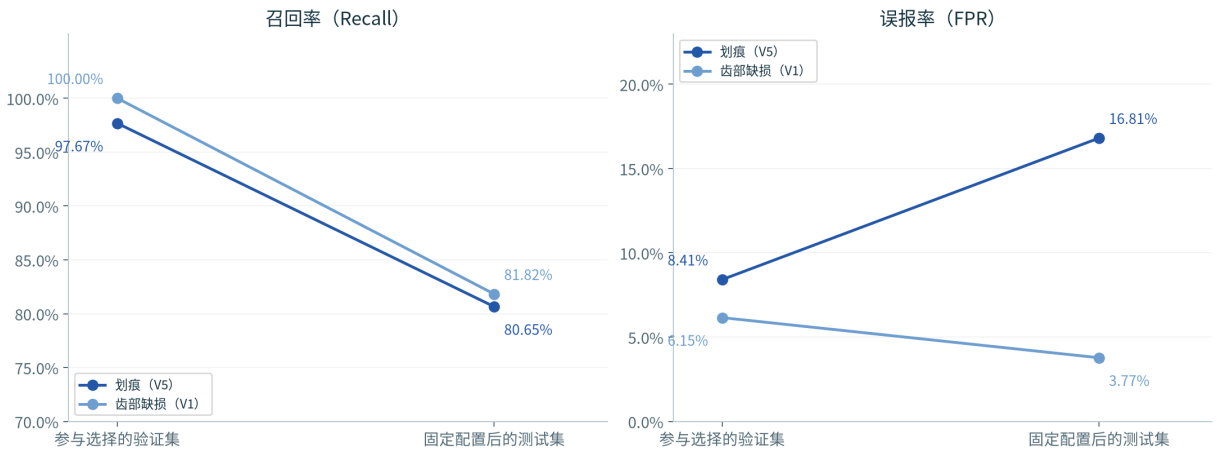


图 10 每条线连接同一缺陷类别的验证与测试指标。两任务分母不同；验证参与多层选择，线条不表示时间上的退化。数据来自（来源：划痕发布配置；齿部缺损发布配置；划痕测试记录；齿部缺损及联合测试记录）。

划痕验证集正确检出 42/43、误报 9/107，测试集正确检出 25/31、误报 20/119；齿部缺损验证集正确检出 34/34、误报 4/65，测试集正确检出 36/44、误报 4/106。测试召回均约 81%，明显低于参与选择的验证表现。

差异可能涉及验证选择偏差、拍摄条件变化和困难样本覆盖不足，当前数据不能量化各因素贡献。按图像计数的 Wilson 95% 召回区间：划痕约 63.7%–90.8%，齿部缺损约 68.0%–90.5%；同一工件图像间的相关性未知，区间仅作描述性参考。

F.8 位置分组结果

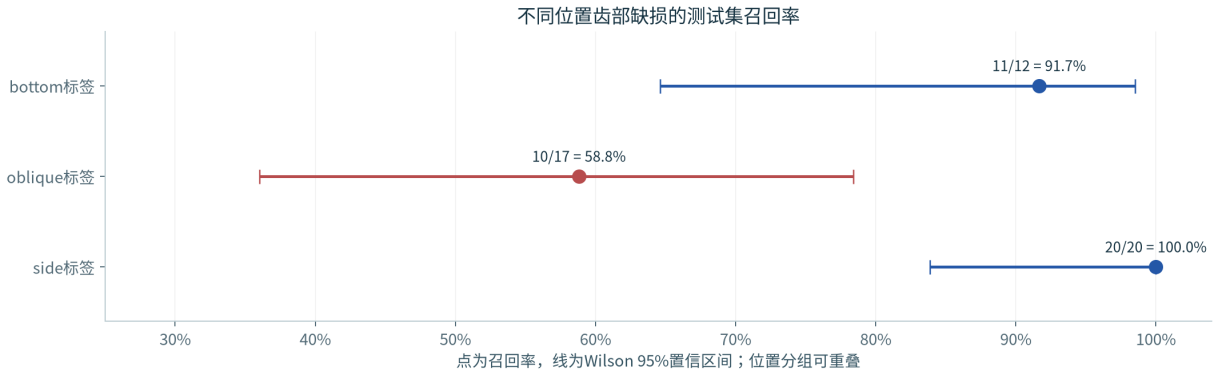


图 11 bottom 为 11/12、oblique 为 10/17、side 为 20/20。位置分组可重叠，数量之和 49 大于 44，不能相加算总体召回；区间按图像计数推导。（来源：齿部缺损及联合测试记录）

齿部缺损 8 个漏检中 7 个属于 oblique，说明这类位置是当前采集和可见性检查的重点。side 的 20/20 也应结合样本量理解。包含困难目标、忽略困难目标和仅评价非困难样本这三种条件下，召回率均约 0.81，困难目标标记并不能充分解释测试结果下降。（来源：《GearPro 综合实验与部署技术报告》第 9.7 节；齿部缺损及联合测试记录）

F.9 缺陷比例与复核负担

联合测试可见目标缺陷图像比例 71/150，是富含缺陷的研究数据，不代表生产线。假设可见缺陷图像的召回率和无可见目标缺陷图像的误报率保持不变，Precision $= \pi R/[\pi R + (1-\pi)\mathrm{FPR}]$，预测为缺陷的样本比例为 $q = \pi R + (1-\pi)\mathrm{FPR}$，$\pi$ 为应用条件下的可见目标缺陷图像比例，并非整件缺陷率。[3]

测试精确率 77.78% 还不足以判断产线人工复核的效果。后续应测量现场图像与工件的缺陷比例、模型未检出工件中的漏检、疑似工件的人工确认比例及复核时间，再选择适合实际流程的阈值。目前人工复核效果尚未测量。

F.10 合并结果的类别解释与划痕分组统计

齿部缺损检测本身检出 36/44 张正样本；两类结果合并后，这 44 张图像中有 41 张被标为疑似缺陷。其中 5 张由划痕检测判为有缺陷，不能据此将齿部缺损检测的正确检出数改为 41。（来源：齿部缺损及联合测试记录）

历史划痕分析中，漏检组的分类模型平均分数约 0.455、检测模型平均分数约 0.144；误报组的分类模型平均分数约 0.814。结合图像外观，加工纹和高光是值得检查的误报来源，但分组均值不能直接解释每张图像的错误原因。（来源：《GearPro 综合实验与部署技术报告》第 8.6.3 节）

F.11 单模型与融合对照的完整记录

下表记录同一任务验证集上各方案按 FPR≤0.20 规则选择的结果。α 是分类分数系数，检测分数系数为 $1-\alpha$；若分类分数是两个分类器的均值，组合就包含三个成员。各方案使用各自阈值，组件的单独作用还需消融实验检查。划痕最终融合 AUPRC 未在发布配置中载明，表中保留缺项。

表 20 单模型与融合完整验证记录

任务	实验名／配置	组合规则	TP／FP	完整阈值	AUPRC	来源
划痕	`f_efficientnet_b0_384_w1_s20260911`	单模型	41／13	0.542919409017341	0.893870	候选评价表
划痕	`p_detector_p2_960`	单模型	38／19	0.18610403292287162	0.866130	候选评价表
划痕	发布配置中的两个分类模型及 P2 检测模型	分类均值与检测分数加权，α=0.25	42／9	0.300273610279458	未载明	发布配置
齿部缺损	`f_cls_efficientnet_b0_512_exclude_difficult_s20260913`	单模型	34／6	0.3809993863105774	0.924740	融合候选评价表
齿部缺损	`p_det_one_class_exclude_difficult_standard_960`	单模型	33／6	0.12059450038989711	0.944733	融合候选评价表
齿部缺损	`classifier_mean`	两个分类分数均值	34／5	0.5251138191759659	0.894532	融合候选评价表

续下页

任务	实验名／配置	组合规则	TP／FP	完整阈值	AUPRC	来源
齿部缺损	`weighted_f_cls_efficientnet_b0_512_exclude_difficult_s20260913_0.25`	EfficientNet 与检测分数加权，α=0.25	34／4	0.20599650265366867	0.963388	融合候选评价表
齿部缺损	`weighted_classifier_mean_0.5`	分类均值与检测分数加权，α=0.50	34／4	0.3413327979078584	0.965955	融合候选评价表

本轮还未核对单模型与融合逐图的新增检出和丢失图像，因此计数差表示净变化。齿部缺损两模型与三模型都是 34TP、4FP，具体预测图像、部署代价和稳定性仍需比较。当前配置保持不变，后续再检查成员必要性与 NX 开销。

附录 G 软件、整机状态与后续测量

G.1 软件输出链路

我负责软件和模型，其他成员负责硬件及后续现场部署。软件分别用采集线程和推理线程处理图像，齿轮定位模型（代码名称 Model1）生成 ROI，再执行两个检测子系统。每次结果保存成员分数、实际阈值、缺陷类别、预测框和耗时。

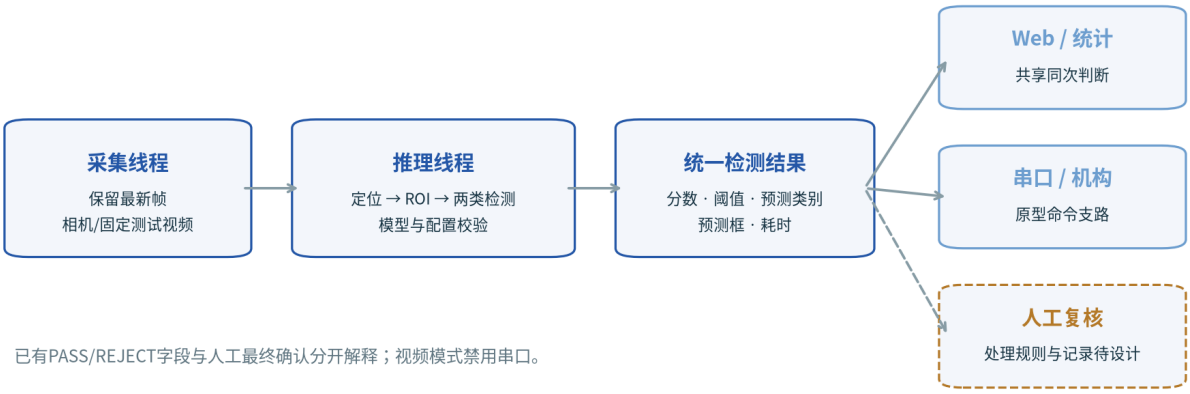


图 12 软件将同次检测结果提供给页面、统计和串口；原型已完成分拣模块联调，人工复核规则和记录方式还待确定。图据《GearPro 综合实验与部署技术报告》第 13 节及负责人确认绘制。

软件用同一个检测结果对象（代码名称 Observation）向页面、统计模块和串口提供结果，避免不同模块各自判断。加载模型时检查配置、版本和文件哈希；暂停后恢复时复用已加载模型。如果必要检测子系统运行失败或分数非法，就停止有效检测输出，避免将运行错误当成通过结果。（来源：《GearPro 综合实验与部署技术报告》第 13 节）

G.2 原型状态

当前仍使用上下两台工业相机，设备已升级为 NX。第一代原型已完成输送、采集、显示与分拣模块联调。新模型只做过简单现场测试，未记录测试数据，整机性能还需要系统测量。

历史软件优先处理最新帧，并设置 5 秒间隔抑制重复计数，以减少积压和重复统计。还需要按工件检查这些设置是否合适，尤其是一帧出现多个齿轮时，整帧判断怎样对应每件分拣。目前尚无

完整跨帧工件 ID 追踪、检测耗时和分拣对应测量。（来源：《GearPro 综合实验与部署技术报告》第 13.1–13.4 节）

表 21 软件与原型状态

内容	当前状态	报告中的证据层级
自建数据与标注	已完成多角度拍摄，图像与工件的对应关系未建立	项目负责人确认＋图像与标签清单
V5/V1 离线模型	已有配置、权重索引与测试记录	配置及 JSON/CSV
Web、统计与串口	已实现统一结果链路	阶段材料记载的实现
上下双相机、NX、机构	第一代原型链路	实物与负责人确认
当前模型 NX 现场测试	简单测试，未记录数据	功能尝试，缺系统性能测量
人工复核流程	应用方向已明确，流程未定	设计需求
部署优化与节拍	尚未开展相应模型优化及时间考虑	后续测量与优化

G.3 整机测量

后续应从相机原帧开始记录齿轮定位、ROI、缺陷判断、串口命令和实际分拣结果。漏定位、未处理、工件错配、命令迟到和未执行都应纳入统计，并分别说明评价对象和分母。这样才能同时检查识别效果与整机流程。

NX 测试先使用当前发布配置，分别记录取帧、定位、各成员模型、后处理和传输时间，同时记录设备温度、资源占用及长时运行表现，再决定是否需要 FP16 等优化。目前还没有确定每件工件的处理时间要求，也没有实测时延与吞吐率。

G.4 后续实验与评价方法

表 22 后续实验与评价方法

待回答的问题	拟开展验证	主要输出
对新齿轮是否有效	建立工件 ID；按工件和拍摄批次分组，采集训练中未见的齿轮	新齿轮工件测试及样本构成
哪些缺陷实际拍得清	固定工件与相机，逐项比较照明、观察角和载台	原图、可见性、定位与困难子组变化
V5 输入与权重各自作用	同拆分和骨干，384/512×w1/w2	解耦后的候选与波动
成员模型校准和融合是否必要	固定成员模型参数，独立校准/开发比较，保存错误交集	NLL、可靠性图、识别收益与开销
复核流程怎样减少漏检	明确被判为无缺陷的工件处理、复核能力与新的判定阈值	Recall、FPR、确认比例及复核时间
NX 是否满足真实节拍	完整原型记录分项耗时和工件命令对应	时延分布、覆盖、资源与稳定性

如果后续需要比较较多参数，可以先用随机搜索作为预算对照 [7]；训练成本较高时，再考虑贝叶斯优化 [8]。当前还没有使用这两种方法，优先把数据来源和待回答的问题确定清楚。

上线后如缺陷稀少、标注预算有限，可参考 Shang 等按预测结果分层抽样并校正 P/R 估计的研究 [9]。这涉及测试抽样，与训练正类复制不同；实际流程需包含被判为无缺陷的工件抽查，才能评价漏检。

参考文献

[1] Raschka S. Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning. arXiv:1811.12808, 2018; v3, 2020. 预印本/综述教程，非正式同行评审论文。

[2] Cawley G C, Talbot N L C. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. JMLR, 2010, 11:2079–2107.

[3] Saito T, Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE, 2015, 10(3):e0118432.

[4] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks. ICML, PMLR 70, 2017:1321–1330.

[5] Tong X, Feng Y, Li J J. Neyman-Pearson Classification Algorithms and NP Receiver Operating Characteristics. Science Advances, 2018, 4(2):eaao1659. 作者机构全文。

[6] Elkan C. The Foundations of Cost-Sensitive Learning. IJCAI, 2001:973–978.

[7] Bergstra J, Bengio Y. Random Search for Hyper-Parameter Optimization. JMLR, 2012, 13:281–305.

[8] Snoek J, Larochelle H, Adams R P. Practical Bayesian Optimization of Machine Learning Algorithms. Advances in Neural Information Processing Systems 25, 2012.

[9] Shang H, Langlois J M, Tsioutsiouliklis K, Kang C. Precision/Recall on Imbalanced Test Data. AISTATS, PMLR 206, 2023:9879–9891.

[10] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016:770–778.

[11] Tan M, Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML, PMLR 97, 2019:6105–6114.

[12] Lin T Y, Dollár P, Girshick R, He K, Hariharan B, Belongie S. Feature Pyramid Networks for Object Detection. CVPR, 2017:2117–2125.

[13] Lin T Y, Goyal P, Girshick R, He K, Dollár P. Focal Loss for Dense Object Detection. ICCV, 2017:2980–2988.

[14] MVTec Software GmbH. MVTec AD 工业异常检测数据集官方说明. 在线数据集资源，访问日期 2026-10-06；用于研究设定说明，项目未以该数据集训练。

[15] Choi K J, Seong J T. A Decision-Level Fusion Hybrid Deep Learning Framework for High-Precision Automated Optical Inspection of VCSEL Semiconductor Devices. AIMS Mathematics, 2026, 11(5):14487–14521. DOI:10.3934/math.2026594.

[16] Kittler J, Hatef M, Duin R P W, Matas J. On Combining Classifiers. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(3):226–239. DOI:10.1109/34.667881.

[17] Wu X, Zhang Q, Wang J, Yao J, Guo Y. Multiple Detection Model Fusion Framework for Printed Circuit Board Defect Detection. Journal of Shanghai Jiaotong University (Science), 2023, 28(6):717–727. DOI:10.1007/s12204-022-2471-0.

[18] Allam A, Moussa M, Tarry C, Veres M. Detecting Teeth Defects on Automotive Gears Using Deep Learning. Sensors, 2021, 21(24):8480. DOI:10.3390/s21248480.